

# Minería de Datos

## Análisis del dataset Cancer

Clasificación, regresión y clustering aplicados al diagnóstico de cáncer de mama

Integrantes:

- Julian David Cabrera Barragan
- Nelson David Posso Suarez
- Edward Julian Garcia Gaitan
- Juan David Cordoba Aguirre

# Problema, dataset y variables

Contexto compactado para enfocar la defensa en el modelado

Registros

569

observaciones

Columnas analíticas

31

diagnosis + 30

Clase objetivo

diagnosis

B / M

## Problema principal

- Clasificación binaria: tumor benigno (B) o maligno (M).
- Regresión: predicción de una variable continua del tumor.
- No supervisados: exploración de agrupamientos y reducción dimensional.

El objetivo no es solo acertar: es justificar qué modelo conviene según métricas y contexto médico.


## Estructura de variables

| Sufijo | Significado    | Ejemplo         |
|--------|----------------|-----------------|
| _mean  | Promedio       | radius_mean     |
| _se    | Error estándar | area_se         |
| _worst | Valor extremo  | concavity_worst |

### Mediciones celulares:

- Radio.
- Textura.
- Perímetro.
- Área.
- Suavidad.
- Compacidad.
- Concavidad.
- Puntos cóncavos.
- Simetría.
- Dimensión fractal.

Distribución de diagnosis



# Calidad y preparación de datos

Decisiones técnicas antes de entrenar modelos

## Calidad de datos

- Se normalizaron nombres de columnas y valores de texto.
- Se revisaron nulos, duplicados y tipos de datos.
- Se excluyó id del modelado por ser identificador.
- Outliers IQR: se conservaron por posible valor clínico.

**Decisión clave: en datos médicos un valor extremo puede ser una señal, no necesariamente un error.**

## Preparación común


- Encoding: M = 1, B = 0.
- Separación X/y: 30 variables predictoras.
- Train/test: 80/20 estratificado para clasificación.
- Escalado StandardScaler para KNN, SVM y PCA.
- PCA con 5 componentes: 84.94% de varianza acumulada.

Train

**455 × 30**



Test

**114 × 30**



# EDA resumido: patrones antes del modelado

La correlación se presenta como parte del análisis exploratorio



## Lectura técnica

El EDA mostró que variables asociadas a tamaño, perímetro, área, concavidad y puntos cóncavos separan mejor benignos y malignos. También hay correlaciones fuertes entre variables de tamaño, por eso PCA es una alternativa lógica para reducir redundancia.

# Estrategia de modelado y evaluación

Qué se implementó y cómo se comparó

## Clasificación

Predicción de diagnóstico (B/M)

- Accuracy
- Precision
- Recall
- F1
- Matriz de confusión

## Regresión

Predicción de area\_worst

- MAE
- MSE
- RMSE
- $R^2$

## No supervisados

Agrupamiento y reducción dimensional

- PCA
- KMeans
- Jerárquico
- DBSCAN
- SilhouetteDunn

**Criterio final de clasificación: Recall primero, luego F1-score y finalmente Accuracy. En un problema médico, el error más costoso es dejar pasar un maligno como benigno.**

# Modelo de clasificación: Regresión logística

Implementación, métricas principales e interpretación técnica

## MODELO APLICADO

### Regresión logística

- Modelo lineal usado como base interpretable.
- Se entrenó sin PCA usando Pipeline con StandardScaler.
- También se entrenó con 5 componentes principales.
- Con PCA mejora Recall y F1 en esta partición.

### Lectura para defensa

La versión con PCA logra el mejor balance general: Recall 0.9524 y F1 0.9639. Esto sugiere que la frontera lineal sobre componentes principales fue suficiente para separar las clases.

## RESULTADOS

| Variante       | Acc.   | Prec.  | Recall | F1     |
|----------------|--------|--------|--------|--------|
| Log. - PCA 5   | 0.9737 | 0.9756 | 0.9524 | 0.9639 |
| Log. - sin PCA | 0.9649 | 0.9750 | 0.9286 | 0.9512 |

Mejor variante

Log. - PCA 5

según Recall > F1

Recall


0.952

clase M

F1-score

0.964

balance



# Modelo de clasificación: KNN

Implementación, métricas principales e interpretación técnica

## MODELO APLICADO

### K-Nearest Neighbors

- Clasifica por cercanía a los vecinos más próximos.
- Se validó la necesidad de escalado.
- Se usó K=5 como configuración final.
- Se comparó sin PCA y con PCA de 5 componentes.

### Lectura para defensa

KNN depende de la distancia entre observaciones. Sin PCA tuvo mejor F1 que con PCA; aun así quedó por debajo de Logística y SVM en recall y F1.

## RESULTADOS

| Variante      | Acc.   | Prec.  | Recall | F1     |
|---------------|--------|--------|--------|--------|
| KNN - sin PCA | 0.9561 | 0.9744 | 0.9048 | 0.9383 |
| KNN - PCA 5   | 0.9474 | 0.9737 | 0.8810 | 0.9250 |

Mejor variante

KNN - sin PCA

según Recall > F1

Recall


0.905

clase M

F1-score

0.938

balance



# Modelo de clasificación: Árbol de decisión

Implementación, métricas principales e interpretación técnica

## MODELO APLICADO

### Árbol de decisión


- Modelo basado en reglas y cortes sobre variables.
- Se ajustó max\_depth=5 y min\_samples\_leaf=2.
- Se comparó con variables originales y componentes PCA.
- Es el modelo más fácil de explicar visualmente.

### Lectura para defensa

El árbol con PCA superó al árbol sin PCA, pero ambos quedaron por debajo de los modelos lineales y SVM. Su fortaleza principal es interpretabilidad, no rendimiento máximo.

## RESULTADOS

| Variante        | Acc.   | Prec.  | Recall | F1     |
|-----------------|--------|--------|--------|--------|
| Arbol - PCA 5   | 0.9386 | 0.9487 | 0.8810 | 0.9136 |
| Arbol - sin PCA | 0.9123 | 0.9444 | 0.8095 | 0.8718 |





# Modelo de clasificación: Árbol de decisión

Implementación, métricas principales e interpretación técnica

MODELO APLICADO

## Árbol de decisión

- Modelo basado en reglas y cortes sobre variables.
- Se ajustó max\_depth=5 y min\_samples\_leaf=2.
- Se comparó con variables originales y componentes PCA.
- Es el modelo más fácil de explicar visualmente.

### Lectura para defensa

El árbol con PCA superó al árbol sin PCA, pero ambos quedaron por debajo de los modelos lineales y SVM. Su fortaleza principal es interpretabilidad, no rendimiento máximo.

RESULTADOS

| Variante        | Acc.   | Prec.  | Recall | F1     |
|-----------------|--------|--------|--------|--------|
| Arbol - PCA 5   | 0.9386 | 0.9487 | 0.8810 | 0.9136 |
| Arbol - sin PCA | 0.9123 | 0.9444 | 0.8095 | 0.8718 |

Mejor variante

Arbol - PCA 5

según Recall > F1

Recall


0.881

clase M

F1-score

0.914

balance



# Modelo de clasificación: Random Forest

Implementación, métricas principales e interpretación técnica

## MODELO APLICADO

### Random Forest

- Ensamble de múltiples árboles para reducir varianza.
- Se entrenó sin PCA con 200 árboles.
- Se entrenó con PCA usando 100 árboles.
- Se revisó importancia de variables en la versión sin PCA.

### Lectura para defensa

Random Forest sin PCA obtuvo Precision perfecta y F1 alto, pero su Recall fue menor que Logística con PCA y SVM. Es robusto, aunque menos interpretable que un árbol.

## RESULTADOS

| Variante     | Acc.   | Prec.  | Recall | F1     |
|--------------|--------|--------|--------|--------|
| RF - sin PCA | 0.9649 | 1.0000 | 0.9048 | 0.9500 |
| RF - PCA 5   | 0.9561 | 0.9744 | 0.9048 | 0.9383 |

Mejor variante

**RF - sin PCA**

según Recall > F1

Recall

**0.905**


clase M

F1-score

**0.950**

balance

Random Forest: top variables



# Modelo de clasificación: SVM

Implementación, métricas principales e interpretación técnica

## MODELO APLICADO

### Support Vector Machine

- Busca una frontera de separación con margen máximo.
- Se usó kernel RBF en el notebook.
- Requiere escalado por sensibilidad a magnitudes.
- Se comparó sin PCA y con PCA.

## RESULTADOS

| Variante      | Acc.   | Prec.  | Recall | F1     |
|---------------|--------|--------|--------|--------|
| SVM - sin PCA | 0.9737 | 1.0000 | 0.9286 | 0.9630 |
| SVM - PCA 5   | 0.9649 | 0.9750 | 0.9286 | 0.9512 |

Mejor variante

**SVM - sin PCA**

según Recall > F1

Recall

**0.929**

clase M


F1-score

**0.963**

balance

### Lectura para defensa

SVM sin PCA fue el segundo mejor modelo por F1, con Accuracy empatado con Logística con PCA. Su principal límite es menor interpretabilidad y sensibilidad a hiperparámetros.



# Modelo de clasificación: Naive Bayes

Implementación, métricas principales e interpretación técnica

## MODELO APLICADO

### Gaussian Naive Bayes

- Modelo probabilístico rápido y simple.
- Asume independencia condicional entre variables.
- Se aplicó sobre variables originales y PCA.
- Sirve como baseline probabilístico.

## RESULTADOS

| Variante           | Acc.   | Prec.  | Recall | F1     |
|--------------------|--------|--------|--------|--------|
| Naive B. - sin PCA | 0.9386 | 1.0000 | 0.8333 | 0.9091 |
| Naive B. - PCA 5   | 0.9035 | 0.9189 | 0.8095 | 0.8608 |

Mejor variante

**Naive B. - sin PCA**

según Recall > F1

Recall

**0.833**

clase M



F1-score

**0.909**

balance

### Lectura para defensa

Naive Bayes logró Precisión alta sin PCA, pero el Recall fue bajo. La correlación entre variables del dataset debilita el supuesto de independencia.




# Modelos de regresión

Predicción de una variable continua: area\_worst

Modelos evaluados: Lineal, Ridge, Lasso, Árbol de Regresión y Random Forest Regressor; cada uno se comparó sin PCA y con PCA.

| Modelo              | MAE   | RMSE  | R²     |
|---------------------|-------|-------|--------|
| Lasso - sin PCA     | 21.2  | 35.5  | 0.9962 |
| Lineal - sin PCA    | 21.3  | 35.6  | 0.9962 |
| Ridge - sin PCA     | 23.5  | 40.1  | 0.9951 |
| RF Reg - sin PCA    | 26.3  | 64.6  | 0.9874 |
| Arbol Reg - sin PCA | 30.6  | 70.6  | 0.9849 |
| RF Reg - PCA 5      | 77.9  | 133.4 | 0.9463 |
| Lasso - PCA 5       | 82.7  | 142.6 | 0.9387 |
| Lineal - PCA 5      | 82.7  | 142.6 | 0.9387 |
| Ridge - PCA 5       | 82.6  | 142.6 | 0.9387 |
| Arbol Reg - PCA 5   | 130.3 | 223.2 | 0.8497 |




## Mejor regresión: Lasso sin PCA

RMSE = 35.55 y  $R^2 = 0.9962$ . El modelo lineal penalizado funcionó mejor que alternativas más complejas.

# PCA: reducción de dimensionalidad

Uso de 5 componentes principales



Componentes

**5**

Varianza acumulada

**84.94%**

## Por qué se usó

- Reduce redundancia en variables altamente correlacionadas.
- Permite probar modelos con menor dimensionalidad.
- Hace visible la separación de casos en componentes principales.
- No siempre mejora: depende del modelo y de la métrica.

# Modelo no supervisado: KMeans

Agrupamiento por centroides con  $k=2$

Silhouette

**0.3450**

Dunn


**0.0608**

k

**2**

## Interpretación

KMeans explora si la estructura natural de los datos se aproxima a dos grupos. El resultado es útil para explorar patrones, pero no reemplaza a los modelos supervisados porque no usa la etiqueta diagnosis durante el entrenamiento.




# Clustering jerárquico y DBSCAN

Comparación de agrupamiento por distancia y densidad

| Modelo         | Silhouette | Dunn   | Ruido |
|----------------|------------|--------|-------|
| DBSCAN         | 0.3900     | 0.3122 | 345   |
| KMeans k=2     | 0.3450     | 0.0608 | -     |
| Jerárquico k=2 | 0.3394     | 0.0724 | -     |

## Lectura comparativa

DBSCAN obtiene mayor Silhouette y Dunn, pero marca 345 observaciones como ruido. Por eso su métrica debe interpretarse con cuidado: mejora separación en los puntos agrupados, pero deja muchos casos fuera.




Jerárquico k=2 queda cerca de KMeans en Silhouette, con Dunn ligeramente mejor que KMeans.



# Comparación final de modelos de clasificación

Ordenado por Recall, luego F1-score y Accuracy

| Modelo             | Accuracy | Precision | Recall | F1-score |
|--------------------|----------|-----------|--------|----------|
| Log. - PCA 5       | 0.9737   | 0.9756    | 0.9524 | 0.9639   |
| SVM - sin PCA      | 0.9737   | 1.0000    | 0.9286 | 0.9630   |
| Log. - sin PCA     | 0.9649   | 0.9750    | 0.9286 | 0.9512   |
| SVM - PCA 5        | 0.9649   | 0.9750    | 0.9286 | 0.9512   |
| RF - sin PCA       | 0.9649   | 1.0000    | 0.9048 | 0.9500   |
| KNN - sin PCA      | 0.9561   | 0.9744    | 0.9048 | 0.9383   |
| RF - PCA 5         | 0.9561   | 0.9744    | 0.9048 | 0.9383   |
| KNN - PCA 5        | 0.9474   | 0.9737    | 0.8810 | 0.9250   |
| Arbol - PCA 5      | 0.9386   | 0.9487    | 0.8810 | 0.9136   |
| Naive B. - sin PCA | 0.9386   | 1.0000    | 0.8333 | 0.9091   |
| Arbol - sin PCA    | 0.9123   | 0.9444    | 0.8095 | 0.8718   |
| Naive B. - PCA 5   | 0.9035   | 0.9189    | 0.8095 | 0.8608   |



## Interpretación obligatoria

No necesariamente gana el modelo con mayor Accuracy. En este caso, Logística con PCA lidera Recall y F1-score, por eso es la opción más defendible para diagnóstico.

# Selección del mejor modelo

Justificación según métricas y contexto médico

Modelo recomendado

**Logística + PCA**

5 componentes

Recall

**0.9524**

prioritario

F1-score

**0.9639**

mejor balance

Accuracy


**0.9737**

empate alto

## Por qué este modelo

- Tiene el mayor Recall del notebook corregido: reduce falsos negativos en malignos.
- También logra el mayor F1-score, por lo que no sacrifica demasiado la precisión.
- PCA reduce dimensionalidad y aprovecha la correlación entre variables clínicas.
- Frente a SVM, es más simple de explicar y obtuvo una ligera ventaja en F1.

Logística - Con PCA (5)



### Alternativa fuerte: SVM sin PCA

Empata Accuracy y queda muy cerca en F1, pero no supera el Recall del modelo recomendado.

# Conclusiones y mejoras futuras

Cierre técnico de la defensa

## Conclusiones

- El flujo completo incluyó limpieza, EDA, preparación, modelos y evaluación.
- El EDA identificó variables relevantes, pero el foco final fue comparar desempeño.
- La preparación fue clave para modelos sensibles a escala y para PCA.
- El mejor modelo se eligió con métricas y contexto, no solo por Accuracy.
- Logística con PCA fue la mejor clasificación del notebook corregido.

## Mejoras futuras

- Aplicar validación cruzada para reducir dependencia de una partición train/test.
- Ajustar hiperparámetros con GridSearch o RandomizedSearch.
- Optimizar umbral de clasificación para maximizar Recall clínico.
- Analizar importancia de variables y explicar predicciones individuales.
- Evaluar con más datos clínicos antes de uso real.

**Cierre: en diagnóstico médico, el mejor modelo no es solo el que más acierta, sino el que reduce el error clínicamente más costoso.**