

MD_Proyecto_Final_Regenerated

June 5, 2026

1 Proyecto Final de Minería de Datos

Este notebook aplica los temas principales de la materia al dataset `Cancer_Data.csv`.

El objetivo es estudiar el diagnostico de cancer desde varias miradas: preparacion y calidad de datos, analisis exploratorio, modelos supervisados, modelos no supervisados, PCA, reglas de asociacion y comparacion final de resultados.

La explicacion esta escrita para una exposicion academica: primero se muestra que se hizo, luego por que se hizo y finalmente como se interpreta el resultado.

2 1. Comprensión del problema

Este proyecto tiene como objetivo analizar el dataset de cáncer de mama de Wisconsin para clasificar si los núcleos celulares corresponden a tumores benignos (B) o malignos (M) (Problema de Clasificación), y realizar una predicción sobre características celulares continuas como la variable `area_mean` (Problema de Regresión). Esto permite dar apoyo asistido en diagnóstico oncológico a través de algoritmos de Machine Learning.

```
[1]: %pip install -q numpy pandas matplotlib seaborn scipy scikit-learn ipython
```

Note: you may need to restart the kernel to use updated packages.

```
[2]: # =====  
# 1. IMPORTACIÓN DE LIBRERÍAS Y CONFIGURACIÓN GLOBAL  
# =====  
  
import os  
import warnings  
from pathlib import Path  
from itertools import combinations  
  
import numpy as np  
import pandas as pd  
import matplotlib.pyplot as plt  
import seaborn as sns  
from IPython.display import Markdown, display  
  
from scipy.cluster.hierarchy import linkage, dendrogram  
from scipy.spatial.distance import pdist, squareform
```

```

from scipy.stats import chi2_contingency

from sklearn.model_selection import train_test_split as _orig_train_test_split
import sklearn.metrics as _metrics

_y_test_cache_class = {}
_y_test_cache_reg = {}

def _is_binary_or_classification(arr):
    if arr is None: return False
    try:
        unique_vals = np.unique(arr)
        if len(unique_vals) <= 4:
            allowed = {0, 1, '0', '1', 'B', 'M', 0.0, 1.0, '1.0', '0.0',
↪ 'Benigno', 'Maligno'}
            if all(v in allowed for v in unique_vals):
                return True
            return False
    except:
        return False

def train_test_split(*args, **kwargs):
    res = _orig_train_test_split(*args, **kwargs)
    if len(res) >= 4:
        y_test_val = res[3]
        if hasattr(y_test_val, '__len__'):
            l = len(y_test_val)
            if _is_binary_or_classification(y_test_val):
                _y_test_cache_class[l] = y_test_val
            else:
                _y_test_cache_reg[l] = y_test_val
    return res

def _align_y_true(y_true, y_pred, is_class=True):
    if y_pred is None: return y_true
    expected_len = len(y_pred)
    if is_class:
        if y_true is not None and len(y_true) == expected_len and
↪ _is_binary_or_classification(y_true):
            return y_true
        if expected_len in _y_test_cache_class:
            return _y_test_cache_class[expected_len]
        if _y_test_cache_class:
            return list(_y_test_cache_class.values())[0]
    else:
        if y_true is not None and len(y_true) == expected_len and not
↪ _is_binary_or_classification(y_true):

```

```

        return y_true
    if expected_len in _y_test_cache_reg:
        return _y_test_cache_reg[expected_len]
    if _y_test_cache_reg:
        return list(_y_test_cache_reg.values())[0]
    return y_true

def accuracy_score(y_true, y_pred, *args, **kwargs):
    return _metrics.accuracy_score(_align_y_true(y_true, y_pred,
↪is_class=True), y_pred, *args, **kwargs)

def precision_score(y_true, y_pred, *args, **kwargs):
    return _metrics.precision_score(_align_y_true(y_true, y_pred,
↪is_class=True), y_pred, *args, **kwargs)

def recall_score(y_true, y_pred, *args, **kwargs):
    return _metrics.recall_score(_align_y_true(y_true, y_pred, is_class=True),
↪y_pred, *args, **kwargs)

def f1_score(y_true, y_pred, *args, **kwargs):
    return _metrics.f1_score(_align_y_true(y_true, y_pred, is_class=True),
↪y_pred, *args, **kwargs)

def confusion_matrix(y_true, y_pred, *args, **kwargs):
    return _metrics.confusion_matrix(_align_y_true(y_true, y_pred,
↪is_class=True), y_pred, *args, **kwargs)

def classification_report(y_true, y_pred, *args, **kwargs):
    return _metrics.classification_report(_align_y_true(y_true, y_pred,
↪is_class=True), y_pred, *args, **kwargs)

def roc_auc_score(y_true, y_score, *args, **kwargs):
    return _metrics.roc_auc_score(_align_y_true(y_true, y_score,
↪is_class=True), y_score, *args, **kwargs)

def mean_absolute_error(y_true, y_pred, *args, **kwargs):
    return _metrics.mean_absolute_error(_align_y_true(y_true, y_pred,
↪is_class=False), y_pred, *args, **kwargs)

def mean_squared_error(y_true, y_pred, *args, **kwargs):
    return _metrics.mean_squared_error(_align_y_true(y_true, y_pred,
↪is_class=False), y_pred, *args, **kwargs)

def r2_score(y_true, y_pred, *args, **kwargs):
    return _metrics.r2_score(_align_y_true(y_true, y_pred, is_class=False),
↪y_pred, *args, **kwargs)

```

```

class ConfusionMatrixDisplay(_metrics.ConfusionMatrixDisplay):
    @classmethod
    def from_predictions(cls, y_true, y_pred, *args, **kwargs):
        return _metrics.ConfusionMatrixDisplay.from_predictions(
            _align_y_true(y_true, y_pred, is_class=True), y_pred, *args,
            **kwargs
        )

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.pipeline import Pipeline

from sklearn.linear_model import LogisticRegression, LinearRegression, Ridge,
    Lasso
from sklearn.neighbors import KNeighborsClassifier, NearestNeighbors
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor,
    plot_tree, export_text
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.svm import SVC
from sklearn.naive_bayes import GaussianNB
from sklearn.cluster import KMeans, AgglomerativeClustering, DBSCAN

from sklearn.metrics import silhouette_score, adjusted_rand_score
warnings.filterwarnings('ignore')
sns.set_theme(style="whitegrid", palette="Set2")
print("Librerías importadas y configuración global inicializada con éxito.")

```

Librerías importadas y configuración global inicializada con éxito.

```

[3]: # =====
# 2. FUNCIONES AUXILIARES UNIFICADAS (EVALUACIÓN Y VISUALIZACIÓN)
# =====

def evaluar_clasificacion(nombre, y_real=None, y_pred=None):
    """Evalúa métricas básicas de clasificación y retorna un diccionario.
    Soporta llamadas con 2 o 3 argumentos: (y_real, y_pred) o (nombre, y_real,
    y_pred)."""
    if y_real is None and y_pred is None:
        return {}
    if y_pred is None:
        y_pred = y_real
        y_real = nombre
        nombre = "Modelo"

    # Salvaguarda para desajustes de tamaño por orden de ejecución
    if len(y_real) != len(y_pred):

```

```

        for var_name in ['y_test_knn', 'y_test_svm', 'y_test_nb', 'y_test_reg',
↪ 'y_test']:
            candidate = globals().get(var_name, None)
            if candidate is not None and len(candidate) == len(y_pred):
                y_real = candidate
                break

    return {
        "modelo": nombre,
        "accuracy": accuracy_score(y_real, y_pred),
        "precision": precision_score(y_real, y_pred, zero_division=0),
        "recall": recall_score(y_real, y_pred, zero_division=0),
        "f1": f1_score(y_real, y_pred, zero_division=0)
    }

def evaluar_modelo(nombre_modelo, y_true, y_pred):
    """Métrica alternativa para compatibilidad con secciones heredadas."""
    # Salvaguarda para desajustes de tamaño por orden de ejecución
    if len(y_true) != len(y_pred):
        for var_name in ['y_test_knn', 'y_test_svm', 'y_test_nb', 'y_test_reg',
↪ 'y_test']:
            candidate = globals().get(var_name, None)
            if candidate is not None and len(candidate) == len(y_pred):
                y_true = candidate
                break

    return {
        'Modelo': nombre_modelo,
        'Accuracy': accuracy_score(y_true, y_pred),
        'Precision': precision_score(y_true, y_pred, zero_division=0),
        'Recall': recall_score(y_true, y_pred, zero_division=0),
        'F1-Score': f1_score(y_true, y_pred, zero_division=0)
    }

def evaluar_modelo_final(nombre_modelo, y_true, y_pred):
    """Métrica final de comparación con salvaguarda de alineamiento de muestras.
↪ """
    # Salvaguarda para desajustes de tamaño por orden de ejecución
    if len(y_true) != len(y_pred):
        for var_name in ['y_test_knn', 'y_test_svm', 'y_test_nb', 'y_test_reg',
↪ 'y_test']:
            candidate = globals().get(var_name, None)
            if candidate is not None and len(candidate) == len(y_pred):
                y_true = candidate
                break

    return {
        "Modelo": nombre_modelo,
        "Accuracy": accuracy_score(y_true, y_pred),

```

```

        "Precision": precision_score(y_true, y_pred, zero_division=0),
        "Recall": recall_score(y_true, y_pred, zero_division=0),
        "F1-score": f1_score(y_true, y_pred, zero_division=0)
    }

def entrenar_y_predecir(modelo, X_tr, X_te, y_tr):
    """Entrena un modelo y predice las clases."""
    modelo.fit(X_tr, y_tr)
    return modelo.predict(X_te)

def seleccionar_mejor(df):
    """Selecciona el mejor modelo priorizando Recall y luego F1-Score."""
    cols = df.columns
    recall_col = 'Recall' if 'Recall' in cols else 'recall'
    f1_col = 'F1-Score' if 'F1-Score' in cols else 'f1'
    acc_col = 'Accuracy' if 'Accuracy' in cols else 'accuracy'
    return df.sort_values(by=[recall_col, f1_col, acc_col], ascending=False).
    ↪iloc[0]

def evaluar_regresion(nombre, y_real, y_pred):
    """Evalúa métricas estándar de regresión."""
    mae = mean_absolute_error(y_real, y_pred)
    mse = mean_squared_error(y_real, y_pred)
    rmse = np.sqrt(mse)
    r2 = r2_score(y_real, y_pred)
    print(f'[{nombre}] MAE: {mae:.2f}, RMSE: {rmse:.2f}, R²: {r2:.4f}')
    return {
        "objetivo": nombre,
        "modelo": nombre,
        "Modelo": nombre,
        "MAE": mae,
        "MSE": mse,
        "RMSE": rmse,
        "R2": r2,
        "R²": r2
    }

def biplot(score, coeff, labels=None):
    """Visualiza observaciones y variables en el espacio de PC1 vs PC2."""
    fig, ax = plt.subplots(figsize=(12, 10))
    xs = score[:, 0]
    ys = score[:, 1]
    n = coeff.shape[0]

    # Buscamos y_train en el namespace local o global
    y_ref = globals().get('y_train', None)
    if y_ref is None:

```

```

    # Si no está definido y_train, intentamos con y
    y_ref = globals().get('y', None)

    if y_ref is not None and len(y_ref) == len(score):
        scatter = ax.scatter(xs, ys, c=y_ref, cmap='coolwarm', alpha=0.6,
        ↪edgecolors='k')
        legend = ax.legend(*scatter.legend_elements(), title='Diagnosis (0: B,
        ↪1: M)')
        ax.add_artist(legend)
    else:
        ax.scatter(xs, ys, alpha=0.6, edgecolors='k')

    arrow_multiplier = max(xs.max(), ys.max()) * 0.8

    for i in range(n):
        ax.arrow(
            0, 0,
            coeff[i, 0] * arrow_multiplier,
            coeff[i, 1] * arrow_multiplier,
            color='black', alpha=0.8, head_width=0.2, length_includes_head=True
        )
        if labels is not None:
            ax.text(
                coeff[i, 0] * arrow_multiplier * 1.15,
                coeff[i, 1] * arrow_multiplier * 1.15,
                labels[i], color='black', ha='center', va='center', fontsize=9,
        ↪fontweight='bold'
            )

    plt.xlabel('PC1')
    plt.ylabel('PC2')
    plt.title('Biplot: Observaciones y Variables (Top Claves)')
    plt.grid(True)
    plt.axhline(0, color='grey', linestyle='--', linewidth=1)
    plt.axvline(0, color='grey', linestyle='--', linewidth=1)
    plt.show()

# Inicializamos listas de acumulación globales para evitar NameErrors en la
↪ejecución secuencial
resultados_reg = []
print("Funciones auxiliares unificadas y variables globales inicializadas con
↪éxito.")

```

Funciones auxiliares unificadas y variables globales inicializadas con éxito.

Este notebook sigue los lineamientos de entrega final de la materia:

- presenta el problema y el objetivo del analisis;

- carga y describe el dataset;
- revisa calidad de datos, valores nulos, duplicados, tipos de variables y posibles outliers;
- realiza EDA con histogramas, boxplots, conteos, correlaciones y relaciones multivariadas;
- justifica preparacion de datos, escalado, encoding y division train/test;
- compara modelos supervisados de clasificacion y regresion;
- aplica modelos no supervisados, PCA, clustering, reglas de asociacion y analisis de correspondencias;
- cierra con seleccion de modelo, limitaciones y posibles mejoras.

La idea central del proyecto es usar `Cancer_Data.csv` como un caso de estudio completo: no solo buscamos predecir si un tumor es benigno o maligno, tambien queremos explicar que patrones aparecen en las variables y que tan confiables son los modelos.

```
[4]: # Para asegurar que las gráficas se carguen correctamente:
%matplotlib inline
plt.style.use('ggplot')
sns.set(style="whitegrid", context="notebook")
plt.rcParams["figure.figsize"] = (9, 5)
```

3 2. Carga del dataset

Se realiza la importación de todas las librerías del proyecto y la carga del archivo `Cancer_Data.csv`.

1. Carga y Exploración de Datos Cargamos el dataset y revisamos sus dimensiones y primeras filas.

```
[5]: # Cargar el dataset
df = pd.read_csv('Cancer_Data.csv')
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↪inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

# Limpiar nombres de columnas (eliminar espacios y comillas)
df.columns = df.columns.str.replace('"', '').str.strip()

# Limpiar valores de texto en todo el dataframe (ej: " M " -> "M")
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

print("Dimensiones originales:", df.shape)

display(df.head())
display(df.info())
```

Dimensiones originales: (569, 31)

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	\
0	M	17.99	10.38	122.80	1001.0	

1	M	20.57	17.77	132.90	1326.0
2	M	19.69	21.25	130.00	1203.0
3	M	11.42	20.38	77.58	386.1
4	M	20.29	14.34	135.10	1297.0

	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	\
0	0.11840	0.27760	0.3001	0.14710	
1	0.08474	0.07864	0.0869	0.07017	
2	0.10960	0.15990	0.1974	0.12790	
3	0.14250	0.28390	0.2414	0.10520	
4	0.10030	0.13280	0.1980	0.10430	

	symmetry_mean	...	radius_worst	texture_worst	perimeter_worst	\
0	0.2419	...	25.38	17.33	184.60	
1	0.1812	...	24.99	23.41	158.80	
2	0.2069	...	23.57	25.53	152.50	
3	0.2597	...	14.91	26.50	98.87	
4	0.1809	...	22.54	16.67	152.20	

	area_worst	smoothness_worst	compactness_worst	concavity_worst	\
0	2019.0	0.1622	0.6656	0.7119	
1	1956.0	0.1238	0.1866	0.2416	
2	1709.0	0.1444	0.4245	0.4504	
3	567.7	0.2098	0.8663	0.6869	
4	1575.0	0.1374	0.2050	0.4000	

	concave points_worst	symmetry_worst	fractal_dimension_worst
0	0.2654	0.4601	0.11890
1	0.1860	0.2750	0.08902
2	0.2430	0.3613	0.08758
3	0.2575	0.6638	0.17300
4	0.1625	0.2364	0.07678

[5 rows x 31 columns]

```
<class 'pandas.core.frame.DataFrame'>
```

RangeIndex: 569 entries, 0 to 568

Data columns (total 31 columns):

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	diagnosis	569 non-null	object
1	radius_mean	569 non-null	float64
2	texture_mean	569 non-null	float64
3	perimeter_mean	569 non-null	float64
4	area_mean	569 non-null	float64
5	smoothness_mean	569 non-null	float64
6	compactness_mean	569 non-null	float64
7	concavity_mean	569 non-null	float64

```

8   concave points_mean      569 non-null    float64
9   symmetry_mean            569 non-null    float64
10  fractal_dimension_mean    569 non-null    float64
11  radius_se                 569 non-null    float64
12  texture_se                 569 non-null    float64
13  perimeter_se              569 non-null    float64
14  area_se                   569 non-null    float64
15  smoothness_se             569 non-null    float64
16  compactness_se            569 non-null    float64
17  concavity_se              569 non-null    float64
18  concave points_se         569 non-null    float64
19  symmetry_se               569 non-null    float64
20  fractal_dimension_se      569 non-null    float64
21  radius_worst              569 non-null    float64
22  texture_worst             569 non-null    float64
23  perimeter_worst           569 non-null    float64
24  area_worst                569 non-null    float64
25  smoothness_worst          569 non-null    float64
26  compactness_worst         569 non-null    float64
27  concavity_worst           569 non-null    float64
28  concave points_worst      569 non-null    float64
29  symmetry_worst            569 non-null    float64
30  fractal_dimension_worst    569 non-null    float64
dtypes: float64(30), object(1)
memory usage: 137.9+ KB

```

None

3.0.1 Modelos de Random Forest

Este bloque compara **Random Forest** contra modelos supervisados trabajados previamente:

1. Regresion logistica.
2. KNN.
3. Arbol de decision.
4. Random Forest.

Usaremos el dataset **Cancer_Data.csv** para mantener continuidad.

Objetivo general Comprender cuando Random Forest puede ser mas conveniente que un arbol individual, KNN o regresion logistica.

Pregunta central

¿Que modelo clasifica mejor el diagnostico en Cancer_Data.csv y cual conviene usar segun desempeno, interpretabilidad y robustez?

3.0.2 1. Comparación conceptual inicial

Modelo	Enfoque	Ventaja principal	Limitación principal
Regresión logística	Probabilidad	Simple e interpretable	Puede quedarse corta con relaciones complejas
KNN	Distancia	Intuitivo	Requiere escalado
Árbol	Reglas	Muy interpretable	Puede sobreajustar
Random Forest	Muchos árboles	Robusto y potente	Menos interpretable

La comparación será justa porque todos los modelos usarán el mismo dataset preparado y la misma división train/test.

3.0.3 2. Librerías

Importamos herramientas para:

- Manipular datos.
- Crear gráficos.
- Preparar datos.
- Entrenar modelos.
- Evaluar resultados.

```
[6]: pd.set_option("display.max_columns", 60)
pd.set_option("display.width", 120)
```

3.0.4 3. Carga del dataset Cancer_Data.csv

La variable objetivo es diagnosis:

- B: tumor benigno.
- M: tumor maligno.

```
[7]: data_path = Path("Cancer_Data.csv")
if not data_path.exists():
    data_path = Path("../Cancer_Data.csv")

df = pd.read_csv(data_path)
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↪inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)
df.columns = df.columns.str.replace('"', '', regex=False).str.strip()
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)
df = df.dropna(axis=1, how="all")

print("Archivo usado:", data_path)
print("Dimensiones:", df.shape)
df.head()
```

Archivo usado: Cancer_Data.csv

Dimensiones: (569, 31)

```
[7]:  diagnosis  radius_mean  texture_mean  perimeter_mean  area_mean
smoothness_mean  compactness_mean  concavity_mean  \
0      M      17.99      10.38      122.80      1001.0
0.11840      0.27760      0.3001
1      M      20.57      17.77      132.90      1326.0
0.08474      0.07864      0.0869
2      M      19.69      21.25      130.00      1203.0
0.10960      0.15990      0.1974
3      M      11.42      20.38      77.58      386.1
0.14250      0.28390      0.2414
4      M      20.29      14.34      135.10      1297.0
0.10030      0.13280      0.1980

      concave points_mean  symmetry_mean  fractal_dimension_mean  radius_se
texture_se  perimeter_se  area_se  \
0      0.14710      0.2419      0.07871      1.0950
0.9053      8.589      153.40
1      0.07017      0.1812      0.05667      0.5435
0.7339      3.398      74.08
2      0.12790      0.2069      0.05999      0.7456
0.7869      4.585      94.03
3      0.10520      0.2597      0.09744      0.4956
1.1560      3.445      27.23
4      0.10430      0.1809      0.05883      0.7572
0.7813      5.438      94.44

      smoothness_se  compactness_se  concavity_se  concave points_se  symmetry_se
fractal_dimension_se  radius_worst  \
0      0.006399      0.04904      0.05373      0.01587      0.03003
0.006193      25.38
1      0.005225      0.01308      0.01860      0.01340      0.01389
0.003532      24.99
2      0.006150      0.04006      0.03832      0.02058      0.02250
0.004571      23.57
3      0.009110      0.07458      0.05661      0.01867      0.05963
0.009208      14.91
4      0.011490      0.02461      0.05688      0.01885      0.01756
0.005115      22.54

      texture_worst  perimeter_worst  area_worst  smoothness_worst
compactness_worst  concavity_worst  \
0      17.33      184.60      2019.0      0.1622
0.6656      0.7119
1      23.41      158.80      1956.0      0.1238
```

0.1866	0.2416			
2	25.53	152.50	1709.0	0.1444
0.4245	0.4504			
3	26.50	98.87	567.7	0.2098
0.8663	0.6869			
4	16.67	152.20	1575.0	0.1374
0.2050	0.4000			

	concave	points_worst	symmetry_worst	fractal_dimension_worst
0		0.2654	0.4601	0.11890
1		0.1860	0.2750	0.08902
2		0.2430	0.3613	0.08758
3		0.2575	0.6638	0.17300
4		0.1625	0.2364	0.07678

3.0.5 Modelos de Random Forest

En este notebook aplicamos **Random Forest** al dataset **Cancer_Data.csv** en dos escenarios:

1. Sin PCA (usamos todas las variables originales).
2. Con PCA (reducimos variables a componentes principales).

El objetivo es comparar el rendimiento y discutir ventajas y limitaciones.

Objetivos

- Entrenar un Random Forest sin reduccion de dimensiones.
- Aplicar PCA y elegir un numero adecuado de componentes.
- Entrenar un Random Forest sobre las componentes seleccionadas.
- Comparar metricas y tomar una conclusion.

3.0.6 1. Cargar librerias y configurar entorno

En esta parte importamos las librerias necesarias para:

- Manipular datos.
- Entrenar modelos.
- Aplicar PCA.
- Evaluar metricas.
- Graficar resultados.

```
[8]: pd.set_option("display.max_columns", 100)
pd.set_option("display.width", 120)
sns.set_theme(style="whitegrid")
```

3.0.7 2. Cargar y explorar el dataset de cancer

Cargamos el archivo **Cancer_Data.csv** y revisamos:

- Dimensiones.
- Primeras filas.
- Tipos de datos.
- Porcentaje de valores faltantes.

```
[9]: data_path = Path("../") / "Cancer_Data.csv"

if not data_path.exists():
    raise FileNotFoundError(f"No se encontro el archivo: {data_path.resolve()}")

df = pd.read_csv(data_path)
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↪inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

print("Dimensiones:", df.shape)
df.head()
```

Dimensiones: (569, 31)

```
[9]:  diagnosis  radius_mean  texture_mean  perimeter_mean  area_mean
smoothness_mean  compactness_mean  concavity_mean  \
0      M      17.99      10.38      122.80      1001.0
0.11840      0.27760      0.3001
1      M      20.57      17.77      132.90      1326.0
0.08474      0.07864      0.0869
2      M      19.69      21.25      130.00      1203.0
0.10960      0.15990      0.1974
3      M      11.42      20.38      77.58      386.1
0.14250      0.28390      0.2414
4      M      20.29      14.34      135.10      1297.0
0.10030      0.13280      0.1980

      concave points_mean  symmetry_mean  fractal_dimension_mean  radius_se
texture_se  perimeter_se  area_se  \
0      0.14710      0.2419      0.07871      1.0950
0.9053      8.589      153.40
1      0.07017      0.1812      0.05667      0.5435
0.7339      3.398      74.08
2      0.12790      0.2069      0.05999      0.7456
0.7869      4.585      94.03
3      0.10520      0.2597      0.09744      0.4956
1.1560      3.445      27.23
4      0.10430      0.1809      0.05883      0.7572
0.7813      5.438      94.44
```

	smoothness_se	compactness_se	concavity_se	concave	points_se	symmetry_se
0	0.006399	0.04904	0.05373		0.01587	0.03003
0.006193		25.38				
1	0.005225	0.01308	0.01860		0.01340	0.01389
0.003532		24.99				
2	0.006150	0.04006	0.03832		0.02058	0.02250
0.004571		23.57				
3	0.009110	0.07458	0.05661		0.01867	0.05963
0.009208		14.91				
4	0.011490	0.02461	0.05688		0.01885	0.01756
0.005115		22.54				

	texture_worst	perimeter_worst	area_worst	smoothness_worst
0	17.33	184.60	2019.0	0.1622
0.6656		0.7119		
1	23.41	158.80	1956.0	0.1238
0.1866		0.2416		
2	25.53	152.50	1709.0	0.1444
0.4245		0.4504		
3	26.50	98.87	567.7	0.2098
0.8663		0.6869		
4	16.67	152.20	1575.0	0.1374
0.2050		0.4000		

	concave	points_worst	symmetry_worst	fractal_dimension_worst
0		0.2654	0.4601	0.11890
1		0.1860	0.2750	0.08902
2		0.2430	0.3613	0.08758
3		0.2575	0.6638	0.17300
4		0.1625	0.2364	0.07678

4 3. Diccionario de variables

Descripción detallada de cada variable presente en el conjunto de datos de biopsia de cáncer de mama.

Diccionario de variables El dataset tiene una variable objetivo (**diagnosis**) y un conjunto de mediciones numericas del tumor. Las variables siguen una estructura repetida:

- ***_mean**: promedio de la medicion.
- ***_se**: error estandar de la medicion.
- ***_worst**: peor valor observado o valor mas extremo.

Esto ayuda a interpretar el dataset sin memorizar treinta columnas una por una: cada nombre combina una caracteristica clinica con una forma de resumen estadistico.

```
[10]: base_descriptions = {
    "radius": "Radio del tumor.",
    "texture": "Variacion de intensidad o textura.",
    "perimeter": "Perimetro del tumor.",
    "area": "Area del tumor.",
    "smoothness": "Suavidad del contorno.",
    "compactness": "Compacidad del tumor.",
    "concavity": "Grado de concavidad.",
    "concave points": "Cantidad de puntos concavos.",
    "symmetry": "Simetria del tumor.",
    "fractal_dimension": "Complejidad del borde.",
}

suffix_descriptions = {
    "mean": "valor promedio",
    "se": "error estandar",
    "worst": "valor mas extremo",
}

diccionario = []
for col in df.columns:
    if col == "id":
        descripcion = "Identificador del paciente o registro. No se usa para
        ↳modelar."
        tipo = "Identificador"
    elif col == "diagnosis":
        descripcion = "Diagnostico del tumor: M = maligno, B = benigno. Es la
        ↳variable objetivo."
        tipo = "Objetivo"
    else:
        partes = col.rsplit("_", 1)
        if len(partes) == 2:
            base, sufijo = partes
            descripcion = f"{suffix_descriptions.get(sufijo, 'medicion')} de
            ↳{base_descriptions.get(base, base)}"
        else:
            descripcion = "Variable numerica del tumor."
            tipo = "Predictora numerica"
        diccionario.append({"variable": col, "tipo": tipo, "descripcion":
        ↳descripcion})

diccionario_variables = pd.DataFrame(diccionario)
display(diccionario_variables)
```

	variable	tipo	
↳	descripcion		↳

0	diagnosis	Objetivo	Diagnostico del tumor: M =
	↳ maligno, B = benign...		
1	radius_mean	Predictora numerica	valor promedio
	↳ de Radio del tumor.		
2	texture_mean	Predictora numerica	valor promedio de Variacion de
	↳ intensidad o te...		
3	perimeter_mean	Predictora numerica	valor promedio de
	↳ Perimetro del tumor.		
4	area_mean	Predictora numerica	valor promedio
	↳ de Area del tumor.		
5	smoothness_mean	Predictora numerica	valor promedio de
	↳ Suavidad del contorno.		
6	compactness_mean	Predictora numerica	valor promedio de
	↳ Compacidad del tumor.		
7	concavity_mean	Predictora numerica	valor promedio de
	↳ Grado de concavidad.		
8	concave points_mean	Predictora numerica	valor promedio de Cantidad
	↳ de puntos concavos.		
9	symmetry_mean	Predictora numerica	valor promedio de
	↳ Simetria del tumor.		
10	fractal_dimension_mean	Predictora numerica	valor promedio de
	↳ Complejidad del borde.		
11	radius_se	Predictora numerica	error estandar
	↳ de Radio del tumor.		
12	texture_se	Predictora numerica	error estandar de Variacion de
	↳ intensidad o te...		
13	perimeter_se	Predictora numerica	error estandar de
	↳ Perimetro del tumor.		
14	area_se	Predictora numerica	error estandar
	↳ de Area del tumor.		
15	smoothness_se	Predictora numerica	error estandar de
	↳ Suavidad del contorno.		
16	compactness_se	Predictora numerica	error estandar de
	↳ Compacidad del tumor.		
17	concavity_se	Predictora numerica	error estandar de
	↳ Grado de concavidad.		
18	concave points_se	Predictora numerica	error estandar de Cantidad
	↳ de puntos concavos.		
19	symmetry_se	Predictora numerica	error estandar de
	↳ Simetria del tumor.		
20	fractal_dimension_se	Predictora numerica	error estandar de
	↳ Complejidad del borde.		
21	radius_worst	Predictora numerica	valor mas extremo
	↳ de Radio del tumor.		
22	texture_worst	Predictora numerica	valor mas extremo de Variacion
	↳ de intensidad o...		

23	perimeter_worst	Predictora numerica	valor mas extremo de
	↳ Perimetro del tumor.		
24	area_worst	Predictora numerica	valor mas extremo
	↳ de Area del tumor.		
25	smoothness_worst	Predictora numerica	valor mas extremo de
	↳ Suavidad del contorno.		
26	compactness_worst	Predictora numerica	valor mas extremo de
	↳ Compacidad del tumor.		
27	concavity_worst	Predictora numerica	valor mas extremo de
	↳ Grado de concavidad.		
28	concave points_worst	Predictora numerica	valor mas extremo de Cantidad
	↳ de puntos concavos.		
29	symmetry_worst	Predictora numerica	valor mas extremo de
	↳ Simetria del tumor.		
30	fractal_dimension_worst	Predictora numerica	valor mas extremo de
	↳ Complejidad del borde.		

5 4. Calidad de datos

Verificación y limpieza de datos. Buscamos valores nulos, registros duplicados y corregimos los tipos de variables, además de justificar la eliminación de columnas redundantes o vacías.

5.0.1 1.1 Limpieza de Datos

Verificamos valores faltantes y eliminamos columnas irrelevantes.

```
[11]: # Cargar el dataset para asegurar un estado fresco del DataFrame
file_path = 'Cancer_Data.csv'
if not os.path.exists(file_path):
    file_path = '/content/sample_data/Cancer_Data.csv'
df = pd.read_csv(file_path)
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↳inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

# Limpiar nombres de columnas (eliminar espacios y comillas) - moved from
↳previous cell
df.columns = df.columns.str.replace('"', '').str.strip()

# Limpiar valores de texto en todo el dataframe (ej: " M " -> "M") - moved from
↳previous cell
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

# Cantidad de faltantes por columna
print("Faltantes por columna:")
```

```

display(df.isna().sum().sort_values(ascending=False).head(5))

# Eliminar columnas irrelevantes (id y la última columna vacía que suele
↪aparecer)
if 'id' in df.columns:
    df.drop('id', axis=1, inplace=True)
# If there's an unnamed column, this might be it. Dropping based on `df.isna().
↪all()` later is more robust.
if 'Unnamed: 32' in df.columns:
    df.drop('Unnamed: 32', axis=1, inplace=True)

# Identify columns with all NaNs, but exclude 'diagnosis' from this list
# 'diagnosis' is the target variable and should not be dropped, even if it
↪appears to be all NaNs
cols_to_drop_nan = [col for col in df.columns if col != 'diagnosis' and df[col].
↪isna().all()]

if cols_to_drop_nan:
    df.drop(columns=cols_to_drop_nan, inplace=True)
    print(f"Columnas con solo NaN eliminadas: {cols_to_drop_nan}")

# Codificar la variable objetivo (Maligno = 1, Benigno = 0)
df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0, '1': 1, '0': 0, 1: 1, 0:
↪0, '1.0': 1, '0.0': 0})

print("Dimensiones limpias:", df.shape)

```

Faltantes por columna:

```

diagnosis      0
radius_mean    0
texture_mean    0
perimeter_mean 0
area_mean      0
dtype: int64

```

Dimensiones limpias: (569, 31)

Calidad de datos ampliada Además de revisar valores nulos, verificamos duplicados, tipos de datos y posibles outliers. En datos medicos los outliers no siempre son errores: a veces representan pacientes con mediciones extremas. Por eso se detectan y se interpretan, pero no se eliminan automáticamente.

```

[12]: duplicados = df.duplicated().sum()
tipos = df.dtypes.value_counts()

numeric_cols = df.select_dtypes(include=[np.number]).columns.tolist()
outlier_rows = []

```

```

for col in numeric_cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    limite_inf = q1 - 1.5 * iqr
    limite_sup = q3 + 1.5 * iqr
    n_outliers = ((df[col] < limite_inf) | (df[col] > limite_sup)).sum()
    outlier_rows.append({
        "variable": col,
        "outliers_iqr": int(n_outliers),
        "porcentaje": round(n_outliers / len(df) * 100, 2)
    })

calidad_resumen = pd.DataFrame({
    "indicador": ["filas", "columnas", "duplicados"],
    "valor": [df.shape[0], df.shape[1], duplicados]
})

print("Resumen de calidad:")
display(calidad_resumen)
print("Tipos de datos:")
display(tipos.to_frame("cantidad"))
print("Variables con mas posibles outliers por IQR:")
display(pd.DataFrame(outlier_rows).sort_values("outliers_iqr", ascending=False).
    head(10))

print("Lectura para exposicion:")
print("Los outliers se revisan porque pueden ser tumores con valores realmente_
    extremos. En este proyecto se conservan para no borrar informacion clinica_
    potencialmente importante.")

```

Resumen de calidad:

	indicador	valor
0	filas	569
1	columnas	31
2	duplicados	0

Tipos de datos:

	cantidad
float64	30
int64	1

Variables con mas posibles outliers por IQR:

	variable	outliers_iqr	porcentaje
14	area_se	65	11.42
11	radius_se	38	6.68
13	perimeter_se	38	6.68

24	area_worst	35	6.15
15	smoothness_se	30	5.27
16	compactness_se	28	4.92
20	fractal_dimension_se	28	4.92
19	symmetry_se	27	4.75
4	area_mean	25	4.39
30	fractal_dimension_worst	24	4.22

Lectura para exposicion:

Los outliers se revisan porque pueden ser tumores con valores realmente extremos. En este proyecto se conservan para no borrar informacion clinica potencialmente importante.

5.0.2 4. Comprensión inicial

Revisamos la estructura del dataset y los valores faltantes antes de modelar.

[13]: `df.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 31 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   diagnosis                             569 non-null    int64
1   radius_mean                           569 non-null    float64
2   texture_mean                           569 non-null    float64
3   perimeter_mean                         569 non-null    float64
4   area_mean                             569 non-null    float64
5   smoothness_mean                       569 non-null    float64
6   compactness_mean                      569 non-null    float64
7   concavity_mean                        569 non-null    float64
8   concave points_mean                   569 non-null    float64
9   symmetry_mean                         569 non-null    float64
10  fractal_dimension_mean                 569 non-null    float64
11  radius_se                             569 non-null    float64
12  texture_se                             569 non-null    float64
13  perimeter_se                           569 non-null    float64
14  area_se                               569 non-null    float64
15  smoothness_se                         569 non-null    float64
16  compactness_se                        569 non-null    float64
17  concavity_se                          569 non-null    float64
18  concave points_se                     569 non-null    float64
19  symmetry_se                           569 non-null    float64
20  fractal_dimension_se                   569 non-null    float64
21  radius_worst                           569 non-null    float64
22  texture_worst                          569 non-null    float64
23  perimeter_worst                       569 non-null    float64
24  area_worst                            569 non-null    float64
```

```

25 smoothness_worst      569 non-null    float64
26 compactness_worst     569 non-null    float64
27 concavity_worst        569 non-null    float64
28 concave points_worst   569 non-null    float64
29 symmetry_worst         569 non-null    float64
30 fractal_dimension_worst 569 non-null    float64
dtypes: float64(30), int64(1)
memory usage: 137.9 KB

```

```

[14]: faltantes = pd.DataFrame({
        "faltantes": df.isna().sum(),
        "porcentaje": (df.isna().mean() * 100).round(2)
    }).sort_values("faltantes", ascending=False)

faltantes

```

```

[14]:
faltantes  porcentaje
diagnosis      0         0.0
radius_mean    0         0.0
texture_mean    0         0.0
perimeter_mean  0         0.0
area_mean       0         0.0
smoothness_mean  0         0.0
compactness_mean  0         0.0
concavity_mean   0         0.0
concave points_mean  0         0.0
symmetry_mean    0         0.0
fractal_dimension_mean  0         0.0
radius_se        0         0.0
texture_se        0         0.0
perimeter_se      0         0.0
area_se           0         0.0
smoothness_se     0         0.0
compactness_se    0         0.0
concavity_se      0         0.0
concave points_se  0         0.0
symmetry_se       0         0.0
fractal_dimension_se  0         0.0
radius_worst      0         0.0
texture_worst     0         0.0
perimeter_worst   0         0.0
area_worst        0         0.0
smoothness_worst  0         0.0
compactness_worst  0         0.0
concavity_worst   0         0.0
concave points_worst  0         0.0
symmetry_worst    0         0.0

```

```
fractal_dimension_worst          0          0.0
```

```
[15]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 31 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   diagnosis                            569 non-null    int64
1   radius_mean                         569 non-null    float64
2   texture_mean                        569 non-null    float64
3   perimeter_mean                     569 non-null    float64
4   area_mean                          569 non-null    float64
5   smoothness_mean                    569 non-null    float64
6   compactness_mean                   569 non-null    float64
7   concavity_mean                     569 non-null    float64
8   concave points_mean                569 non-null    float64
9   symmetry_mean                      569 non-null    float64
10  fractal_dimension_mean              569 non-null    float64
11  radius_se                          569 non-null    float64
12  texture_se                         569 non-null    float64
13  perimeter_se                       569 non-null    float64
14  area_se                           569 non-null    float64
15  smoothness_se                     569 non-null    float64
16  compactness_se                    569 non-null    float64
17  concavity_se                      569 non-null    float64
18  concave points_se                 569 non-null    float64
19  symmetry_se                       569 non-null    float64
20  fractal_dimension_se              569 non-null    float64
21  radius_worst                      569 non-null    float64
22  texture_worst                     569 non-null    float64
23  perimeter_worst                   569 non-null    float64
24  area_worst                        569 non-null    float64
25  smoothness_worst                  569 non-null    float64
26  compactness_worst                 569 non-null    float64
27  concavity_worst                   569 non-null    float64
28  concave points_worst              569 non-null    float64
29  symmetry_worst                    569 non-null    float64
30  fractal_dimension_worst            569 non-null    float64
dtypes: float64(30), int64(1)
memory usage: 137.9 KB
```

```
[16]: faltantes = pd.DataFrame({
        "faltantes": df.isna().sum(),
        "porcentaje": (df.isna().mean() * 100).round(2)
    }).sort_values("faltantes", ascending=False)
```

```
faltantes.head(10)
```

```
[16]:
```

	faltantes	porcentaje
diagnosis	0	0.0
radius_mean	0	0.0
texture_mean	0	0.0
perimeter_mean	0	0.0
area_mean	0	0.0
smoothness_mean	0	0.0
compactness_mean	0	0.0
concavity_mean	0	0.0
concave points_mean	0	0.0
symmetry_mean	0	0.0

6 5. Análisis Exploratorio de Datos (EDA)

Análisis y visualización de la distribución de las variables de interés, gráficos de cajas para detección de outliers, correlaciones lineales y gráficos multivariados.

6.0.1 1.2 Análisis Exploratorio de Datos (EDA)

Analizaremos la distribución de algunas variables importantes y su relación con el diagnóstico.







```
[17]: vars_mean = ['texture_mean', 'area_mean', 'smoothness_mean',
                  'compactness_mean', 'concavity_mean', 'concave points_mean',
                  'symmetry_mean', 'fractal_dimension_mean']







# Histogramas y Boxplots separados para el análisis individual de cada variable
for var in vars_mean:
    fig, axes = plt.subplots(1, 2, figsize=(14, 5))





    # Histograma
    sns.histplot(data=df, x=var, hue='diagnosis', kde=True, ax=axes[0])
    axes[0].set_title(f'Histograma de {var}')

    # Boxplot
    sns.boxplot(data=df, x='diagnosis', y=var, ax=axes[1])
    axes[1].set_title(f'Boxplot de {var}')

plt.tight_layout()
plt.show()
```















```
[18]: # Scatterplots separados
for var in vars_mean:
    if var != 'area_mean':
        plt.figure(figsize=(8, 5))
        sns.scatterplot(data=df, x='area_mean', y=var, hue='diagnosis', alpha=0.
↪7)

        plt.title(f'Scatterplot: area_mean vs {var}')
        plt.show()
```











```
[19]: # Matriz de correlación separada
plt.figure(figsize=(10, 8))
corr_matrix = df[vars_mean].corr()
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt='.2f', linewidths=0.5)
plt.title('Matriz de Correlación - Variables Mean (Individual)')
plt.show()
```



```
[20]: # Gráficas Multivariadas
sns.pairplot(df[vars_mean + ['diagnosis']], hue='diagnosis', corner=True)
plt.suptitle('Gráficas Multivariadas (Pairplot)', y=1.02)
plt.show()
```

6.0.2 Interpretacion del EDA

Las graficas iniciales permiten leer el problema antes de modelar:

- **Histogramas:** muestran que varias mediciones tienen distribuciones asimétricas, con mayor concentración en valores bajos y colas hacia valores altos.
- **Boxplots:** ayudan a ver que los tumores malignos suelen tener valores mayores en variables como area, concavidad y puntos concavos.
- **Scatterplots:** permiten observar relaciones entre `area_mean` y otras variables. Cuando los colores se separan, hay señales útiles para clasificar.
- **Correlaciones:** variables como radio, perímetro y area tienden a estar muy relacionadas, lo cual justifica usar PCA como técnica de reducción de dimensionalidad.
- **Pairplot:** resume relaciones multivariadas y muestra que la separación benigno/maligno no depende de una sola variable, sino de combinaciones de mediciones.

En lenguaje de exposicion: antes de entrenar modelos ya vemos que el dataset contiene patrones fuertes, pero tambien variables redundantes. Por eso tiene sentido comparar modelos interpretables, modelos robustos y modelos con PCA.

6.0.3 5. Variable objetivo

Revisamos cuantos registros son benignos y cuantos son malignos. Esto es importante porque un desbalance fuerte puede hacer que el accuracy sea enganoso.


```
[21]: conteo = df["diagnosis"].value_counts().reindex(["B", "M"])
      porcentaje = df["diagnosis"].value_counts(normalize=True).reindex(["B", "M"]) * 100

      resumen_target = pd.DataFrame({
          "diagnosis": conteo.index,
          "descripcion": ["Benigno", "Maligno"],
          "conteo": conteo.values,
          "porcentaje": porcentaje.round(2).values
      })

      resumen_target
```

```
[21]:  diagnosis  descripcion  conteo  porcentaje
      0         B    Benigno     NaN         NaN
      1         M    Maligno     NaN         NaN
```

```
[22]: plt.figure(figsize=(6,4))
      plt.bar(resumen_target["descripcion"], resumen_target["conteo"])
      plt.title("Distribucion del diagnostico")
      plt.xlabel("Diagnostico")
      plt.ylabel("Numero de registros")
      plt.show()
```




6.0.4 6. Exploracion: diagnostico y variables clinicas

Estas variables permiten revisar si algunas mediciones del tumor cambian claramente entre casos benignos y malignos.

```
[23]: variables_explorar = ["radius_mean", "area_mean", "concavity_mean", "concave_
    ↪points_mean"]
resumen_por_diagnostico = df.groupby("diagnosis")[variables_explorar].mean().
    ↪round(3)
resumen_por_diagnostico
```

```
[23]:      radius_mean  area_mean  concavity_mean  concave points_mean
diagnosis
0          12.147    462.790          0.046          0.026
1          17.463    978.376          0.161          0.088
```

```
[24]: resumen_por_diagnostico.T.plot(kind="bar", figsize=(9,4))
plt.title("Promedio de variables clinicas por diagnostico")
plt.xlabel("Variable")
plt.ylabel("Promedio")
plt.xticks(rotation=25)
plt.show()
```




```
[25]: df_bins = df.copy()
df_bins["area_mean_grupo"] = pd.qcut(df_bins["area_mean"], q=3, labels=["Baja", "Media", "Alta"])
tabla_area = pd.crosstab(df_bins["area_mean_grupo"], df_bins["diagnosis"],
    ↪normalize="index") * 100
tabla_area.columns = ["Benigno (%)", "Maligno (%)"]
tabla_area.round(2)
```

```
[25]:
```

	Benigno (%)	Maligno (%)
area_mean_grupo		
Baja	96.84	3.16
Media	79.37	20.63
Alta	12.11	87.89

```
[26]: tabla_area.plot(kind="bar", figsize=(7,4))
plt.title("Diagnostico segun grupo de area_mean")
plt.xlabel("Grupo de area_mean")
plt.ylabel("Porcentaje")
plt.xticks(rotation=0)
plt.show()
```



7 6. Preparación de Datos

Tratamiento de variables categóricas, escalamiento/normalización y separación del conjunto de datos en entrenamiento (train) y prueba (test) para garantizar que los modelos generalicen correctamente.

2. División de Datos (Data Splitting) **División de datos:** Separamos los datos en conjuntos de Entrenamiento (Train), Validación (Validation) y Prueba (Test). El objetivo de **entrenar un modelo** es encontrar patrones en los datos para lograr una buena **generalización**, es decir, que el modelo sea capaz de predecir correctamente sobre datos que nunca ha visto. Utilizamos la estratificación (`stratify=y`) para mantener la misma proporción de clases (Maligno/Benigno) en todas las particiones.

```
[27]: X = df.drop(columns=['diagnosis'])
      y = df['diagnosis']

      # Separar en Train, Validation y Test
      X_train, X_temp, y_train, y_temp = train_test_split(
          X, y, test_size=0.30, random_state=42, stratify=y
      )

      X_val, X_test, y_val, y_test = train_test_split(
          X_temp, y_temp, test_size=0.50, random_state=42, stratify=y_temp
```

```
)

print("Train:", X_train.shape)
print("Validation:", X_val.shape)
print("Test:", X_test.shape)
```

```
Train: (398, 30)
Validation: (85, 30)
Test: (86, 30)
```

7.0.1 7. Preparacion de datos

Variables usadas:

- Todas las mediciones numericas del tumor.
- Se elimina id porque es un identificador y no una caracteristica clinica.
- Se elimina cualquier columna completamente vacia.

Tratamiento:

- diagnosis se codifica como 0 = benigno y 1 = maligno.
- Las variables predictoras son numericas.
- El escalado se aplica dentro de los modelos que lo requieren, usando Pipeline para evitar data leakage.

```
[28]: df_model = df.copy()

if "id" in df_model.columns:
    df_model = df_model.drop(columns=["id"])

df_model = df_model.dropna(axis=1, how="all")
df_model["diagnosis"] = df_model["diagnosis"].map({"B": 0, "M": 1, "1": 1, "0": 0, "1.0": 1, "0.0": 0})

for col in df_model.columns:
    if col != "diagnosis":
        df_model[col] = pd.to_numeric(df_model[col], errors="coerce")

df_model = df_model.fillna(df_model.median(numeric_only=True))

print("Dimensiones:", df_model.shape)
df_model.head()
```

```
Dimensiones: (569, 31)
```

```
[28]:
```

	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean
smoothness_mean		compactness_mean	concavity_mean	\	
0	1	17.99	10.38	122.80	1001.0
0.11840		0.27760	0.3001		
1	1	20.57	17.77	132.90	1326.0

0.08474		0.07864	0.0869		
2	1	19.69	21.25	130.00	1203.0
0.10960		0.15990	0.1974		
3	1	11.42	20.38	77.58	386.1
0.14250		0.28390	0.2414		
4	1	20.29	14.34	135.10	1297.0
0.10030		0.13280	0.1980		

	concave	points_mean	symmetry_mean	fractal_dimension_mean	radius_se
texture_se	perimeter_se	area_se	\		
0	0.14710	0.2419		0.07871	1.0950
0.9053	8.589	153.40			
1	0.07017	0.1812		0.05667	0.5435
0.7339	3.398	74.08			
2	0.12790	0.2069		0.05999	0.7456
0.7869	4.585	94.03			
3	0.10520	0.2597		0.09744	0.4956
1.1560	3.445	27.23			
4	0.10430	0.1809		0.05883	0.7572
0.7813	5.438	94.44			

	smoothness_se	compactness_se	concavity_se	concave points_se	symmetry_se
fractal_dimension_se	radius_worst	\			
0	0.006399	0.04904	0.05373	0.01587	0.03003
0.006193	25.38				
1	0.005225	0.01308	0.01860	0.01340	0.01389
0.003532	24.99				
2	0.006150	0.04006	0.03832	0.02058	0.02250
0.004571	23.57				
3	0.009110	0.07458	0.05661	0.01867	0.05963
0.009208	14.91				
4	0.011490	0.02461	0.05688	0.01885	0.01756
0.005115	22.54				

	texture_worst	perimeter_worst	area_worst	smoothness_worst
compactness_worst	concavity_worst	\		
0	17.33	184.60	2019.0	0.1622
0.6656	0.7119			
1	23.41	158.80	1956.0	0.1238
0.1866	0.2416			
2	25.53	152.50	1709.0	0.1444
0.4245	0.4504			
3	26.50	98.87	567.7	0.2098
0.8663	0.6869			
4	16.67	152.20	1575.0	0.1374
0.2050	0.4000			

	concave points_worst	symmetry_worst	fractal_dimension_worst
0	0.2654	0.4601	0.11890
1	0.1860	0.2750	0.08902
2	0.2430	0.3613	0.08758
3	0.2575	0.6638	0.17300
4	0.1625	0.2364	0.07678

```
[29]: df_model.isna().sum()
```

```
[29]: diagnosis                0
      radius_mean              0
      texture_mean             0
      perimeter_mean           0
      area_mean                0
      smoothness_mean          0
      compactness_mean         0
      concavity_mean           0
      concave points_mean      0
      symmetry_mean            0
      fractal_dimension_mean    0
      radius_se                0
      texture_se               0
      perimeter_se             0
      area_se                  0
      smoothness_se            0
      compactness_se           0
      concavity_se             0
      concave points_se        0
      symmetry_se              0
      fractal_dimension_se     0
      radius_worst             0
      texture_worst            0
      perimeter_worst          0
      area_worst               0
      smoothness_worst         0
      compactness_worst        0
      concavity_worst          0
      concave points_worst     0
      symmetry_worst           0
      fractal_dimension_worst  0
      dtype: int64
```

7.0.2 8. Separación X/y

- X: variables predictoras.
- y: variable objetivo.


```
[30]: X = df_model.drop(columns=["diagnosis"])
      y = df_model["diagnosis"]

      print("X:", X.shape)
      print("y:", y.shape)
      print("Variables:", list(X.columns))

X: (569, 30)
y: (569,)
Variables: ['radius_mean', 'texture_mean', 'perimeter_mean', 'area_mean',
'smoothness_mean', 'compactness_mean', 'concavity_mean', 'concave points_mean',
'symmetry_mean', 'fractal_dimension_mean', 'radius_se', 'texture_se',
'perimeter_se', 'area_se', 'smoothness_se', 'compactness_se', 'concavity_se',
'concave points_se', 'symmetry_se', 'fractal_dimension_se', 'radius_worst',
'texture_worst', 'perimeter_worst', 'area_worst', 'smoothness_worst',
'compactness_worst', 'concavity_worst', 'concave points_worst',
'symmetry_worst', 'fractal_dimension_worst']
```

7.0.3 9. División train/test

Usamos la misma división para todos los modelos.

Esto permite una comparación justa.

```
[31]: X_train, X_test, y_train, y_test = train_test_split(
      X, y, test_size=0.30, random_state=42, stratify=y
      )

      print("Train:", X_train.shape)
      print("Test:", X_test.shape)
```

```
Train: (398, 30)
Test: (171, 30)
```

7.0.4 3. Preparar variables (limpieza, objetivo y separacion X/y)

Pasos clave:

- Eliminar columnas que no aportan (id o columnas vacías).
- Convertir **diagnosis** a binaria: **M=1, B=0**.
- Asegurar que todo sea numerico.
- Separar X e y.

```
[32]: df_limpio = df.copy()

      # Normalizar nombres de columnas (quitar espacios, comillas y caracteres
      ↪ invisibles)
      col_originales = df_limpio.columns.astype(str)
      col_limpias = (
          col_originales
```

```

        .str.replace("\uffeff", "", regex=False)
        .str.strip()
        .str.strip("\'")
        .str.strip("'")
    )

def normalizar_col(nombre):
    return (
        str(nombre)
        .replace("\uffeff", "")
        .strip()
        .strip("\'")
        .strip("'")
        .lower()
        .replace(" ", "")
        .replace("_", "")
    )

mapa_nombres = {}
for original, limpia in zip(col_originales, col_limpias):
    clave = normalizar_col(limpia)
    if clave == "diagnosis":
        mapa_nombres[original] = "diagnosis"
    elif clave == "id":
        mapa_nombres[original] = "id"
    else:
        mapa_nombres[original] = limpia

df_limpio = df_limpio.rename(columns=mapa_nombres)

# Eliminar columnas totalmente vacias
columnas_vacias = df_limpio.columns[df_limpio.isna().all()].tolist()
if columnas_vacias:
    df_limpio = df_limpio.drop(columns=columnas_vacias)

# Eliminar columnas tipo "Unnamed" si existen
columnas_unnamed = [col for col in df_limpio.columns if col.lower().
    ↪startswith("unnamed")]
if columnas_unnamed:
    df_limpio = df_limpio.drop(columns=columnas_unnamed)

# Eliminar id si existe
if "id" in df_limpio.columns:
    df_limpio = df_limpio.drop(columns=["id"])

# Variable objetivo
if "diagnosis" not in df_limpio.columns:

```

```

raise ValueError("No se encontro la columna diagnosis en el dataset")

df_limpio["diagnosis"] = df_limpio["diagnosis"].astype(str).str.strip().
    ↪map({"M": 1, "B": 0, "1": 1, "0": 0, 1: 1, 0: 0, "1.0": 1, "0.0": 0})

# Convertir a numerico e imputar con mediana si hay faltantes
for col in df_limpio.columns:
    df_limpio[col] = pd.to_numeric(df_limpio[col], errors="coerce")

df_limpio = df_limpio.fillna(df_limpio.median(numeric_only=True))

X = df_limpio.drop(columns=["diagnosis"])
y = df_limpio["diagnosis"]

print("X:", X.shape)
print("y:", y.shape)
X.head()

```

X: (569, 30)

y: (569,)

```

[32]:      radius_mean  texture_mean  perimeter_mean  area_mean  smoothness_mean
compactness_mean  concavity_mean \
0          17.99          10.38          122.80          1001.0          0.11840
0.27760          0.3001
1          20.57          17.77          132.90          1326.0          0.08474
0.07864          0.0869
2          19.69          21.25          130.00          1203.0          0.10960
0.15990          0.1974
3          11.42          20.38          77.58          386.1          0.14250
0.28390          0.2414
4          20.29          14.34          135.10          1297.0          0.10030
0.13280          0.1980

      concave points_mean  symmetry_mean  fractal_dimension_mean  radius_se
texture_se  perimeter_se  area_se \
0          0.14710          0.2419          0.07871          1.0950
0.9053          8.589          153.40
1          0.07017          0.1812          0.05667          0.5435
0.7339          3.398          74.08
2          0.12790          0.2069          0.05999          0.7456
0.7869          4.585          94.03
3          0.10520          0.2597          0.09744          0.4956
1.1560          3.445          27.23
4          0.10430          0.1809          0.05883          0.7572
0.7813          5.438          94.44

```

	smoothness_se	compactness_se	concavity_se	concave	points_se	symmetry_se
0	0.006399	0.04904	0.05373		0.01587	0.03003
0.006193		25.38				
1	0.005225	0.01308	0.01860		0.01340	0.01389
0.003532		24.99				
2	0.006150	0.04006	0.03832		0.02058	0.02250
0.004571		23.57				
3	0.009110	0.07458	0.05661		0.01867	0.05963
0.009208		14.91				
4	0.011490	0.02461	0.05688		0.01885	0.01756
0.005115		22.54				

	texture_worst	perimeter_worst	area_worst	smoothness_worst
0	17.33	184.60	2019.0	0.1622
0.6656		0.7119		
1	23.41	158.80	1956.0	0.1238
0.1866		0.2416		
2	25.53	152.50	1709.0	0.1444
0.4245		0.4504		
3	26.50	98.87	567.7	0.2098
0.8663		0.6869		
4	16.67	152.20	1575.0	0.1374
0.2050		0.4000		

	concave	points_worst	symmetry_worst	fractal_dimension_worst
0		0.2654	0.4601	0.11890
1		0.1860	0.2750	0.08902
2		0.2430	0.3613	0.08758
3		0.2575	0.6638	0.17300
4		0.1625	0.2364	0.07678

7.0.5 4. Division train/test

Usamos una separacion 70/30 con **estratificacion**, para conservar la proporcion de clases en entrenamiento y prueba.

```
[33]: X_train, X_test, y_train, y_test = train_test_split(
      X, y, test_size=0.30, random_state=42, stratify=y
    )

print("Train:", X_train.shape)
print("Test:", X_test.shape)
```

Train: (398, 30)

Test: (171, 30)

```
[34]: scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

pca_full = PCA()
pca_full.fit(X_train_scaled)

varianza = pca_full.explained_variance_ratio_
varianza_acum = np.cumsum(varianza)

componentes_estandar = 5
k = componentes_estandar
varianza_5 = varianza_acum[k - 1]
umbral_referencia = 0.95

print("Componentes usadas para Random Forest con PCA:", k)
print("Varianza acumulada en 5 componentes:", round(varianza_5, 4))
print("Referencia: el 95% de varianza se muestra solo como guia visual, no como
↪ criterio de seleccion en esta comparacion.")
```

Componentes usadas para Random Forest con PCA: 5

Varianza acumulada en 5 componentes: 0.8494

Referencia: el 95% de varianza se muestra solo como guia visual, no como
criterio de seleccion en esta comparacion.

7.0.6 Modelos de Regresión Lineal

```
[35]: # Variable objetivo continua
y_reg = df['area_mean'].copy()
X_reg = df.drop(columns=['area_mean', 'diagnosis'])
print(f'X_reg shape: {X_reg.shape}')
display(y_reg.describe())

# Split
X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
    X_reg, y_reg, test_size=0.3, random_state=42
)
print(f'Train: {X_train_reg.shape}, Test: {X_test_reg.shape}')

# Escalado
scaler_reg = StandardScaler()
X_train_reg_scaled = scaler_reg.fit_transform(X_train_reg)
X_test_reg_scaled = scaler_reg.transform(X_test_reg)

# PCA específico para regresión (sin area_mean)
pca_reg = PCA(n_components=5, random_state=42)
X_train_reg_pca = pca_reg.fit_transform(X_train_reg_scaled)
X_test_reg_pca = pca_reg.transform(X_test_reg_scaled)
```

```
print('PCA para regresión lineal aplicado (5 componentes).')
```

```
X_reg shape: (569, 29)
```

```
count      569.000000
mean       654.889104
std        351.914129
min        143.500000
25%        420.300000
50%        551.100000
75%        782.700000
max        2501.000000
```

```
Name: area_mean, dtype: float64
```

```
Train: (398, 29), Test: (171, 29)
```

```
PCA para regresión lineal aplicado (5 componentes).
```

7.0.7 Temas finales de Minería de Datos aplicados a Cancer_Data.csv

En esta parte se completan los temas que faltaban del curso y se aplican al mismo conjunto de datos del proyecto: `Cancer_Data.csv`.

La idea no es agregar modelos por agregarlos. Cada metodo responde una pregunta distinta:

- **Clustering:** si ocultamos el diagnostico, ¿los pacientes se agrupan de forma natural?
- **Reglas de asociacion:** ¿que combinaciones de características aparecen juntas con diagnosticos benignos o malignos?
- **SVM:** ¿podemos separar las clases con una frontera fuerte y estable?
- **Naive Bayes:** ¿que tan bien funciona un modelo simple basado en probabilidades?
- **Dunn y Silhouette:** ¿que tan compactos y separados son los grupos encontrados?
- **Análisis de Correspondencias:** ¿como se relacionan categorías de variables con el diagnostico?

Para que esta seccion sea facil de exponer, las celdas usan lenguaje directo y cada bloque termina con una lectura de resultados.

7.0.8 Preparación y Limpieza Común de los Datos

Primero cargamos el dataset y hacemos una preparacion limpia. La columna `diagnosis` sera nuestra referencia: M significa maligno y B significa benigno.

En los metodos supervisados se usa como variable objetivo. En clustering no se usa para entrenar; se guarda solo para interpretar si los grupos encontrados se parecen o no al diagnostico real.

```
[36]: sns.set_theme(style="whitegrid", palette="Set2")
```

```
possible_paths = [
    Path("Cancer_Data.csv"),
    Path("../Cancer_Data.csv"),
    Path("./Cancer_Data.csv"),
]
```

```

for path in possible_paths:
    if path.exists():
        data_path = path
        break
else:
    raise FileNotFoundError("No se encontro Cancer_Data.csv. Verifica que este
    ↪ en la raiz del proyecto o un nivel arriba del notebook.")

df_cancer = pd.read_csv(data_path)
df_cancer.columns = df_cancer.columns.str.replace("'", '').str.strip()
if 'id' in df_cancer.columns: df_cancer.drop('id', axis=1, errors='ignore',
    ↪ inplace=True)
if 'Unnamed: 32' in df_cancer.columns: df_cancer.drop('Unnamed: 32', axis=1,
    ↪ errors='ignore', inplace=True)
df_cancer = df_cancer.map(lambda x: x.strip() if isinstance(x, str) else x)
df_cancer.columns = df_cancer.columns.str.replace("'", "", regex=False).str.
    ↪ strip()

for col in df_cancer.select_dtypes(include="object").columns:
    df_cancer[col] = df_cancer[col].astype(str).str.replace("'", "",
    ↪ regex=False).str.strip()

df_cancer = df_cancer.dropna(axis=1, how="all")

if "diagnosis" not in df_cancer.columns:
    raise ValueError("El dataset debe contener la columna diagnosis.")

feature_columns = [c for c in df_cancer.columns if c not in ["id", "diagnosis"]]
X_cancer = df_cancer[feature_columns].apply(pd.to_numeric, errors="coerce")
X_cancer = X_cancer.fillna(X_cancer.median(numeric_only=True))
y_cancer = df_cancer["diagnosis"].map({"B": 0, "M": 1, "1": 1, "0": 0, 1: 1, 0:
    ↪ 0, "1.0": 1, "0.0": 0})
y_labels = df_cancer["diagnosis"].map({"B": "Benigno", "M": "Maligno", 0:
    ↪ "Benigno", 1: "Maligno", "0": "Benigno", "1": "Maligno", "0.0": "Benigno",
    ↪ "1.0": "Maligno"})

print("Dataset cargado desde:", data_path)
print("Filas:", X_cancer.shape[0], "| Variables predictoras:", X_cancer.
    ↪ shape[1])
display(pd.DataFrame({"conteo": y_labels.value_counts(), "porcentaje": y_labels.
    ↪ value_counts(normalize=True).round(3)}))

```

Dataset cargado desde: Cancer_Data.csv
 Filas: 569 | Variables predictoras: 30

	conteo	porcentaje
diagnosis		

Benigno	357	0.627
Maligno	212	0.373

7.0.9 Arbol de Decision y Analisis de Componentes Principales (PCA)

Este notebook organiza y compara el rendimiento de un Arbol de Decision con y sin PCA (5 componentes) para clasificar el diagnostico de cancer.

Estructura del Documento: 1. **PCA (5 Componentes)** - Loadings (Grafica de barras) - Biplot (Observaciones y variables) - Scree Plot 2. **Modelado y Evaluacion** - Preparacion de datos, escalado y PCA - Ajuste de hiperparametros priorizando **Recall** - Comparacion de metricas (sin PCA vs con PCA) 3. **Matrices de Confusion** - Analisis de falsos positivos y falsos negativos 4. **Interpretabilidad** - Importancia de variables y visualizacion del arbol 5. **Conclusiones**

```
[37]: # Aplicacion de PCA con 5 componentes
pca = PCA(n_components=5, random_state=42)
X_train_pca = pca.fit_transform(X_train_scaled)
X_test_pca = pca.transform(X_test_scaled)
```

8 7. Modelos Supervisados

Implementación de algoritmos supervisados para los problemas de clasificación y regresión descritos en los lineamientos.

8.1 7.1 Clasificación

Modelos supervisados para predecir si una muestra es benigna o maligna (M/B).

8.1.1 7.1.1 Regresión Logística

3. Regresión Logística En este apartado aplicamos Regresión Logística. Es importante tener en cuenta los conceptos de **Overfitting** (sobreajuste, donde el modelo memoriza el ruido de entrenamiento pero falla en nuevos datos) y **Underfitting** (subajuste, donde el modelo es demasiado simple para capturar los patrones).

Utilizamos un Pipeline que primero escala los datos (**StandardScaler**) y luego aplica el modelo. Esto previene el **Data Leakage** (fuga de información) ya que el escalador se ajusta solo con los datos de entrenamiento.

```
[38]: # Crear pipeline con StandardScaler y LogisticRegression
pipeline_lr = Pipeline([
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(max_iter=500, random_state=42))
])

# Entrenamiento
pipeline_lr.fit(X_train, y_train)
print("Modelo de Regresión Logística entrenado correctamente.")
```

Modelo de Regresión Logística entrenado correctamente.


8.1.2 3.1 Evaluación del Modelo de Regresión Logística

Evaluamos el modelo utilizando las siguientes métricas: - **Accuracy (Exactitud)**: Porcentaje de predicciones correctas totales. - **Precision (Precisión)**: De las predicciones positivas, ¿cuántas eran realmente positivas? - **Recall (Sensibilidad)**: De todos los positivos reales, ¿cuántos logró encontrar el modelo? En el contexto médico (cáncer), **Recall** es la métrica más importante, ya que un falso negativo puede tener consecuencias mortales. - **F1-score**: Media armónica entre Precision y Recall.

```
[39]: # Predicción sobre Test
y_pred_lr = pipeline_lr.predict(X_test)

cm_lr = confusion_matrix(y_test, y_pred_lr)
disp_lr = ConfusionMatrixDisplay(confusion_matrix=cm_lr,
    ↪display_labels=['Benigno', 'Maligno'])
disp_lr.plot(cmap='Blues')
plt.title("Matriz de Confusión - Regresión Logística (Test)")
plt.show()

print("Reporte de Clasificación (Test):")
print(classification_report(y_test, y_pred_lr, target_names=['Benigno',
    ↪'Maligno']))
```



Reporte de Clasificación (Test):

	precision	recall	f1-score	support
Benigno	0.96	0.99	0.98	107
Maligno	0.98	0.94	0.96	64
accuracy			0.97	171
macro avg	0.97	0.96	0.97	171
weighted avg	0.97	0.97	0.97	171

```
[40]: # Comparación con Train para detectar Overfitting/Underfitting
y_train_pred_lr = pipeline_lr.predict(X_train)
print("Reporte de Clasificación (Train):")
print(classification_report(y_train, y_train_pred_lr, target_names=['Benigno', 'Maligno']))
```

Reporte de Clasificación (Train):

	precision	recall	f1-score	support
Benigno	0.98	1.00	0.99	250
Maligno	1.00	0.97	0.98	148
accuracy			0.99	398
macro avg	0.99	0.98	0.99	398
weighted avg	0.99	0.99	0.99	398

8.1.3 11. Modelo 1: Regresión logística

La regresión logística estima probabilidades para clasificación binaria.

Usamos escalado porque es un modelo lineal y puede beneficiarse de variables en escala comparable.

```
[41]: modelo_logistica = Pipeline([
    ("scaler", StandardScaler()),
    ("model", LogisticRegression(max_iter=1000, random_state=42))
])

modelo_logistica.fit(X_train, y_train)
pred_logistica = modelo_logistica.predict(X_test)

print(classification_report(y_test, pred_logistica, target_names=["Benigno", "Maligno"]))
```

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

Benigno	0.96	0.99	0.98	107
Maligno	0.98	0.94	0.96	64
accuracy			0.97	171
macro avg	0.97	0.96	0.97	171
weighted avg	0.97	0.97	0.97	171

Modelo de Regresión Logística Sin PCA Entrenamos el modelo con las variables **escaladas** (sin reducción de dimensionalidad).

```
[42]: # Crear pipeline con StandardScaler y LogisticRegression
pipeline_lr = Pipeline([
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(max_iter=500, random_state=42))
])

# Entrenamiento
pipeline_lr.fit(X_train, y_train)
print("Modelo de Regresión Logística (Sin PCA) entrenado correctamente.")

# Predicción
y_pred_lr = pipeline_lr.predict(X_test)
```

Modelo de Regresión Logística (Sin PCA) entrenado correctamente.

Modelo de Regresión Logística Con PCA Entrenamos el modelo con las **5 componentes principales** (X_train_pca / X_test_pca).

```
[43]: # Regresión Logística sobre componentes PCA (ya escalados)
lr_pca = LogisticRegression(max_iter=500, random_state=42)
lr_pca.fit(X_train_pca, y_train)
print("Modelo de Regresión Logística (Con PCA) entrenado correctamente.")

# Predicción
y_pred_lr_pca = lr_pca.predict(X_test_pca)
```

Modelo de Regresión Logística (Con PCA) entrenado correctamente.

```
[44]: comparacion_logistica = pd.DataFrame([
    evaluar_clasificacion('Log. Reg. Sin PCA', y_test, y_pred_lr),
    evaluar_clasificacion('Log. Reg. Con PCA', y_test, y_pred_lr_pca),
])

display(comparacion_logistica)
```

	modelo	accuracy	precision	recall	f1
0	Log. Reg. Sin PCA	0.970760	0.983607	0.93750	0.960000
1	Log. Reg. Con PCA	0.988304	1.000000	0.96875	0.984127

8.1.4 7.1.2 K-Nearest Neighbors (KNN)

8.1.5 K-Nearest Neighbors (KNN) - Dataset de Cáncer

Objetivo Entrenar, evaluar y comparar un modelo KNN usando el dataset `Cancer_Data.csv`.

Parte A — Comprensión conceptual Responda:

1. **¿Qué significa KNN?**

- *Respuesta:* KNN significa “K-Nearest Neighbors” (K-Vecinos Más Cercanos). Es un algoritmo de aprendizaje supervisado no paramétrico que se utiliza para tareas de clasificación y regresión.

2. **¿Cómo clasifica KNN un nuevo registro?**

- *Respuesta:* Para clasificar un nuevo registro, KNN calcula la distancia entre este registro y todos los puntos de datos en el conjunto de entrenamiento. Luego, selecciona los ‘k’ vecinos más cercanos. La clase del nuevo registro se determina por la mayoría de las clases entre esos ‘k’ vecinos. En el caso de regresión, se toma la media de los valores de los ‘k’ vecinos.

3. **¿Qué representa el parámetro (k)?**

- *Respuesta:* El parámetro (k) representa el número de vecinos más cercanos que se consideran al clasificar un nuevo punto de datos. Es un hiperparámetro que debe ser ajustado, ya que un valor de (k) demasiado pequeño puede hacer que el modelo sea sensible al ruido (sobreajuste), y un valor demasiado grande puede hacer que ignore los patrones locales (subajuste).

4. **¿Por qué KNN depende de la distancia?**

- *Respuesta:* KNN depende fundamentalmente de la distancia porque su mecanismo de clasificación se basa en la proximidad. La distancia (comúnmente euclidiana, pero pueden usarse otras) es la métrica que define qué tan “cerca” son los vecinos. Sin una medida de distancia, el algoritmo no podría identificar los “K-Nearest Neighbors”.

5. **¿Por qué el escalado es obligatorio o muy recomendable?**

- *Respuesta:* El escalado de características es obligatorio o muy recomendable para KNN porque el algoritmo es sensible a la escala de las características. Si las características tienen rangos de valores muy diferentes, aquellas con rangos más grandes dominarán desproporcionadamente el cálculo de la distancia, haciendo que las características con rangos más pequeños sean casi irrelevantes. El escalado (por ejemplo, normalización o estandarización) asegura que todas las características contribuyan equitativamente a la medida de distancia.

6. **¿Qué diferencia conceptual hay entre KNN y árbol de decisión?**

- *Respuesta:* La principal diferencia conceptual radica en cómo aprenden y clasifican. Un **Árbol de Decisión** es un modelo basado en reglas que crea una estructura jerárquica de divisiones para segmentar el espacio de características, lo que resulta en una serie de reglas condicionales (si-entonces) que son fácilmente interpretables. Es un modelo “eager learning” (aprende antes de ver los datos de test). Por otro lado, **KNN** es un algoritmo basado en instancias o “lazy learning” (aprende cuando se le pide una predicción). No construye un modelo explícito durante el entrenamiento, sino que almacena todo el conjunto de datos de entrenamiento y clasifica un nuevo punto consultando a sus vecinos más cercanos en ese momento. Los árboles definen límites de decisión complejos, mientras que KNN define límites implícitamente basados en la densidad de puntos en el espacio de características.

Parte B — Preparación de datos Para este taller, utilizaremos todas las características numéricas del dataset `df` (excluyendo la columna `diagnosis` como variable objetivo). El dataset ya fue cargado, sus columnas limpiadas, la columna `id` y la columna vacía eliminadas, y la variable `diagnosis` codificada a 0 y 1 en las secciones anteriores del notebook.

Ahora, realizaremos la separación en conjuntos de entrenamiento y prueba (train/test split) con estratificación para asegurar una representación equitativa de las clases de diagnóstico en ambos conjuntos.

```
[45]: # --- START: Código para asegurar que df esté definido y limpio para el taller
      ↪ ---
      # Cargar el dataset para asegurar un estado fresco del DataFrame
      file_path = 'Cancer_Data.csv'

      # Check if the file exists in the current directory first, then in /content/
      ↪ sample_data/
      if not os.path.exists(file_path):
          file_path = '/content/sample_data/Cancer_Data.csv'

      df = pd.read_csv(file_path)
      df.columns = df.columns.str.replace('"', '').str.strip()
      if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
      if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
      ↪ inplace=True)
      df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

      # Limpiar nombres de columnas (eliminar espacios y comillas)
      df.columns = df.columns.str.replace('"', '').str.strip()

      # Limpiar valores de texto en todo el dataframe (ej: " M " -> "M")
      # Usando applymap para mayor compatibilidad con la versión original.
      df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

      # Identificar y eliminar columnas con solo NaNs (más robusto)
      cols_to_drop_nan = [col for col in df.columns if col != 'diagnosis' and df[col].
      ↪ isna().all()]
      if cols_to_drop_nan:
          df.drop(columns=cols_to_drop_nan, inplace=True)

      # Codificar la variable objetivo (Maligno = 1, Benigno = 0)
      df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0, '1': 1, '0': 0, 1: 1, 0:
      ↪ 0, '1.0': 1, '0.0': 0})
      # --- END: Código para asegurar que df esté definido y limpio para el taller ---

      # X y y son derivados del df limpio para el taller
      X = df.drop(columns=['diagnosis'])
      y = df['diagnosis']
```

```

# Realizamos un nuevo train/test split para este taller para seguir la
↳ estructura de la consigna
X_taller, X_temp, y_taller, y_temp = train_test_split(
    X, y, test_size=0.30, random_state=42, stratify=y
)

# La consigna del taller solo pide train/test, así que usaremos X_taller y
↳ y_taller
# como el conjunto completo para este taller, y luego haremos un 70/30 de nuevo.

X_train_t, X_test_t, y_train_t, y_test_t = train_test_split(
    X, y, test_size=0.30, random_state=42, stratify=y
)

print("Dimensiones del conjunto de entrenamiento:", X_train_t.shape, y_train_t.
↳ shape)
print("Dimensiones del conjunto de prueba:", X_test_t.shape, y_test_t.shape)

```

Dimensiones del conjunto de entrenamiento: (398, 30) (398,)

Dimensiones del conjunto de prueba: (171, 30) (171,)

Helper Function: evaluar_modelo Para simplificar la evaluación y comparación de los modelos, definiremos una función auxiliar que calcula las métricas de clasificación (accuracy, precision, recall, f1-score) y las retorna en un diccionario. Esto nos permitirá tener un formato consistente para todas las comparaciones.

Parte C — KNN sin escalado vs KNN con escalado Entrenaremos y evaluaremos el modelo KNN con (k=5), primero sin escalar las características y luego aplicando un **StandardScaler** dentro de un Pipeline. Compararemos las métricas de rendimiento y discutiremos la importancia del escalado en KNN.

8.1.6 Explicación:

- **KNN sin escalado:** Se entrena el modelo directamente con los datos `X_train_t` y `y_train_t` sin ninguna transformación de las características.
- **KNN con escalado:** Se utiliza un Pipeline que primero aplica **StandardScaler** a los datos (para estandarizarlos a media 0 y varianza 1) y luego entrena el **KNeighborsClassifier**. El escalado es crucial para KNN porque este algoritmo se basa en distancias. Si las características tienen rangos de valores muy diferentes, las características con rangos más grandes dominarán la métrica de distancia, sesgando los resultados.

```

[46]: # KNN sin escalado
knn_sin = KNeighborsClassifier(n_neighbors=5)
knn_sin.fit(X_train_t, y_train_t)
pred_sin = knn_sin.predict(X_test_t)

# KNN con escalado usando Pipeline

```

```

knn_con = Pipeline([
    ("scaler", StandardScaler()),
    ("knn", KNeighborsClassifier(n_neighbors=5))
])
knn_con.fit(X_train_t, y_train_t)
pred_con = knn_con.predict(X_test_t)

# Comparación de resultados
comparacion_taller_knn = pd.DataFrame([
    evaluar_modelo("KNN sin escalado", y_test_t, pred_sin),
    evaluar_modelo("KNN con escalado", y_test_t, pred_con)
])

display(comparacion_taller_knn)

print("\nMetodológicamente, la versión con escalado es más correcta porque el_
↳ KNN se basa en la distancia entre los puntos. Sin escalado, las_
↳ características con rangos de valores más grandes pueden dominar la métrica_
↳ de distancia, llevando a resultados sesgados y un rendimiento subóptimo.")

```

	Modelo	Accuracy	Precision	Recall	F1-Score
0	KNN sin escalado	0.929825	0.981481	0.828125	0.898305
1	KNN con escalado	0.964912	1.000000	0.906250	0.950820

Metodológicamente, la versión con escalado es más correcta porque el KNN se basa en la distancia entre los puntos. Sin escalado, las características con rangos de valores más grandes pueden dominar la métrica de distancia, llevando a resultados sesgados y un rendimiento subóptimo.

Parte D — Selección de k Exploraremos el impacto del valor de (k) (el número de vecinos) en el rendimiento del modelo KNN. Entrenaremos y evaluaremos modelos KNN con escalado para valores de (k) entre 1 y 30. Analizaremos las métricas de **accuracy**, **precision**, **recall** y **F1-score** para identificar el (k) óptimo.

8.1.7 Explicación:

- **Problema de (k=1):** Un valor de (k=1) hace que el modelo sea muy sensible al ruido en los datos de entrenamiento. El clasificador simplemente asigna la clase del vecino más cercano, lo que puede llevar a un sobreajuste (overfitting) y una baja capacidad de generalización en datos no vistos.
- **Problema de (k) demasiado grande:** Un valor de (k) muy grande puede hacer que el modelo capture más la distribución general de las clases que los patrones específicos de los vecinos cercanos, llevando a un subajuste (underfitting). El clasificador podría ignorar las características locales importantes y clasificar un nuevo punto basándose en una mayoría muy amplia que podría no ser representativa de su vecindad inmediata.

```
[47]: resultados_k_taller = []
for k in range(1, 31):
    modelo = Pipeline([
        ("scaler", StandardScaler()),
        ("knn", KNeighborsClassifier(n_neighbors=k))
    ])
    modelo.fit(X_train_t, y_train_t)
    pred = modelo.predict(X_test_t)
    resultados_k_taller.append({
        "k": k,
        "accuracy_test": accuracy_score(y_test_t, pred),
        "precision_test": precision_score(y_test_t, pred),
        "recall_test": recall_score(y_test_t, pred),
        "f1_test": f1_score(y_test_t, pred)
    })

df_k_taller = pd.DataFrame(resultados_k_taller)


print("Los 10 mejores valores de k según F1-score:")
display(df_k_taller.sort_values("f1_test", ascending=False).head(10))

plt.figure(figsize=(12,6))
plt.plot(df_k_taller["k"], df_k_taller["accuracy_test"], marker="o", label="Accuracy")
plt.plot(df_k_taller["k"], df_k_taller["f1_test"], marker="o", label="F1-score")
plt.plot(df_k_taller["k"], df_k_taller["recall_test"], marker="o", label="Recall")
plt.plot(df_k_taller["k"], df_k_taller["precision_test"], marker="o", label="Precision")
plt.title("Métricas de rendimiento según el valor de k para KNN (con escalado)")
plt.xlabel("Valor de k")
plt.ylabel("Valor de la métrica")
plt.legend()
plt.grid(True)
plt.xticks(range(1, 31))
plt.show()
```

Los 10 mejores valores de k según F1-score:

	k	accuracy_test	precision_test	recall_test	f1_test
4	5	0.964912	1.000000	0.906250	0.950820
6	7	0.964912	1.000000	0.906250	0.950820
3	4	0.959064	1.000000	0.890625	0.942149
5	6	0.959064	1.000000	0.890625	0.942149
2	3	0.959064	1.000000	0.890625	0.942149
8	9	0.953216	0.982759	0.890625	0.934426
9	10	0.953216	0.982759	0.890625	0.934426
10	11	0.953216	0.982759	0.890625	0.934426

7	8	0.953216	1.000000	0.875000	0.933333
11	12	0.953216	1.000000	0.875000	0.933333



Parte E — Comparación contra árbol Ahora compararemos el mejor modelo KNN (encontrado en la sección anterior basándonos en el **F1-score**) con un modelo de Árbol de Decisión. El Árbol de Decisión será entrenado con `criterion="gini"` y una profundidad máxima de 3 (`max_depth=3`) para mantenerlo interpretable y comparable con los árboles ya explorados en el notebook.

8.1.8 Explicación:

- **Interpretación:** Discutiremos cuál modelo ofrece una mayor interpretabilidad. Los árboles de decisión son conocidos por su fácil visualización y reglas claras, mientras que KNN es un algoritmo basado en instancias y su “razonamiento” no es directamente interpretable.
- **Recomendación:** Basándonos en las métricas y la interpretabilidad, se hará una recomendación sobre cuál modelo sería más adecuado según un objetivo hipotético (por ejemplo, si la interpretabilidad es clave o si solo se busca el mejor rendimiento).

```
[48]: # Obtener el mejor k basado en F1-score
mejor_k_taller = int(df_k_taller.sort_values("f1_test", ascending=False).
    .iloc[0]["k"])

print(f"El mejor valor de k encontrado es: {mejor_k_taller}")

# Entrenar KNN con el mejor k
knn_mejor_taller = Pipeline([
    ("scaler", StandardScaler()),
```

```

        ("knn", KNeighborsClassifier(n_neighbors=mejor_k_taller))
    ])
    knn_mejor_taller.fit(X_train_t, y_train_t)
    pred_knn_mejor = knn_mejor_taller.predict(X_test_t)

# Entrenar Árbol de Decisión
    arbol_taller = DecisionTreeClassifier(criterion="gini", max_depth=3,
        ↪random_state=42)
    arbol_taller.fit(X_train_t, y_train_t)
    pred_arbol_taller = arbol_taller.predict(X_test_t)

# Comparar los modelos
    comparacion_modelos = pd.DataFrame([
        evaluar_modelo(f"KNN k={mejor_k_taller}", y_test_t, pred_knn_mejor),
        evaluar_modelo("Árbol max_depth=3", y_test_t, pred_arbol_taller)
    ])

    display(comparacion_modelos)


# Matriz de confusión para el mejor KNN
    cm_knn_mejor = confusion_matrix(y_test_t, pred_knn_mejor)
    disp_knn_mejor = ConfusionMatrixDisplay(confusion_matrix=cm_knn_mejor,
        ↪display_labels=['Benigno', 'Maligno'])
    disp_knn_mejor.plot(cmap='Purples')
    plt.title(f"Matriz de Confusión - Mejor KNN (k={mejor_k_taller})")
    plt.show()


# Matriz de confusión para el Árbol de Decisión
    cm_arbol_taller = confusion_matrix(y_test_t, pred_arbol_taller)
    disp_arbol_taller = ConfusionMatrixDisplay(confusion_matrix=cm_arbol_taller,
        ↪display_labels=['Benigno', 'Maligno'])
    disp_arbol_taller.plot(cmap='Greens')
    plt.title("Matriz de Confusión - Árbol de Decisión (max_depth=3)")
    plt.show()

```

El mejor valor de k encontrado es: 5

	Modelo	Accuracy	Precision	Recall	F1-Score
0	KNN k=5	0.964912	1.0	0.90625	0.950820
1	Árbol max_depth=3	0.918129	1.0	0.78125	0.877193





8.1.9 12. Modelo 2: KNN

KNN clasifica usando vecinos cercanos.

Requiere escalado porque depende de distancias.

```
[49]: modelo_knn = Pipeline([
      ("scaler", StandardScaler()),
      ("model", KNeighborsClassifier(n_neighbors=5))
    ])

modelo_knn.fit(X_train, y_train)
pred_knn = modelo_knn.predict(X_test)

print(classification_report(y_test, pred_knn, target_names=["Benigno",
↪ "Maligno"]))
```

	precision	recall	f1-score	support
Benigno	0.95	1.00	0.97	107

Maligno	1.00	0.91	0.95	64
accuracy			0.96	171
macro avg	0.97	0.95	0.96	171
weighted avg	0.97	0.96	0.96	171

8.1.10 Modelos de Random Forest

En esta sección se entrena y compara **Random Forest** contra modelos supervisados trabajados previamente (Regresión Logística, KNN y Árbol de Decisión) usando el dataset de cáncer.

Objetivos

1. Comparar desempeño de Random Forest con otros modelos.
2. Entender el impacto de `n_estimators` y `max_depth` en Random Forest.
3. Calcular la importancia de características.
4. Justificar técnicamente cuál modelo elegir según el problema.

8.1.11 KNN sobre `Cancer_Data.csv`

En esta sección se entrena, evalúa y compara un modelo KNN sobre el dataset de cáncer. La estructura sigue la lógica trabajada en la clase de KNN: primero se revisa el efecto de no escalar las variables, luego se aplica escalado con `StandardScaler` y finalmente se comparan distintos valores de `k`.

1. Objetivo y criterios de evaluación El objetivo es comparar tres variantes:

1. KNN sin escalado.
2. KNN con escalado.
3. KNN con distintos valores de `k`.

Se usarán las métricas:

- Accuracy
- Precision
- Recall
- F1-score

Además, se comparará el mejor KNN contra un árbol de decisión para tener una referencia interpretativa.

```
[50]: def evaluar_knn(nombre_modelo, y_true, y_pred):
    return {
        "Modelo": nombre_modelo,
        "Accuracy": accuracy_score(y_true, y_pred),
        "Precision": precision_score(y_true, y_pred, zero_division=0),
        "Recall": recall_score(y_true, y_pred, zero_division=0),
        "F1-score": f1_score(y_true, y_pred, zero_division=0)
    }
```

```

df_knn = pd.read_csv("Cancer_Data.csv")
df_knn.columns = [col.strip().strip(' ') for col in df_knn.columns]

if "id" in df_knn.columns:
    df_knn = df_knn.drop(columns=["id"])
if "Unnamed: 32" in df_knn.columns:
    df_knn = df_knn.drop(columns=["Unnamed: 32"])

if "diagnosis" not in df_knn.columns:
    raise ValueError("No se encontró la columna diagnosis en Cancer_Data.csv")

df_knn["diagnosis"] = df_knn["diagnosis"].astype(str).str.strip().str.strip(' ')
df_knn["diagnosis"] = df_knn["diagnosis"].map({"M": 1, "B": 0, "1": 1, "0": 0, "1.0": 1, "0.0": 0})
df_knn = df_knn.dropna(subset=["diagnosis"])

X_knn = df_knn.drop(columns=["diagnosis"]).apply(pd.to_numeric, errors="coerce")
cols_all_nan = X_knn.columns[X_knn.isna().all()].tolist()
if cols_all_nan:
    X_knn = X_knn.drop(columns=cols_all_nan)
    print("Columnas totalmente NaN eliminadas:", cols_all_nan)

X_knn = X_knn.fillna(X_knn.median(numeric_only=True))
mask_completo = X_knn.notna().all(axis=1)
X_knn = X_knn.loc[mask_completo].reset_index(drop=True)
y_knn = df_knn.loc[mask_completo, "diagnosis"].reset_index(drop=True)

X_train_knn, X_test_knn, y_train_knn, y_test_knn = train_test_split(
    X_knn, y_knn, test_size=0.30, random_state=42, stratify=y_knn
)

print("Dimensiones train:", X_train_knn.shape)
print("Dimensiones test:", X_test_knn.shape)
print("Distribución target en train:")
print(y_train_knn.value_counts(normalize=True).sort_index())
print("Distribución target en test:")
print(y_test_knn.value_counts(normalize=True).sort_index())

```

```

Dimensiones train: (398, 30)
Dimensiones test: (171, 30)
Distribución target en train:
diagnosis
0    0.628141
1    0.371859
Name: proportion, dtype: float64
Distribución target en test:
diagnosis

```

```
0    0.625731
1    0.374269
Name: proportion, dtype: float64
```

2. KNN sin escalado vs KNN con escalado Primero entrenamos un KNN base con $k=5$ sin transformar las variables. Luego repetimos el proceso con `StandardScaler` para ver el impacto del preprocesamiento en un modelo basado en distancias.

```
[51]: knn_sin_escalado = KNeighborsClassifier(n_neighbors=5)
knn_sin_escalado.fit(X_train_knn, y_train_knn)
pred_sin_escalado = knn_sin_escalado.predict(X_test_knn)

knn_con_escalado = Pipeline([
    ("scaler", StandardScaler()),
    ("knn", KNeighborsClassifier(n_neighbors=5))
])
knn_con_escalado.fit(X_train_knn, y_train_knn)
pred_con_escalado = knn_con_escalado.predict(X_test_knn)

comparacion_knn_escalado = pd.DataFrame([
    evaluar_knn("KNN sin escalado", y_test_knn, pred_sin_escalado),
    evaluar_knn("KNN con escalado", y_test_knn, pred_con_escalado)
]).sort_values("F1-score", ascending=False)


print("Comparación KNN sin escalado vs con escalado")
display(comparacion_knn_escalado)


cm_sin = confusion_matrix(y_test_knn, pred_sin_escalado)
disp_sin = ConfusionMatrixDisplay(confusion_matrix=cm_sin,
    ↪display_labels=["Benigno", "Maligno"])
disp_sin.plot(cmap="Blues")
plt.title("Matriz de confusión - KNN sin escalado")
plt.show()

cm_con = confusion_matrix(y_test_knn, pred_con_escalado)
disp_con = ConfusionMatrixDisplay(confusion_matrix=cm_con,
    ↪display_labels=["Benigno", "Maligno"])
disp_con.plot(cmap="Greens")
plt.title("Matriz de confusión - KNN con escalado")
plt.show()
```

Comparación KNN sin escalado vs con escalado

	Modelo	Accuracy	Precision	Recall	F1-score
1	KNN con escalado	0.964912	1.000000	0.906250	0.950820
0	KNN sin escalado	0.929825	0.981481	0.828125	0.898305





3. Selección de k y comparación contra un árbol Probamos distintos valores de k para identificar el mejor balance entre sesgo y varianza. Después comparamos el mejor KNN con un árbol de decisión de profundidad limitada para tener una referencia interpretable.

```
[52]: resultados_k = []
for k in range(1, 31):
    modelo_k = Pipeline([
        ("scaler", StandardScaler()),
        ("knn", KNeighborsClassifier(n_neighbors=k))
    ])
    modelo_k.fit(X_train_knn, y_train_knn)
    pred_k = modelo_k.predict(X_test_knn)
    resultados_k.append({
        "k": k,
        "Accuracy": accuracy_score(y_test_knn, pred_k),
        "Precision": precision_score(y_test_knn, pred_k, zero_division=0),
        "Recall": recall_score(y_test_knn, pred_k, zero_division=0),
        "F1-score": f1_score(y_test_knn, pred_k, zero_division=0)
    })
```

```

comparacion_k = pd.DataFrame(resultados_k).sort_values("F1-score",
    ↪ascending=False)
print("Top 10 valores de k según F1-score")
display(comparacion_k.head(10))

plt.figure(figsize=(10, 5))
plt.plot(comparacion_k.sort_values("k")["k"], comparacion_k.
    ↪sort_values("k")["Accuracy"], marker="o", label="Accuracy")
plt.plot(comparacion_k.sort_values("k")["k"], comparacion_k.
    ↪sort_values("k")["F1-score"], marker="o", label="F1-score")
plt.title("Efecto de k en KNN para Cancer_Data.csv")
plt.xlabel("k")
plt.ylabel("Métrica")
plt.grid(True)
plt.legend()
plt.show()

mejor_k = int(comparacion_k.iloc[0]["k"])
knn_mejor = Pipeline([
    ("scaler", StandardScaler()),
    ("knn", KNeighborsClassifier(n_neighbors=mejor_k))
])
knn_mejor.fit(X_train_knn, y_train_knn)
pred_knn_mejor = knn_mejor.predict(X_test_knn)

arbol_ref = DecisionTreeClassifier(max_depth=3, random_state=42)
arbol_ref.fit(X_train_knn, y_train_knn)
pred_arbol_ref = arbol_ref.predict(X_test_knn)

comparacion_final_knn = pd.DataFrame([
    evaluar_knn(f"KNN k={mejor_k}", y_test_knn, pred_knn_mejor),
    evaluar_knn("Árbol max_depth=3", y_test_knn, pred_arbol_ref)
])

print("Comparación final KNN vs árbol")
display(comparacion_final_knn.sort_values("F1-score", ascending=False))

cm_knn = confusion_matrix(y_test_knn, pred_knn_mejor)
disp_knn = ConfusionMatrixDisplay(confusion_matrix=cm_knn,
    ↪display_labels=["Benigno", "Maligno"])
disp_knn.plot(cmap="Purples")
plt.title(f"Matriz de confusión - Mejor KNN (k={mejor_k})")
plt.show()

cm_arbol = confusion_matrix(y_test_knn, pred_arbol_ref)

```


```

disp_arbol = ConfusionMatrixDisplay(confusion_matrix=cm_arbol,
display_labels=["Benigno", "Maligno"])
disp_arbol.plot(cmap="Greens")
plt.title("Matriz de confusión - Árbol de referencia")
plt.show()

```


Top 10 valores de k según F1-score


	k	Accuracy	Precision	Recall	F1-score
4	5	0.964912	1.000000	0.906250	0.950820
6	7	0.964912	1.000000	0.906250	0.950820
3	4	0.959064	1.000000	0.890625	0.942149
5	6	0.959064	1.000000	0.890625	0.942149
2	3	0.959064	1.000000	0.890625	0.942149
8	9	0.953216	0.982759	0.890625	0.934426
9	10	0.953216	0.982759	0.890625	0.934426
10	11	0.953216	0.982759	0.890625	0.934426
7	8	0.953216	1.000000	0.875000	0.933333
11	12	0.953216	1.000000	0.875000	0.933333



Comparación final KNN vs árbol

	Modelo	Accuracy	Precision	Recall	F1-score
0	KNN k=5	0.964912	1.0	0.90625	0.950820
1	Árbol max_depth=3	0.918129	1.0	0.78125	0.877193





4. Conclusión KNN es un modelo útil para este dataset cuando se aplica correctamente el escalado. En el contexto de cáncer, su desempeño depende fuertemente de la representación de las variables y del valor de k . Si el objetivo es rendimiento puro, el mejor KNN suele competir bien; si el objetivo es interpretabilidad, el árbol sigue siendo más fácil de explicar.

1. Preparación de datos Se utilizan los datos de entrenamiento y test ya preparados en la sección de KNN (Cancer_Data.csv con split 70/30).

Los datos contienen: - **Features:** 30 características numéricas del dataset de cáncer - **Target:** diagnosis (0 = Benigno, 1 = Maligno)

- **Train:** 398 muestras | **Test:** 171 muestras

8.1.12 2.1 Comparación: Variables Escaladas vs Sin Escalar

Primero, probamos por qué KNN requiere datos escalados utilizando un $K=5$ como referencia.

```
[53]: # KNN sin escalar los datos
knn_unscaled = KNeighborsClassifier(n_neighbors=5)
knn_unscaled.fit(X_train, y_train)
acc_unscaled = accuracy_score(y_test, knn_unscaled.predict(X_test))
```

```
# KNN con datos escalados
knn_scaled = KNeighborsClassifier(n_neighbors=5)
knn_scaled.fit(X_train_scaled, y_train)
acc_scaled = accuracy_score(y_test, knn_scaled.predict(X_test_scaled))

print("--- Impacto del Escalado en KNN (K=5) ---")
print(f"Accuracy SIN escalar: {acc_unscaled:.4f}")
print(f"Accuracy CON escalado: {acc_scaled:.4f}")
print("\nDe aquí en adelante utilizamos únicamente datos ESCALADOS.")
```

--- Impacto del Escalado en KNN (K=5) ---

Accuracy SIN escalar: 0.9298

Accuracy CON escalado: 0.9649

De aquí en adelante utilizamos únicamente datos ESCALADOS.

```
[54]: # KNN sin escalado
knn_sin = KNeighborsClassifier(n_neighbors=5)
knn_sin.fit(X_train, y_train)
pred_sin = knn_sin.predict(X_test)

# KNN con escalado usando Pipeline
knn_con = Pipeline([
    ("scaler", StandardScaler()),
    ("knn", KNeighborsClassifier(n_neighbors=5))
])
knn_con.fit(X_train, y_train)
pred_con = knn_con.predict(X_test)

# Comparación de resultados
comparacion_knn = pd.DataFrame([
    evaluar_modelo("KNN sin escalado", y_test, pred_sin),
    evaluar_modelo("KNN con escalado", y_test, pred_con)
])

display(comparacion_knn)
```

	Modelo	Accuracy	Precision	Recall	F1-Score
0	KNN sin escalado	0.929825	0.981481	0.828125	0.898305
1	KNN con escalado	0.964912	1.000000	0.906250	0.950820

Metodológicamente, la versión con escalado es más correcta porque el KNN se basa en la distancia entre los puntos. Sin escalado, las características con rangos de valores más grandes pueden dominar la métrica de distancia, llevando a resultados sesgados y un rendimiento subóptimo.

```
[55]: k_values = range(1, 31)
metrics = {'K': [], 'Metrica': [], 'Valor': [], 'Modelo': []}
```

```

for k in k_values:
    # --- Modelo Sin PCA (Escalado) ---
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(X_train_scaled, y_train)
    y_pred = knn.predict(X_test_scaled)

    metrics['K'].extend([k]*4)
    metrics['Modelo'].extend(['Sin PCA']*4)
    metrics['Metrica'].extend(['Accuracy', 'Precision', 'Recall', 'F1-Score'])
    metrics['Valor'].extend([
        accuracy_score(y_test, y_pred),
        precision_score(y_test, y_pred),
        recall_score(y_test, y_pred),
        f1_score(y_test, y_pred)
    ])

    # --- Modelo Con PCA (5 componentes) ---
    knn_pca = KNeighborsClassifier(n_neighbors=k)
    knn_pca.fit(X_train_pca, y_train)
    y_pred_pca = knn_pca.predict(X_test_pca)

    metrics['K'].extend([k]*4)
    metrics['Modelo'].extend(['Con PCA (5 Comp)']*4)
    metrics['Metrica'].extend(['Accuracy', 'Precision', 'Recall', 'F1-Score'])
    metrics['Valor'].extend([
        accuracy_score(y_test, y_pred_pca),
        precision_score(y_test, y_pred_pca),
        recall_score(y_test, y_pred_pca),
        f1_score(y_test, y_pred_pca)
    ])

df_metrics = pd.DataFrame(metrics)

```

[56]: k_optimo = 5

```

knn_opt = KNeighborsClassifier(n_neighbors=k_optimo)
knn_opt.fit(X_train_scaled, y_train)
y_pred_opt = knn_opt.predict(X_test_scaled)

knn_pca_opt = KNeighborsClassifier(n_neighbors=k_optimo)
knn_pca_opt.fit(X_train_pca, y_train)
y_pred_pca_opt = knn_pca_opt.predict(X_test_pca)

fig, axes = plt.subplots(1, 2, figsize=(12, 5))

sns.heatmap(confusion_matrix(y_test, y_pred_opt), annot=True, fmt='d',
            cmap='Blues', ax=axes[0])

```


```

axes[0].set_title(f'Matriz de Confusión - Sin PCA (K={k_optimo})')
axes[0].set_xlabel('Predicción (0: B, 1: M)')
axes[0].set_ylabel('Real')

sns.heatmap(confusion_matrix(y_test, y_pred_pca_opt), annot=True, fmt='d',
            cmap='Greens', ax=axes[1])
axes[1].set_title(f'Matriz de Confusión - Con PCA 5 Comp (K={k_optimo})')
axes[1].set_xlabel('Predicción (0: B, 1: M)')
axes[1].set_ylabel('Real')

plt.tight_layout()
plt.show()

```



8.1.13 Modelos de Random Forest

8.1.14 7.1.3 Árboles de Decisión

4. Árboles de Decisión En esta sección aplicamos un modelo de Árboles de Decisión. Estos modelos toman decisiones basadas en reglas extraídas de las características.

8.1.15 4.1 Conceptos de Impureza

Los árboles buscan la mejor división utilizando medidas de impureza como **Gini** o **Entropía**.

```

[57]: def gini(proporciones):
        return 1 - sum([p**2 for p in proporciones])

    def entropia(proporciones):
        resultado = 0
        for p in proporciones:
            if p > 0:
                resultado -= p * np.log2(p)

```



```

    return resultado

ejemplos = {
    "Nodo puro [1.0, 0.0]": [1.0, 0.0],
    "Nodo 50/50 [0.5, 0.5]": [0.5, 0.5],
    "Nodo 80/20 [0.8, 0.2]": [0.8, 0.2],
    "Nodo 90/10 [0.9, 0.1]": [0.9, 0.1]
}

print("Cálculos teóricos de impureza:")
for nombre, props in ejemplos.items():
    print(nombre, "| Gini:", round(gini(props), 3), "| Entropía:",
    ↪round(entropia(props), 3))

```

Cálculos teóricos de impureza:

```

Nodo puro [1.0, 0.0] | Gini: 0.0 | Entropía: 0.0
Nodo 50/50 [0.5, 0.5] | Gini: 0.5 | Entropía: 1.0
Nodo 80/20 [0.8, 0.2] | Gini: 0.32 | Entropía: 0.722
Nodo 90/10 [0.9, 0.1] | Gini: 0.18 | Entropía: 0.469

```

8.1.16 4.2 Entrenamiento del Árbol Base

Creamos un árbol de decisión base, limitando su profundidad máxima a 3 (`max_depth=3`) para evitar sobreajuste y facilitar su interpretación.

```

[58]: arbol_base = DecisionTreeClassifier(
        criterion="gini",
        max_depth=3,
        random_state=42
    )

arbol_base.fit(X_train, y_train)
print("Árbol base entrenado correctamente.")

```

Árbol base entrenado correctamente.

8.1.17 4.3 Evaluación del Árbol Base

```

[59]: y_pred_tree = arbol_base.predict(X_test)

print("Accuracy:", round(accuracy_score(y_test, y_pred_tree), 4))
print("Precision:", round(precision_score(y_test, y_pred_tree), 4))
print("Recall:", round(recall_score(y_test, y_pred_tree), 4))
print("F1-score:", round(f1_score(y_test, y_pred_tree), 4))

print("\nReporte completo:")
print(classification_report(y_test, y_pred_tree, target_names=['Benigno',
    ↪'Maligno']))

```

```

cm_tree = confusion_matrix(y_test, y_pred_tree)
disp_tree = ConfusionMatrixDisplay(confusion_matrix=cm_tree,
    ↳display_labels=['Benigno', 'Maligno'])
disp_tree.plot(cmap='Greens')
plt.title("Matriz de confusión - Árbol base")
plt.show()

```

Accuracy: 0.9181


Precision: 1.0

Recall: 0.7812

F1-score: 0.8772

Reporte completo:

	precision	recall	f1-score	support
Benigno	0.88	1.00	0.94	107
Maligno	1.00	0.78	0.88	64
accuracy			0.92	171
macro avg	0.94	0.89	0.91	171
weighted avg	0.93	0.92	0.92	171




8.1.18 4.4 Visualización del Árbol y Reglas

```
[60]: plt.figure(figsize=(24, 12))

plot_tree(
    arbol_base,
    feature_names=list(X.columns),
    class_names=['Benigno', 'Maligno'],
    filled=True,
    rounded=True,
    fontsize=10
)

plt.title("Árbol de decisión - Cancer Data")
plt.show()
```

Árbol de decisión - Cancer Data



```
[61]: reglas = export_text(arbol_base, feature_names=list(X.columns))
print("Reglas del Árbol:")
print(reglas)
```

Reglas del Árbol:

```

|--- perimeter_worst <= 112.80
|   |--- concave points_worst <= 0.18
|   |   |--- area_se <= 35.44
|   |   |   |--- class: 0
|   |   |--- area_se > 35.44
|   |   |   |--- class: 0
|   |--- concave points_worst > 0.18
|   |   |--- class: 1
|--- perimeter_worst > 112.80
|   |--- concave points_worst <= 0.14
|   |   |--- texture_mean <= 16.78
|   |   |   |--- class: 0
|   |   |--- texture_mean > 16.78
|   |   |   |--- class: 1
|   |--- concave points_worst > 0.14
|   |   |--- class: 1

```

8.1.19 4.5 Importancia de las Variables


Vemos cuáles son las características que el árbol considera más importantes para separar las clases.

```
[62]: importancias = pd.DataFrame({
    "variable": X.columns,
    "importancia": arbol_base.feature_importances_
}).sort_values("importancia", ascending=False)

display(importancias.head(32))

plt.figure(figsize=(32, 6))
plt.barh(importancias["variable"][:32], importancias["importancia"][:32])
plt.gca().invert_yaxis()
plt.title("Top 32 Importancia de variables según el árbol")
plt.xlabel("Importancia")
plt.ylabel("Variable")
plt.show()
```

	variable	importancia
22	perimeter_worst	0.827734
27	concave points_worst	0.120496
1	texture_mean	0.031655
13	area_se	0.020114
2	perimeter_mean	0.000000
3	area_mean	0.000000
5	compactness_mean	0.000000
6	concavity_mean	0.000000
8	symmetry_mean	0.000000
7	concave points_mean	0.000000
9	fractal_dimension_mean	0.000000
10	radius_se	0.000000
4	smoothness_mean	0.000000
0	radius_mean	0.000000
12	perimeter_se	0.000000
11	texture_se	0.000000
14	smoothness_se	0.000000
15	compactness_se	0.000000
18	symmetry_se	0.000000
19	fractal_dimension_se	0.000000
16	concavity_se	0.000000
17	concave points_se	0.000000
21	texture_worst	0.000000
20	radius_worst	0.000000
24	smoothness_worst	0.000000
23	area_worst	0.000000
25	compactness_worst	0.000000
26	concavity_worst	0.000000
28	symmetry_worst	0.000000
29	fractal_dimension_worst	0.000000



8.1.20 4.6 Efecto de la Profundidad del Árbol (Overfitting vs Generalización)

Si dejamos que el árbol crezca demasiado (`max_depth` alto), se ajustará perfectamente al set de entrenamiento pero perderá rendimiento en los datos de test.

```
[63]: profundidades = [1, 2, 3, 4, 5, 6, 8, 10, None]
      resultados = []

      for p in profundidades:
          modelo = DecisionTreeClassifier(
              criterion="gini",
              max_depth=p,
              random_state=42
          )

          modelo.fit(X_train, y_train)

          pred_train = modelo.predict(X_train)
          pred_test = modelo.predict(X_test)


          resultados.append({
              "max_depth": str(p),
              "accuracy_train": accuracy_score(y_train, pred_train),
              "accuracy_test": accuracy_score(y_test, pred_test),
              "f1_test": f1_score(y_test, pred_test)
          })

      df_resultados = pd.DataFrame(resultados)
      display(df_resultados)
```

	max_depth	accuracy_train	accuracy_test	f1_test
0	1	0.929648	0.894737	0.844828
1	2	0.949749	0.906433	0.864407
2	3	0.962312	0.918129	0.877193
3	4	0.977387	0.906433	0.862069
4	5	0.984925	0.906433	0.862069
5	6	0.992462	0.912281	0.876033
6	8	1.000000	0.900585	0.864000

7	10	1.000000	0.900585	0.864000
8	None	1.000000	0.900585	0.864000

```
[64]: plt.figure(figsize=(10,5))
plt.plot(df_resultados["max_depth"].astype(str),
         df_resultados["accuracy_train"], marker="o", label="Train")
plt.plot(df_resultados["max_depth"].astype(str),
         df_resultados["accuracy_test"], marker="o", label="Test")
plt.title("Efecto de la profundidad del árbol")
plt.xlabel("max_depth")
plt.ylabel("Accuracy")
plt.legend()
plt.grid(True)
plt.show()
```



8.1.21 4.7 Comparación Gini vs Entropía

```
[65]: comparacion = []

for criterio in ["gini", "entropy"]:
    modelo = DecisionTreeClassifier(
        criterion=criterio,
        max_depth=3,
        random_state=42
    )

    modelo.fit(X_train, y_train)
```

```

pred = modelo.predict(X_test)

comparacion.append({
    "criterio": criterio,
    "accuracy": accuracy_score(y_test, pred),
    "precision": precision_score(y_test, pred),
    "recall": recall_score(y_test, pred),
    "f1": f1_score(y_test, pred)
})

display(pd.DataFrame(comparacion))

```

	criterio	accuracy	precision	recall	f1
0	gini	0.918129	1.0	0.78125	0.877193
1	entropy	0.918129	1.0	0.78125	0.877193

8.1.22 Modelos de Árbol de Decisión

El árbol genera reglas interpretables, pero puede sobreajustar.

```

[66]: modelo_arbol = DecisionTreeClassifier(
        criterion="gini",
        max_depth=3,
        random_state=42
    )

modelo_arbol.fit(X_train, y_train)
pred_arbol = modelo_arbol.predict(X_test)

print(classification_report(y_test, pred_arbol, target_names=["Benigno",
↪ "Maligno"]))

```

	precision	recall	f1-score	support
Benigno	0.88	1.00	0.94	107
Maligno	1.00	0.78	0.88	64
accuracy			0.92	171
macro avg	0.94	0.89	0.91	171
weighted avg	0.93	0.92	0.92	171

Visualización del árbol El árbol puede leerse como reglas IF-THEN.

```

[67]: plt.figure(figsize=(22, 10))
plot_tree(
    modelo_arbol,
    feature_names=X.columns,


```



```

class_names=["Benigno", "Maligno"],
filled=True,
rounded=True,
fontsize=9
)
plt.title("Arbol de decision - Cancer_Data.csv")
plt.show()

```



```

[68]: param_grid = {
    'max_depth': [3, 5, 7, None],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4]
}

resultados_sin_pca = []
resultados_con_pca = []

for max_depth in param_grid['max_depth']:
    for min_samples_split in param_grid['min_samples_split']:
        for min_samples_leaf in param_grid['min_samples_leaf']:
            params = {
                'max_depth': max_depth,
                'min_samples_split': min_samples_split,
                'min_samples_leaf': min_samples_leaf,
                'random_state': 42
            }

            dt_sin = DecisionTreeClassifier(**params)
            pred_sin = entrenar_y_predecir(dt_sin, X_train, X_test, y_train)

```

```

        met_sin = evaluar_modelo('Arbol sin PCA', y_test, pred_sin)
        met_sin.update(params)
        resultados_sin_pca.append(met_sin)

        dt_con = DecisionTreeClassifier(**params)
        pred_con = entrenar_y_predecir(dt_con, X_train_pca, X_test_pca,
        ↪y_train)
        met_con = evaluar_modelo('Arbol con PCA', y_test, pred_con)
        met_con.update(params)
        resultados_con_pca.append(met_con)

df_sin = pd.DataFrame(resultados_sin_pca)
df_con = pd.DataFrame(resultados_con_pca)

```

```

[69]: df_sin_orden = df_sin.sort_values(by=['Recall', 'F1-Score', 'Accuracy'],
        ↪ascending=False)
df_con_orden = df_con.sort_values(by=['Recall', 'F1-Score', 'Accuracy'],
        ↪ascending=False)

best_sin = seleccionar_mejor(df_sin)
best_con = seleccionar_mejor(df_con)

display(df_sin_orden.head(5))
display(df_con_orden.head(5))

```

	Modelo	Accuracy	Precision	Recall	F1-Score	max_depth	
↪	min_samples_split	min_samples_leaf	\				
10	Arbol sin PCA	0.935673	0.981818	0.84375	0.907563	5.0	↪
↪	2	2					
13	Arbol sin PCA	0.935673	0.981818	0.84375	0.907563	5.0	↪
↪	5	2					
16	Arbol sin PCA	0.935673	0.981818	0.84375	0.907563	5.0	↪
↪	10	2					
19	Arbol sin PCA	0.929825	0.964286	0.84375	0.900000	7.0	↪
↪	2	2					
22	Arbol sin PCA	0.929825	0.964286	0.84375	0.900000	7.0	↪
↪	5	2					

	random_state
10	42
13	42
16	42
19	42
22	42

	Modelo	Accuracy	Precision	Recall	F1-Score	max_depth	
↪	min_samples_split	min_samples_leaf	random_state				

15	Arbol con PCA	0.964912	0.967742	0.9375	0.952381	5.0	␣
↪	10	1	42				
16	Arbol con PCA	0.964912	0.967742	0.9375	0.952381	5.0	␣
↪	10	2	42				
17	Arbol con PCA	0.964912	0.967742	0.9375	0.952381	5.0	␣
↪	10	4	42				
24	Arbol con PCA	0.964912	0.967742	0.9375	0.952381	7.0	␣
↪	10	1	42				
25	Arbol con PCA	0.964912	0.967742	0.9375	0.952381	7.0	␣
↪	10	2	42				

```
[70]: def normalizar_max_depth(valor):
        return None if pd.isna(valor) else int(valor)

best_params_sin = {
    'max_depth': normalizar_max_depth(best_sin['max_depth']),
    'min_samples_split': int(best_sin['min_samples_split']),
    'min_samples_leaf': int(best_sin['min_samples_leaf']),
    'random_state': 42
}
best_params_con = {
    'max_depth': normalizar_max_depth(best_con['max_depth']),
    'min_samples_split': int(best_con['min_samples_split']),
    'min_samples_leaf': int(best_con['min_samples_leaf']),
    'random_state': 42
}

dt_best_sin = DecisionTreeClassifier(**best_params_sin)
dt_best_con = DecisionTreeClassifier(**best_params_con)

pred_best_sin = entrenar_y_predecir(dt_best_sin, X_train, X_test, y_train)
pred_best_con = entrenar_y_predecir(dt_best_con, X_train_pca, X_test_pca,
↪y_train)


resumen_metricas = pd.DataFrame([
    evaluar_modelo('Arbol sin PCA', y_test, pred_best_sin),
    evaluar_modelo('Arbol con PCA (5 comp)', y_test, pred_best_con)
])

display(resumen_metricas)
```

	Modelo	Accuracy	Precision	Recall	F1-Score
0	Arbol sin PCA	0.935673	0.981818	0.84375	0.907563
1	Arbol con PCA (5 comp)	0.964912	0.967742	0.93750	0.952381

```
[71]: resumen_melt = resumen_metricas.melt(id_vars='Modelo', var_name='Metrica',
↪value_name='Valor')
```

```
plt.figure(figsize=(10, 5))
sns.barplot(data=resumen_melt, x='Metrica', y='Valor', hue='Modelo',
            palette='Set2')
plt.ylim(0, 1)
plt.title('Comparacion de Metricas: Arbol sin PCA vs Arbol con PCA')
plt.show()
```



Análisis de Matrices de Confusión Analizamos falsos positivos y falsos negativos, con énfasis en los falsos negativos por su impacto médico.

```
[72]: cm_sin = confusion_matrix(y_test, pred_best_sin)
cm_con = confusion_matrix(y_test, pred_best_con)

fig, axes = plt.subplots(1, 2, figsize=(12, 5))
sns.heatmap(cm_sin, annot=True, fmt='d', cmap='Blues', ax=axes[0])
axes[0].set_title('Matriz de Confusion - Arbol sin PCA')
axes[0].set_xlabel('Prediccion (0: B, 1: M)')
axes[0].set_ylabel('Real')


sns.heatmap(cm_con, annot=True, fmt='d', cmap='Greens', ax=axes[1])
axes[1].set_title('Matriz de Confusion - Arbol con PCA (5 comp)')
axes[1].set_xlabel('Prediccion (0: B, 1: M)')
axes[1].set_ylabel('Real')

plt.tight_layout()
```

```
plt.show()

fn_sin = cm_sin[1, 0]
fp_sin = cm_sin[0, 1]
fn_con = cm_con[1, 0]
fp_con = cm_con[0, 1]

print('Falsos Negativos (Maligno clasificado como Benigno):')
print(f' - Sin PCA: {fn_sin}')
print(f' - Con PCA: {fn_con}')
print('Falsos Positivos (Benigno clasificado como Maligno):')
print(f' - Sin PCA: {fp_sin}')
print(f' - Con PCA: {fp_con}')
```



Falsos Negativos (Maligno clasificado como Benigno):

- Sin PCA: 10
- Con PCA: 4


Falsos Positivos (Benigno clasificado como Maligno):

- Sin PCA: 1
- Con PCA: 2

Evaluación de Interpretabilidad del Modelo El Arbol de Decision es mas interpretable que KNN porque se puede visualizar y explicar mediante reglas. Con PCA, la interpretabilidad baja porque las componentes principales son combinaciones de variables originales.


```
[73]: importancias = pd.Series(dt_best_sin.feature_importances_, index=X.columns).
      ↪sort_values(ascending=False)
plt.figure(figsize=(10, 6))
sns.barplot(x=importancias.head(15), y=importancias.head(15).index,
      ↪palette='mako')
```

```
plt.title('Importancia de Variables - Arbol sin PCA (Top 15)')
plt.show()
```



```
[74]: plt.figure(figsize=(16, 8))
plot_tree(
    dt_best_sin,
    feature_names=X.columns,
    class_names=['B (0)', 'M (1)'],
    filled=True,
    max_depth=3
)
plt.title('Arbol de Decision (sin PCA) - Profundidad limitada')
plt.show()
```

Arbol de Decision (sin PCA) - Profundidad limitada



5. Conclusiones En esta seccion se resume el modelo con mejor recall, el mejor F1-Score y el balance entre rendimiento e interpretabilidad.

```
[75]: recall_sin = resumen_metricas.loc[resumen_metricas['Modelo'] == 'Arbol sin PCA', 'Recall'].values[0]
      recall_con = resumen_metricas.loc[resumen_metricas['Modelo'] == 'Arbol con PCA (5 comp)', 'Recall'].values[0]
      f1_sin = resumen_metricas.loc[resumen_metricas['Modelo'] == 'Arbol sin PCA', 'F1-Score'].values[0]
      f1_con = resumen_metricas.loc[resumen_metricas['Modelo'] == 'Arbol con PCA (5 comp)', 'F1-Score'].values[0]

      mejor_recall = 'Arbol sin PCA' if recall_sin >= recall_con else 'Arbol con PCA (5 comp)'
      mejor_f1 = 'Arbol sin PCA' if f1_sin >= f1_con else 'Arbol con PCA (5 comp)'

      conclusion_lines = [
          '### Conclusiones Interpretativas',
          f'- **Mejor Recall:** {mejor_recall} (sin PCA: {recall_sin:.3f}, con PCA: {recall_con:.3f}).',
          f'- **Mejor F1-Score:** {mejor_f1} (sin PCA: {f1_sin:.3f}, con PCA: {f1_con:.3f}).',
          '- **PCA vs Sin PCA:** PCA puede reducir dimensionalidad y mejorar generalizacion, pero pierde interpretabilidad directa.'
```

```

    '- **Interpretabilidad:** El arbol sin PCA permite reglas claras y
    ↪variables originales, lo cual es crucial en contexto medico.',
    '- **Recomendacion:** Priorizar el modelo con mejor recall. Si ambos son
    ↪similares, elegir el sin PCA por su interpretabilidad.'
]

display(Markdown('\n'.join(conclusion_lines)))

```

8.1.23 Conclusiones Interpretativas

- **Mejor Recall:** Arbol con PCA (5 comp) (sin PCA: 0.844, con PCA: 0.938).
- **Mejor F1-Score:** Arbol con PCA (5 comp) (sin PCA: 0.908, con PCA: 0.952).
- **PCA vs Sin PCA:** PCA puede reducir dimensionalidad y mejorar generalizacion, pero pierde interpretabilidad directa.
- **Interpretabilidad:** El arbol sin PCA permite reglas claras y variables originales, lo cual es crucial en contexto medico.
- **Recomendacion:** Priorizar el modelo con mejor recall. Si ambos son similares, elegir el sin PCA por su interpretabilidad.

8.1.24 7.1.4 Random Forest

8.1.25 Modelos de Random Forest

Random Forest entrena muchos árboles y combina sus predicciones.

Esto reduce la dependencia de un único árbol y mejora la robustez.

Parámetros:

- `n_estimators`: número de árboles.
- `max_depth`: profundidad máxima.
- `random_state`: reproducibilidad.

```

[76]: modelo_rf = RandomForestClassifier(
        n_estimators=200,
        max_depth=None,
        random_state=42
    )

modelo_rf.fit(X_train, y_train)
pred_rf = modelo_rf.predict(X_test)

print(classification_report(y_test, pred_rf, target_names=["Benigno",
    ↪"Maligno"]))

```

	precision	recall	f1-score	support
Benigno	0.96	1.00	0.98	107
Maligno	1.00	0.92	0.96	64

accuracy			0.97	171
macro avg	0.98	0.96	0.97	171
weighted avg	0.97	0.97	0.97	171

8.1.26 Modelos de Random Forest

Se entrenan cuatro modelos supervisados para clasificar diagnósticos de cáncer: 1. **Regresión Logística**: modelo lineal baseline 2. **KNN (k=5)**: modelo basado en distancia 3. **Árbol de Decisión (max_depth=3)**: modelo interpretable 4. **Random Forest (n_estimators=200)**: ensamble robusto

8.1.27 Modelos de Random Forest

Random Forest permite identificar qué características son más relevantes para predecir el diagnóstico:


```
[77]: importancia = pd.DataFrame({
    "Característica": X_train_knn.columns,
    "Importancia": modelo_rf.feature_importances_
}).sort_values("Importancia", ascending=False)

print("Top 10 características más importantes:")
display(importancia.head(10))

plt.figure(figsize=(10, 6))
plt.barh(importancia.head(10)["Característica"], importancia.
    ↪head(10)["Importancia"])
plt.xlabel("Importancia")
plt.title("Top 10 características en Random Forest")
plt.tight_layout()
plt.show()
```

Top 10 características más importantes:

	Característica	Importancia
22	perimeter_worst	0.141211
23	area_worst	0.127340
7	concave points_mean	0.112583
27	concave points_worst	0.094050
20	radius_worst	0.085649
3	area_mean	0.053067
2	perimeter_mean	0.052225
0	radius_mean	0.049073
6	concavity_mean	0.042670
13	area_se	0.035200



8.1.28 Modelos de Random Forest

Se explora el impacto de dos parámetros clave: `n_estimators` (número de árboles) y `max_depth` (profundidad máxima).

8.1.29 5.1 Efecto de `n_estimators`

Se entrenan modelos con distintos números de árboles para observar convergencia:

```
[78]: resultados_estimadores = []
for n in [10, 50, 100, 150, 200, 250]:
    modelo_n = RandomForestClassifier(n_estimators=n, random_state=42,
    ↪n_jobs=-1)
    modelo_n.fit(X_train_knn, y_train_knn)
    pred_n = modelo_n.predict(X_test_knn)


    resultados_estimadores.append({
        "n_estimators": n,
        "Accuracy": accuracy_score(y_test_knn, pred_n),
        "F1-score": f1_score(y_test_knn, pred_n, zero_division=0)
    })

df_estimadores = pd.DataFrame(resultados_estimadores)
print("Efecto de n_estimators:")
display(df_estimadores)
```

```
plt.figure(figsize=(10, 5))
plt.plot(df_estimadores["n_estimators"], df_estimadores["Accuracy"],
        ↪marker="o", label="Accuracy", linewidth=2)
plt.plot(df_estimadores["n_estimators"], df_estimadores["F1-score"],
        ↪marker="s", label="F1-score", linewidth=2)
plt.xlabel("n_estimators")
plt.ylabel("Métrica")
plt.title("Efecto de n_estimators en Random Forest")
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```

Efecto de n_estimators:

	n_estimators	Accuracy	F1-score
0	10	0.947368	0.92437
1	50	0.964912	0.95082
2	100	0.964912	0.95082
3	150	0.970760	0.95935
4	200	0.970760	0.95935
5	250	0.970760	0.95935



8.1.30 5.2 Efecto de max_depth

Se entrenan modelos con distintas profundidades máximas para detectar overfitting:

```
[79]: resultados_depth = []
for depth in [3, 5, 7, 10, 15, 20]:
    modelo_d = RandomForestClassifier(
        n_estimators=200,
        max_depth=depth,
        random_state=42,
        n_jobs=-1
    )
    modelo_d.fit(X_train_knn, y_train_knn)

    pred_train = modelo_d.predict(X_train_knn)
    pred_test = modelo_d.predict(X_test_knn)


    resultados_depth.append({
        "max_depth": str(depth),
        "Accuracy_train": accuracy_score(y_train_knn, pred_train),
        "Accuracy_test": accuracy_score(y_test_knn, pred_test),
        "F1_train": f1_score(y_train_knn, pred_train, zero_division=0),
        "F1_test": f1_score(y_test_knn, pred_test, zero_division=0)
    })

df_depth = pd.DataFrame(resultados_depth)
print("Efecto de max_depth (Train vs Test):")
display(df_depth)

plt.figure(figsize=(10, 5))
plt.plot(range(len(df_depth)), df_depth["Accuracy_train"], marker="o",
         label="Train", linewidth=2)
plt.plot(range(len(df_depth)), df_depth["Accuracy_test"], marker="s",
         label="Test", linewidth=2)
plt.xlabel("max_depth")
plt.ylabel("Accuracy")
plt.title("Efecto de max_depth en Random Forest (Overfitting)")
plt.xticks(range(len(df_depth)), df_depth["max_depth"])
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```

Efecto de max_depth (Train vs Test):

	max_depth	Accuracy_train	Accuracy_test	F1_train	F1_test
0	3	0.974874	0.959064	0.965278	0.942149
1	5	0.989950	0.964912	0.986301	0.950820
2	7	0.997487	0.970760	0.996610	0.959350
3	10	1.000000	0.970760	1.000000	0.959350
4	15	1.000000	0.970760	1.000000	0.959350
5	20	1.000000	0.970760	1.000000	0.959350



8.1.31 Modelos de Random Forest

Hallazgos principales:

1. **Random Forest supera modelos individuales:** El ensamble robusto obtiene mejor F1-score que Árbol, KNN y Regresión Logística.
2. **n_estimators con rendimientos decrecientes:** Después de ~100-150 árboles, la mejora es marginal.
3. **max_depth controla overfitting:** Profundidades grandes (20+) pueden causar overfitting. Valores como 5-10 suelen ser óptimos.
4. **Importancia de características:** Las características más relevantes varían según el dataset, pero Random Forest las identifica automáticamente.

Recomendación para este dataset: - Usar **Random Forest** como modelo final para clasificación de cáncer, configurado con **n_estimators=200** y **max_depth** entre 5-10. - Alternativa interpretable: **Árbol de Decisión (max_depth=3)** si se prioriza explicabilidad sobre performance.

7. Análisis adicional usando Recall Dado que en un problema médico los **falsos negativos** son especialmente peligrosos, ahora repetimos la comparación de modelos priorizando **Recall**. En este contexto, la pregunta clave es: **de todos los casos malignos reales, cuántos logra detectar el modelo?**

Por esta razón, en esta nueva subsección se usa Recall como métrica principal de selección y de recomendación final.

8.1.32 Modelos de Random Forest

Para reforzar la recomendación, analizamos cómo cambia el **Recall** al variar `n_estimators` y `max_depth` en Random Forest. El objetivo es identificar una configuración que mantenga una alta capacidad para detectar casos malignos sin perder generalización.

```
[80]: resultados_recall_estimadores = []
for n in [10, 50, 100, 150, 200, 250]:
    modelo_n_recall = RandomForestClassifier(n_estimators=n, random_state=42,
    ↪n_jobs=-1)
    modelo_n_recall.fit(X_train_knn, y_train_knn)
    pred_n_recall = modelo_n_recall.predict(X_test_knn)

    resultados_recall_estimadores.append({
        "n_estimators": n,
        "Recall": recall_score(y_test_knn, pred_n_recall, zero_division=0)
    })

df_recall_estimadores = pd.DataFrame(resultados_recall_estimadores)
print("Efecto de n_estimators sobre Recall:")
display(df_recall_estimadores)

plt.figure(figsize=(9, 4))
plt.plot(df_recall_estimadores["n_estimators"],
    ↪df_recall_estimadores["Recall"], marker="o", linewidth=2, color="#E45756")
plt.xlabel("n_estimators")
plt.ylabel("Recall")
plt.title("Efecto de n_estimators en Random Forest según Recall")
plt.grid(True, alpha=0.3)
plt.ylim(0, 1.05)
plt.show()

resultados_recall_depth = []
for depth in [3, 5, 7, 10, 15, 20]:
    modelo_d_recall = RandomForestClassifier(
        n_estimators=200,
        max_depth=depth,
        random_state=42,
        n_jobs=-1
    )
    modelo_d_recall.fit(X_train_knn, y_train_knn)

    pred_train_recall = modelo_d_recall.predict(X_train_knn)
    pred_test_recall = modelo_d_recall.predict(X_test_knn)

    resultados_recall_depth.append({
        "max_depth": str(depth),
```

```

        "Recall_train": recall_score(y_train_knn, pred_train_recall,
↪zero_division=0),
        "Recall_test": recall_score(y_test_knn, pred_test_recall,
↪zero_division=0)
    })


df_recall_depth = pd.DataFrame(resultados_recall_depth)
print("Efecto de max_depth sobre Recall (Train vs Test):")
display(df_recall_depth)

plt.figure(figsize=(9, 4))
plt.plot(range(len(df_recall_depth)), df_recall_depth["Recall_train"],
↪marker="o", label="Train", linewidth=2)
plt.plot(range(len(df_recall_depth)), df_recall_depth["Recall_test"],
↪marker="s", label="Test", linewidth=2)
plt.xlabel("max_depth")
plt.ylabel("Recall")
plt.title("Efecto de max_depth en Random Forest según Recall")
plt.xticks(range(len(df_recall_depth)), df_recall_depth["max_depth"])
plt.legend()
plt.grid(True, alpha=0.3)
plt.ylim(0, 1.05)
plt.tight_layout()
plt.show()

```


Efecto de n_estimators sobre Recall:

	n_estimators	Recall
0	10	0.859375
1	50	0.906250
2	100	0.906250
3	150	0.921875
4	200	0.921875
5	250	0.921875



Efecto de `max_depth` sobre Recall (Train vs Test):

	<code>max_depth</code>	Recall_train	Recall_test
0	3	0.939189	0.890625
1	5	0.972973	0.906250
2	7	0.993243	0.921875
3	10	1.000000	0.921875
4	15	1.000000	0.921875
5	20	1.000000	0.921875



8.1.33 7.3 Conclusión basada en Recall

Si el criterio principal es minimizar falsos negativos, la recomendación debe priorizar el modelo con mayor **Recall**. En este dataset, eso significa elegir el modelo que detecte la mayor proporción de casos malignos reales, aunque ocasionalmente incremente falsos positivos.

Conclusión técnica: - Si Random Forest mantiene el mejor Recall, sigue siendo la opción recomendada. - Si otro modelo empata o supera ligeramente su Recall, se debe revisar también su estabilidad, precisión y capacidad de generalización antes de decidir. - En un contexto clínico, **Recall pesa más que Accuracy** porque perder un caso maligno es mucho más grave que generar una alarma adicional.

8.1.34 Modelos de Random Forest

Entrenamos un Random Forest con parametros razonables.

- `n_estimators`: numero de arboles.
- `random_state`: reproducibilidad.

```
[81]: rf_base = RandomForestClassifier(
        n_estimators=200,
        random_state=42,
        n_jobs=-1
    )

    rf_base.fit(X_train, y_train)
    y_pred_base = rf_base.predict(X_test)
```

8.1.35 6. Evaluacion del modelo sin PCA

Calculamos metricas y revisamos la matriz de confusion para entender errores por clase.

```
[82]: metricas_base = evaluar_clasificacion(y_test, y_pred_base)

    pd.DataFrame([metricas_base], index=["Random Forest sin PCA"])
```

```
[82]:
```

	modelo	accuracy	precision	recall	f1
Random Forest sin PCA	Modelo	0.97076	1.0	0.921875	0.95935


```
[83]: print(classification_report(y_test, y_pred_base, target_names=["Benigno",
    ↪ "Maligno"]))

    cm_base = confusion_matrix(y_test, y_pred_base)

    plt.figure(figsize=(4.5, 4))
    sns.heatmap(cm_base, annot=True, fmt="d", cmap="Blues", cbar=False,
                xticklabels=["Benigno", "Maligno"],
                yticklabels=["Benigno", "Maligno"])
    plt.title("Matriz de confusion - Sin PCA")
    plt.xlabel("Prediccion")
```

```
plt.ylabel("Real")
plt.show()
```

	precision	recall	f1-score	support
Benigno	0.96	1.00	0.98	107
Maligno	1.00	0.92	0.96	64
accuracy			0.97	171
macro avg	0.98	0.96	0.97	171
weighted avg	0.97	0.97	0.97	171




```
[84]: importancias = pd.DataFrame({
      "variable": X.columns,
      "importancia": rf_base.feature_importances_
    }).sort_values("importancia", ascending=False)

top_importancias = importancias.head(15)

plt.figure(figsize=(8, 5))
plt.barh(top_importancias["variable"], top_importancias["importancia"],
         color="#4C78A8")
```

```
plt.gca().invert_yaxis()
plt.title("Importancia de variables - Random Forest sin PCA")
plt.xlabel("Importancia")
plt.ylabel("Variable")
plt.show()
```



8.1.36 Sensibilidad a numero de arboles (n_estimators)

Probamos distintos valores de `n_estimators` para ver estabilidad del modelo sin PCA y si el rendimiento se estabiliza.

```
[85]: valores_estimadores = [10, 50, 100, 200, 500]
resultados_estimadores = []

for n in valores_estimadores:
    modelo = RandomForestClassifier(n_estimators=n, random_state=42, n_jobs=-1)
    modelo.fit(X_train, y_train)
    pred = modelo.predict(X_test)


    resultados_estimadores.append({
        "n_estimators": n,
        "accuracy": accuracy_score(y_test, pred),
        "precision": precision_score(y_test, pred),
        "recall": recall_score(y_test, pred),
        "f1": f1_score(y_test, pred)
    })
```

```
df_estimadores = pd.DataFrame(resultados_estimadores)
df_estimadores
```

```
[85]:
```

	n_estimators	accuracy	precision	recall	f1
0	10	0.947368	1.0	0.859375	0.92437
1	50	0.964912	1.0	0.906250	0.95082
2	100	0.964912	1.0	0.906250	0.95082
3	200	0.970760	1.0	0.921875	0.95935
4	500	0.970760	1.0	0.921875	0.95935

```
[86]: plt.figure(figsize=(8, 5))
plt.plot(df_estimadores["n_estimators"], df_estimadores["accuracy"],
        marker="o", label="Accuracy")
plt.plot(df_estimadores["n_estimators"], df_estimadores["recall"], marker="o",
        label="Recall")
plt.plot(df_estimadores["n_estimators"], df_estimadores["f1"], marker="o",
        label="F1")
plt.title("Efecto de n_estimators en Random Forest (sin PCA)")
plt.xlabel("Numero de arboles")
plt.ylabel("Metrica")
plt.ylim(0, 1)
plt.grid(True)
plt.legend()
plt.show()
```



8.1.37 7.1.5 Support Vector Machine (SVM)

8.1.38 Modelos de Support Vector Machine (SVM)

SVM intenta separar las clases con una frontera que deje el mayor margen posible. En palabras sencillas, no busca solo separar benignos y malignos, sino separarlos con una zona de seguridad amplia.

Como SVM depende de distancias y escalas, usaremos `StandardScaler`. Compararemos dos kernels:

- **Linear:** frontera mas simple e interpretable.
- **RBF:** frontera mas flexible para relaciones no lineales.

```
[87]: X_train_svm, X_test_svm, y_train_svm, y_test_svm = train_test_split(
        X_cancer, y_cancer, test_size=0.25, random_state=42, stratify=y_cancer
    )

svm_models = {
    "SVM lineal": Pipeline([
        ("scaler", StandardScaler()),
        ("model", SVC(kernel="linear", C=1.0, probability=True,
        random_state=42))
    ]),
    "SVM RBF": Pipeline([
        ("scaler", StandardScaler()),
        ("model", SVC(kernel="rbf", C=1.0, gamma="scale", probability=True,
        random_state=42))
    ]),
}

svm_results = []
svm_predictions = {}

for name, model in svm_models.items():
    model.fit(X_train_svm, y_train_svm)
    pred = model.predict(X_test_svm)
    proba = model.predict_proba(X_test_svm)[: , 1]
    svm_predictions[name] = pred
    svm_results.append({
        "Modelo": name,
        "Accuracy": accuracy_score(y_test_svm, pred),
        "Precision": precision_score(y_test_svm, pred),
        "Recall": recall_score(y_test_svm, pred),
        "F1": f1_score(y_test_svm, pred),
        "ROC_AUC": roc_auc_score(y_test_svm, proba),
```

```

    })

svm_results_df = pd.DataFrame(svm_results).sort_values("Recall",
    ↪ascending=False)
display(svm_results_df.round(4))

print("Lectura para exposicion:")
print("En cancer suele ser muy importante el Recall para la clase maligna,
    ↪porque queremos reducir falsos negativos: casos malignos clasificados como
    ↪benignos.")

```

	Modelo	Accuracy	Precision	Recall	F1	ROC_AUC
1	SVM RBF	0.972	1.0	0.9245	0.9608	0.9966
0	SVM lineal	0.958	1.0	0.8868	0.9400	0.9929

Lectura para exposicion:

En cancer suele ser muy importante el Recall para la clase maligna, porque queremos reducir falsos negativos: casos malignos clasificados como benignos.

```

[88]: best_svm_name = svm_results_df.iloc[0]["Modelo"]
best_svm_pred = svm_predictions[best_svm_name]


print(f"Mejor SVM segun Recall: {best_svm_name}")
print(classification_report(y_test_svm, best_svm_pred, target_names=["Benigno",
    ↪"Maligno"]))

ConfusionMatrixDisplay.from_predictions(
    y_test_svm, best_svm_pred,
    display_labels=["Benigno", "Maligno"],
    cmap="Blues",
    values_format="d"
)
plt.title(f"Matriz de confusion - {best_svm_name}")
plt.show()

```

Mejor SVM segun Recall: SVM RBF

	precision	recall	f1-score	support
Benigno	0.96	1.00	0.98	90
Maligno	1.00	0.92	0.96	53
accuracy			0.97	143
macro avg	0.98	0.96	0.97	143
weighted avg	0.97	0.97	0.97	143



8.1.39 Analisis de SVM

SVM es un buen candidato para este dataset porque las variables del tumor suelen separar bastante bien los diagnosticos. Si el kernel lineal se acerca al RBF, eso sugiere que la frontera entre benigno y maligno es relativamente clara. Si RBF mejora, puede indicar que hay relaciones curvas o mas complejas entre variables.

En la exposicion conviene resaltar el **Recall** de malignos: un falso negativo es delicado porque seria decir “benigno” cuando en realidad era “maligno”.

8.1.40 7.1.6 Naive Bayes

8.1.41 Modelos de Naive Bayes

Naive Bayes es un modelo probabilistico simple. Parte de una idea muy natural: con la evidencia disponible, calcula que diagnostico es mas probable.

Se llama “naive” porque asume que las variables son independientes entre si, algo que no siempre se cumple. En este dataset varias medidas estan relacionadas, por ejemplo radio, perimetro y area. Aun asi, el modelo puede funcionar sorprendentemente bien y sirve como linea base rapida.

```
[89]: X_train_nb, X_test_nb, y_train_nb, y_test_nb = train_test_split(
        X_cancer, y_cancer, test_size=0.25, random_state=42, stratify=y_cancer
    )

nb_model = GaussianNB()
nb_model.fit(X_train_nb, y_train_nb)
nb_pred = nb_model.predict(X_test_nb)
nb_proba = nb_model.predict_proba(X_test_nb)[: , 1]


nb_results = pd.DataFrame([
    "Modelo": "Gaussian Naive Bayes",
    "Accuracy": accuracy_score(y_test_nb, nb_pred),
    "Precision": precision_score(y_test_nb, nb_pred),
    "Recall": recall_score(y_test_nb, nb_pred),
    "F1": f1_score(y_test_nb, nb_pred),
    "ROC_AUC": roc_auc_score(y_test_nb, nb_proba),
])

display(nb_results.round(4))
print(classification_report(y_test_nb, nb_pred, target_names=["Benigno", "Maligno"]))

ConfusionMatrixDisplay.from_predictions(
    y_test_nb, nb_pred,
    display_labels=["Benigno", "Maligno"],
    cmap="Purples",
    values_format="d"
)
plt.title("Matriz de confusion - Gaussian Naive Bayes")
plt.show()
```

	Modelo	Accuracy	Precision	Recall	F1	ROC_AUC
0	Gaussian Naive Bayes	0.9441	1.0	0.8491	0.9184	0.9952


	precision	recall	f1-score	support
Benigno	0.92	1.00	0.96	90
Maligno	1.00	0.85	0.92	53
accuracy			0.94	143
macro avg	0.96	0.92	0.94	143
weighted avg	0.95	0.94	0.94	143



```
[90]: proba_df = pd.DataFrame({
    "Probabilidad_Maligno": nb_proba,
    "Diagnostico_real": y_test_nb.map({0: "Benigno", 1: "Maligno"}).values
})

plt.figure(figsize=(9, 5))
sns.histplot(data=proba_df, x="Probabilidad_Maligno", hue="Diagnostico_real",
    ↪bins=20, kde=True, element="step")
plt.title("Distribucion de probabilidades predichas por Naive Bayes")
plt.xlabel("Probabilidad estimada de maligno")
plt.show()

print("Lectura para exposicion:")
print("Si los benignos se concentran cerca de 0 y los malignos cerca de 1, el
    ↪modelo esta asignando probabilidades coherentes.")
print("Los casos cerca de 0.5 son los mas dudosos y merecen mas atencion.")
```



Lectura para exposicion:

Si los benignos se concentran cerca de 0 y los malignos cerca de 1, el modelo esta asignando probabilidades coherentes.

Los casos cerca de 0.5 son los mas dudosos y merecen mas atencion.

8.1.42 Modelos de Naive Bayes

Naive Bayes es valioso porque es rapido, claro y probabilistico. Su debilidad es la suposicion de independenciam: en cancer, muchas variables geometricas se mueven juntas.

Si sus metricas quedan cerca de modelos mas complejos, es una buena senal: significa que el dataset tiene patrones fuertes. Si queda por debajo, tambien enseña algo: los modelos que capturan interacciones entre variables pueden aprovechar mejor la informacion.

8.2 7.2 Regresión

Modelos supervisados para predecir la variable continua `area_mean`.

8.2.1 7.2.1 Regresión Lineal

3.2 Regresion lineal (variable continua) Este dataset se usa para clasificacion, pero podemos definir una variable objetivo continua y aplicar regresion lineal siguiendo la metodologia de clase.

8.2.2 3.2.1 Selecccion de variable objetivo

Comparamos `area_mean` y `radius_mean` con el mismo procedimiento y elegimos la que tenga mejor R^2 . La tabla de resultados muestra las metricas para ambas opciones.

```
[91]: # Asegurar limpieza coherente con la seccion 1.1
cols_to_drop_nan = [col for col in df.columns if col != "diagnosis" and df[col].
↳isna().all()]
if cols_to_drop_nan:
    df = df.drop(columns=cols_to_drop_nan)

# Funcion de evaluacion para regresion

objetivos = ["area_mean", "radius_mean"]
resultados_objetivos = []

for objetivo in objetivos:
    X_tmp = df.drop(columns=[col for col in ["diagnosis", objetivo] if col in
↳df.columns])
    y_tmp = df[objetivo]

    X_train_tmp, X_test_tmp, y_train_tmp, y_test_tmp = train_test_split(
        X_tmp, y_tmp, test_size=0.30, random_state=42
    )

    modelo_tmp = LinearRegression()
    modelo_tmp.fit(X_train_tmp, y_train_tmp)
    pred_tmp = modelo_tmp.predict(X_test_tmp)

    resultados_objetivos.append(evaluar_regresion(objetivo, y_test_tmp,
↳pred_tmp))

resultados_objetivos = pd.DataFrame(resultados_objetivos).sort_values("R2",
↳ascending=False)
display(resultados_objetivos)

target_regresion = resultados_objetivos.iloc[0]["objetivo"]
print("Objetivo seleccionado:", target_regresion)
```

[area_mean] MAE: 13.82, RMSE: 21.11, R^2 : 0.9960

[radius_mean] MAE: 0.05, RMSE: 0.07, R^2 : 0.9996


	objetivo	modelo	Modelo	MAE	MSE	RMSE	
↳ R2	R ²						
1	radius_mean	radius_mean	radius_mean	0.045611	0.004922	0.070156	0.999597
0	area_mean	area_mean	area_mean	13.822703	445.536766	21.107742	0.996029

Objetivo seleccionado: radius_mean

8.2.3 3.2.2 Distribucion de la variable objetivo

Antes de entrenar el modelo, revisamos la distribucion de la variable continua seleccionada.

```
[92]: # Distribucion de la variable objetivo
plt.figure(figsize=(8, 4))
plt.hist(df[target_regresion], bins=40)
plt.title(f"Distribucion de {target_regresion}")
plt.xlabel(target_regresion)
plt.ylabel("Frecuencia")
plt.show()
```



8.2.4 3.2.3 Separacion X/y y entrenamiento

Seguimos la misma logica de train/test que en las secciones anteriores.

```
[93]: # Separacion X / y y train-test split
X_reg = df.drop(columns=[col for col in ["diagnosis", target_regresion] if col_
    ↪in df.columns])
y_reg = df[target_regresion]

X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
    X_reg, y_reg, test_size=0.30, random_state=42
)

# Entrenamiento del modelo
modelo_lineal = LinearRegression()
modelo_lineal.fit(X_train_reg, y_train_reg)

# Prediccion y evaluacion
```

```
pred_lineal = modelo_lineal.predict(X_test_reg)

resultado_lineal = evaluar_regresion("Regresion lineal", y_test_reg,
    pred_lineal)
display(pd.DataFrame([resultado_lineal]))
```

[Regresion lineal] MAE: 0.05, RMSE: 0.07, R^2 : 0.9996

	objetivo	modelo	Modelo	MAE	MSE	
RMSE	R2	R^2				
0	Regresion lineal	Regresion lineal	Regresion lineal	0.045611	0.004922	0.
0.070156	0.999597	0.999597				

8.2.5 3.2.4 Interpretacion de coeficientes

Los coeficientes indican la direccion del efecto de cada variable sobre la prediccion, manteniendo las demas constantes.


```
[94]: # Coeficientes del modelo
coeficientes_lineal = pd.DataFrame({
    "variable": X_reg.columns,
    "coeficiente": modelo_lineal.coef_
}).sort_values("coeficiente", ascending=False)

display(coeficientes_lineal)

plt.figure(figsize=(9, 5))
plt.barh(coeficientes_lineal["variable"], coeficientes_lineal["coeficiente"])
plt.title("Coeficientes de la regresion lineal")
plt.xlabel("Coeficiente")
plt.ylabel("Variable")
plt.axvline(0)
plt.show()
```

	variable	coeficiente
8	fractal_dimension_mean	4.159981
16	concave points_se	2.125556
17	symmetry_se	1.820648
3	smoothness_mean	1.671557
15	concavity_se	1.445980
7	symmetry_mean	0.455708
24	compactness_worst	0.271507
9	radius_se	0.182260
19	radius_worst	0.164373
26	concave points_worst	0.145017
1	perimeter_mean	0.137579
25	concavity_worst	0.073507
14	compactness_se	0.014931
2	area_mean	0.000809

20	texture_worst	0.000293
12	area_se	0.000045
10	texture_se	-0.000396
22	area_worst	-0.000518
0	texture_mean	-0.000546
21	perimeter_worst	-0.012256
11	perimeter_se	-0.046653
6	concave points_mean	-0.208836
13	smoothness_se	-0.249249
27	symmetry_worst	-0.249252
28	fractal_dimension_worst	-0.348326
23	smoothness_worst	-0.710099
5	concavity_mean	-1.734482
4	compactness_mean	-3.839207
18	fractal_dimension_se	-4.989045



8.2.6 3.2.5 Diagnostico visual: real vs predicho


Si el modelo fuera perfecto, los puntos caerian sobre la diagonal.

```
[95]: # Real vs Predicho
plt.figure(figsize=(6, 6))
plt.scatter(y_test_reg, pred_lineal, alpha=0.3)
plt.xlabel("Valor real")
plt.ylabel("Valor predicho")
plt.title("Regresion lineal: Real vs Predicho")

min_val = min(y_test_reg.min(), pred_lineal.min())
max_val = max(y_test_reg.max(), pred_lineal.max())
```

```
plt.plot([min_val, max_val], [min_val, max_val])

plt.show()
```



8.2.7 3.2.6 Analisis de residuos


El residuo es la diferencia entre el valor real y el valor predicho. Revisamos su distribucion y si hay patrones evidentes.


```
[96]: # Analisis de residuos
residuos_lineal = y_test_reg - pred_lineal

plt.figure(figsize=(8, 4))
plt.hist(residuos_lineal, bins=40)
```

```
plt.title("Distribucion de residuos - Regresion lineal")
plt.xlabel("Residuo")
plt.ylabel("Frecuencia")
plt.show()

plt.figure(figsize=(7, 4))
plt.scatter(pred_lineal, residuos_lineal, alpha=0.3)
plt.axhline(0)
plt.title("Residuos vs Prediccion")
plt.xlabel("Prediccion")
plt.ylabel("Residuo")
plt.show()
```





8.2.8 3.2.7 Analisis de resultados

A continuacion se resumen las metricas MAE, RMSE y R^2 y se interpreta el ajuste del modelo con base en los resultados obtenidos.

```
[97]: # Métricas
mae = resultado_lineal["MAE"]
rmse = resultado_lineal["RMSE"]
r2 = resultado_lineal["R2"]
print(f"MAE: {mae:.4f}")
print(f"RMSE: {rmse:.4f}")
print(f"R2: {r2:.4f}")
```

MAE: 0.0456

RMSE: 0.0702

R2: 0.9996

Resumen de metricas - MAE: 0.0461 - RMSE: 0.0707 - R^2 : 0.9996

Lectura de graficas - Distribucion del objetivo: se observa una concentracion principal y cola hacia valores altos, lo que explica algunos errores mas grandes. - Real vs predicho: los puntos se alinean cerca de la diagonal, indicando buen ajuste global. - Histograma de residuos: centrado en 0 y relativamente simetrico, sin sesgo fuerte. - Residuos vs prediccion: dispersion moderada; si hay abanico en valores altos, sugiere ligera heterocedasticidad.

Conclusion - El modelo lineal explica casi toda la variabilidad del objetivo y los errores son bajos. - No se observan patrones fuertes en residuos, por lo que el ajuste lineal es adecuado para este

conjunto.

8.2.9 Modelos de Regresión Lineal

```
[98]: lin_reg = LinearRegression()
lin_reg.fit(X_train_reg, y_train_reg)
pred_nopca = lin_reg.predict(X_test_reg)
resultados_reg.append(evaluar_regresion('Reg. Lineal Sin PCA', y_test_reg,
    ↪pred_nopca))
```

[Reg. Lineal Sin PCA] MAE: 0.05, RMSE: 0.07, R^2 : 0.9996

8.2.10 Modelos de Regresión Lineal

Entrenamos un modelo de Regresión Lineal con las **5 componentes principales** (calculadas sin incluir `area_mean` entre las features).

```
[99]: lin_reg_pca = LinearRegression()
lin_reg_pca.fit(X_train_reg_pca, y_train_reg)
pred_pca = lin_reg_pca.predict(X_test_reg_pca)
resultados_reg.append(evaluar_regresion('Reg. Lineal Con PCA', y_test_reg,
    ↪pred_pca))
```

[Reg. Lineal Con PCA] MAE: 0.55, RMSE: 0.74, R^2 : 0.9553

8.2.11 7.2.2 Regresión Ridge y Lasso

8.2.12 3.3 Ridge y Lasso Regression

Ahora extendemos el análisis de regresión con modelos regularizados. Ridge penaliza coeficientes grandes con una penalización cuadrática y Lasso puede llevar algunos coeficientes a cero, lo que ayuda a seleccionar variables.

Esto sigue la lógica de la clase: comparar una regresión lineal base con variantes regularizadas para ver cómo cambia el error.

```
[100]: file_path = "Cancer_Data.csv"
if not os.path.exists(file_path):
    file_path = "./Cancer_Data.csv"

df = pd.read_csv(file_path)
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↪inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)
df.columns = df.columns.str.replace('"', '').str.strip()
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)

if "id" in df.columns:
```

```

df = df.drop(columns=["id"])
if "Unnamed: 32" in df.columns:
    df = df.drop(columns=["Unnamed: 32"])

if "diagnosis" in df.columns:
    df["diagnosis"] = df["diagnosis"].map({"M": 1, "B": 0, "1": 1, "0": 0, 1: 0, 0: 1, 0: 0, "1.0": 1, "0.0": 0})

if "target_regression" not in globals():
    objetivos = ["area_mean", "radius_mean"]
    resultados_objetivos = []

    for objetivo in objetivos:
        X_tmp = df.drop(columns=[col for col in ["diagnosis", objetivo] if col in df.columns])
        y_tmp = df[objetivo]

        X_train_tmp, X_test_tmp, y_train_tmp, y_test_tmp = train_test_split(
            X_tmp, y_tmp, test_size=0.30, random_state=42
        )

        modelo_tmp = LinearRegression()
        modelo_tmp.fit(X_train_tmp, y_train_tmp)
        pred_tmp = modelo_tmp.predict(X_test_tmp)

        resultados_objetivos.append(evaluar_regresion(objetivo, y_test_tmp, pred_tmp))

    resultados_objetivos = pd.DataFrame(resultados_objetivos).sort_values("R2", ascending=False)
    target_regression = resultados_objetivos.iloc[0]["modelo"]

if "X_train_reg" not in globals():
    X_reg = df.drop(columns=[col for col in ["diagnosis", target_regression] if col in df.columns])
    y_reg = df[target_regression]

    X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
        X_reg, y_reg, test_size=0.30, random_state=42
    )

if "modelo_lineal" not in globals():
    modelo_lineal = LinearRegression()
    modelo_lineal.fit(X_train_reg, y_train_reg)
    pred_lineal = modelo_lineal.predict(X_test_reg)

alphas = [0.01, 1, 100]

```

```

if "resultados_regularizacion" not in globals() or not_
    resultados_regularizacion: resultados_regularizacion = []

for alpha in alphas:
    modelo_ridge = Pipeline([
        ("scaler", StandardScaler()),
        ("model", Ridge(alpha=alpha))
    ])
    modelo_ridge.fit(X_train_reg, y_train_reg)
    pred_ridge = modelo_ridge.predict(X_test_reg)
    resultados_regularizacion.append(evaluar_regresion(f"Ridge alpha={alpha}",_
    y_test_reg, pred_ridge))

    modelo_lasso = Pipeline([
        ("scaler", StandardScaler()),
        ("model", Lasso(alpha=alpha, max_iter=10000))
    ])
    modelo_lasso.fit(X_train_reg, y_train_reg)
    pred_lasso = modelo_lasso.predict(X_test_reg)
    resultados_regularizacion.append(evaluar_regresion(f"Lasso alpha={alpha}",_
    y_test_reg, pred_lasso))

comparacion_regularizacion = pd.DataFrame(resultados_regularizacion).
    sort_values("RMSE")
print("Comparación Ridge vs Lasso:")
display(comparacion_regularizacion)

plt.figure(figsize=(10, 5))
plt.bar(comparacion_regularizacion["modelo"],_
    comparacion_regularizacion["RMSE"])
plt.title("Comparación de RMSE para Ridge y Lasso")
plt.ylabel("RMSE")
plt.xticks(rotation=45)
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()
plt.show()

```


```

[Ridge alpha=0.01] MAE: 0.05, RMSE: 0.07, R2: 0.9996
[Lasso alpha=0.01] MAE: 0.05, RMSE: 0.08, R2: 0.9995
[Ridge alpha=1] MAE: 0.06, RMSE: 0.08, R2: 0.9995
[Lasso alpha=1] MAE: 0.79, RMSE: 0.99, R2: 0.9204
[Ridge alpha=100] MAE: 0.36, RMSE: 0.46, R2: 0.9827
[Lasso alpha=100] MAE: 2.78, RMSE: 3.50, R2: -0.0022
Comparación Ridge vs Lasso:

```

	objetivo	modelo	Modelo	MAE	MSE	
→ RMSE	R2	R ²				

0	Ridge alpha=0.01	Ridge alpha=0.01	Ridge alpha=0.01	0.045356	0.004854	0.
	0.069673	0.999602	0.999602			
2	Ridge alpha=1	Ridge alpha=1	Ridge alpha=1	0.058731	0.005924	0.
	0.076966	0.999515	0.999515			
1	Lasso alpha=0.01	Lasso alpha=0.01	Lasso alpha=0.01	0.053638	0.006217	0.
	0.078850	0.999491	0.999491			
4	Ridge alpha=100	Ridge alpha=100	Ridge alpha=100	0.356940	0.211370	0.
	0.459749	0.982687	0.982687			
3	Lasso alpha=1	Lasso alpha=1	Lasso alpha=1	0.788650	0.972446	0.
	0.986127	0.920350	0.920350			
5	Lasso alpha=100	Lasso alpha=100	Lasso alpha=100	2.777898	12.235386	3.
	0.497912	-0.002158	-0.002158			



8.2.13 7.2.3 Árbol de Regresión

8.2.14 Modelos de Árbol de Regresión

El árbol de regresión permite capturar relaciones no lineales entre las variables y el objetivo continuo. Igual que en la clase, luego compararemos distintas profundidades para observar señales de sobreajuste.

```
[101]: modelo_arbol_reg = DecisionTreeRegressor(max_depth=5, random_state=42)
modelo_arbol_reg.fit(X_train_reg, y_train_reg)
pred_arbol_reg = modelo_arbol_reg.predict(X_test_reg)

resultado_arbol_reg = evaluar_regresion("Árbol max_depth=5", y_test_reg,
pred_arbol_reg)
display(pd.DataFrame([resultado_arbol_reg]))
```

```

plt.figure(figsize=(22, 10))
plot_tree(
    modelo_arbol_reg,
    feature_names=X_reg.columns,
    filled=True,
    rounded=True,
    max_depth=3,
    fontsize=8
)
plt.title("Árbol de regresión - visualización parcial")
plt.show()

profundidades = [1, 2, 3, 4, 5, 8, 12, None]
resultados_arbol_reg = []

for profundidad in profundidades:
    arbol = DecisionTreeRegressor(max_depth=profundidad, random_state=42)
    arbol.fit(X_train_reg, y_train_reg)

    pred_train = arbol.predict(X_train_reg)
    pred_test = arbol.predict(X_test_reg)

    resultados_arbol_reg.append({
        "max_depth": str(profundidad),
        "RMSE_train": np.sqrt(mean_squared_error(y_train_reg, pred_train)),
        "RMSE_test": np.sqrt(mean_squared_error(y_test_reg, pred_test)),
        "R2_test": r2_score(y_test_reg, pred_test)
    })

df_arbol_reg = pd.DataFrame(resultados_arbol_reg)
print("Efecto de la profundidad del árbol en regresión:")
display(df_arbol_reg)


plt.figure(figsize=(9, 5))
plt.plot(df_arbol_reg["max_depth"], df_arbol_reg["RMSE_train"], marker="o",
        label="Train")
plt.plot(df_arbol_reg["max_depth"], df_arbol_reg["RMSE_test"], marker="o",
        label="Test")
plt.title("Efecto de max_depth en el árbol de regresión")
plt.xlabel("max_depth")
plt.ylabel("RMSE")
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()

```

[Árbol max_depth=5] MAE: 0.20, RMSE: 0.35, R^2 : 0.9899


	objetivo	modelo	Modelo	MAE	MSE	
↩	RMSE	R ²				
0	Árbol max_depth=5	Árbol max_depth=5	Árbol max_depth=5	0.203899	0.122906	↩
↩	0.35058	0.989933	0.989933			

Árbol de regresión - visualización parcial



Efecto de la profundidad del árbol en regresión:

	max_depth	RMSE_train	RMSE_test	R2_test
0	1	1.972192	1.985791	0.677013
1	2	1.197400	1.285317	0.864687
2	3	0.590064	0.690035	0.961000
3	4	0.306928	0.366208	0.989016
4	5	0.155641	0.350580	0.989933
5	8	0.025559	0.253083	0.994754
6	12	0.000819	0.239218	0.995313
7	None	0.000000	0.256184	0.994624



8.2.15 7.2.4 Random Forest para Regresión

8.2.16 Modelos de Random Forest

Los lineamientos también piden comparar Random Forest en regresión. Aquí lo usamos para predecir la variable continua seleccionada. A diferencia de la regresión lineal, Random Forest puede capturar relaciones no lineales, pero pierde interpretabilidad directa de coeficientes.

```
[102]: modelo_rf_reg = RandomForestRegressor(
        n_estimators=200,
        max_depth=8,
        random_state=42,
        n_jobs=-1
    )
    modelo_rf_reg.fit(X_train_reg, y_train_reg)
    pred_rf_reg = modelo_rf_reg.predict(X_test_reg)

    resultado_rf_reg = evaluar_regresion("Random Forest Regressor", y_test_reg,
    ↪ pred_rf_reg)
    display(pd.DataFrame([resultado_rf_reg]))

    importancias_rf_reg = pd.DataFrame({
        "variable": X_reg.columns,
        "importancia": modelo_rf_reg.feature_importances_
    }).sort_values("importancia", ascending=False).head(10)
```




```
plt.figure(figsize=(9, 5))
sns.barplot(data=importancias_rf_reg, x="importancia", y="variable",
            palette="crest")
plt.title("Importancia de variables - Random Forest Regressor")
plt.xlabel("Importancia")
plt.ylabel("Variable")
plt.tight_layout()
plt.show()

print("Lectura para exposicion:")
print("Random Forest Regressor ayuda a capturar relaciones no lineales. Si
mejora RMSE frente a modelos lineales, aporta capacidad predictiva; si no
mejora, los modelos lineales son suficientes y mas faciles de explicar.")
```

[Random Forest Regressor] MAE: 0.10, RMSE: 0.18, R^2 : 0.9973

	objetivo				modelo	Modelo
	MAE	MSE	RMSE	R^2	\	
0	Random Forest Regressor	Random Forest Regressor	Random Forest Regressor	Random Forest Regressor	0.	
	0.096266	0.033122	0.181994	0.997287		

R^2
0 0.997287



Lectura para exposicion:

Random Forest Regressor ayuda a capturar relaciones no lineales. Si mejora RMSE frente a modelos lineales, aporta capacidad predictiva; si no mejora, los modelos lineales son suficientes y mas faciles de explicar.

8.2.17 7.2.5 Comparación y Conclusión de Modelos de Regresión

8.2.18 3.6 Comparacion final de modelos

Comparamos la regresion lineal, Ridge, Lasso, el arbol de regresion y Random Forest Regressor usando las mismas metricas. Esta tabla resume que modelo se ajusta mejor al objetivo continuo seleccionado y cual conserva un mejor equilibrio entre error, estabilidad e interpretabilidad.

```
[103]: mejor_ridge = comparacion_regularizacion[comparacion_regularizacion["modelo"].
↳str.startswith("Ridge")].sort_values("RMSE").iloc[0]
mejor_lasso = comparacion_regularizacion[comparacion_regularizacion["modelo"].
↳str.startswith("Lasso")].sort_values("RMSE").iloc[0]

modelos_regresion = [
    evaluar_regresion("Regresion lineal", y_test_reg, pred_lineal),
    resultado_arbol_reg,
    mejor_ridge.to_dict(),
    mejor_lasso.to_dict()
]

if "resultado_rf_reg" in globals():
    modelos_regresion.append(resultado_rf_reg)

resultados_finales_reg = pd.DataFrame(modelos_regresion)
resultados_finales_reg = resultados_finales_reg.sort_values("RMSE").
↳reset_index(drop=True)
print("Comparacion final de modelos de regresion:")
display(resultados_finales_reg)

plt.figure(figsize=(9, 5))
plt.bar(resultados_finales_reg["modelo"], resultados_finales_reg["RMSE"])
plt.title("Comparacion de RMSE por modelo")
plt.ylabel("RMSE")
plt.xticks(rotation=30)
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()
plt.show()

plt.figure(figsize=(9, 5))
plt.bar(resultados_finales_reg["modelo"], resultados_finales_reg["R2"])
plt.title("Comparacion de R2 por modelo")
plt.ylabel("R2")
plt.xticks(rotation=30)
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()
plt.show()
```

[Regresion lineal] MAE: 0.05, RMSE: 0.07, R^2 : 0.9996
Comparacion final de modelos de regresion:

	objetivo			modelo	Modelo	
	MAE	MSE	RMSE	R2 \		
0		Ridge alpha=0.01		Ridge alpha=0.01	Ridge alpha=0.01	0.
	0.045356	0.004854	0.069673	0.999602		
1		Regresion lineal		Regresion lineal	Regresion lineal	0.
	0.045611	0.004922	0.070156	0.999597		
2		Lasso alpha=0.01		Lasso alpha=0.01	Lasso alpha=0.01	0.
	0.053638	0.006217	0.078850	0.999491		
3		Random Forest Regressor		Random Forest Regressor	Random Forest Regressor	0.
	0.096266	0.033122	0.181994	0.997287		
4		Árbol max_depth=5		Árbol max_depth=5	Árbol max_depth=5	0.
	0.203899	0.122906	0.350580	0.989933		

R²


0 0.999602


1 0.999597

2 0.999491

3 0.997287

4 0.989933





8.2.19 3.7 Conclusion tecnica de regresion

Con esta ampliacion, el notebook sigue la logica de la clase y de los lineamientos: regresion lineal base, modelos regularizados, arbol de regresion y Random Forest Regressor.

La recomendacion final debe basarse en el mejor equilibrio entre error y estabilidad. Si Random Forest reduce el RMSE, puede ser una buena opcion predictiva porque captura relaciones no lineales. Si la diferencia es pequena, conviene preferir un modelo lineal o regularizado porque se explica con mayor facilidad. Si el arbol mejora en entrenamiento pero pierde en prueba, hay senal de sobreajuste.

9 8. Modelos No Supervisados

Aplicación de técnicas de aprendizaje no supervisado sobre el dataset.

9.1 8.1 PCA (Análisis de Componentes Principales)

Reducción de dimensionalidad aplicada a los datos de cáncer de mama.

9.1.1 Modelos de Árbol de Decisión

9.1.2 Arbol de Decision y Analisis de Componentes Principales (PCA)

Este notebook organiza y compara el rendimiento de un Arbol de Decision con y sin PCA (5 componentes) para clasificar el diagnostico de cancer.

Estructura del Documento: 1. **PCA (5 Componentes)** - Loadings (Grafica de barras) - Biplot (Observaciones y variables) - Scree Plot 2. **Modelado y Evaluacion** - Preparacion de datos, escalado y PCA - Ajuste de hiperparametros priorizando Recall - Comparacion de metricas

(sin PCA vs con PCA) 3. **Matrices de Confusion** - Analisis de falsos positivos y falsos negativos
4. **Interpretabilidad** - Importancia de variables y visualizacion del arbol 5. **Conclusiones**

```
[104]: warnings.filterwarnings('ignore')
```

```
sns.set_theme(style="whitegrid")
```

```
[105]: # Carga y limpieza de datos
df = pd.read_csv('Cancer_Data.csv')
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↪inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)
if 'Unnamed: 32' in df.columns:
    df = df.drop('Unnamed: 32', axis=1)
if 'id' in df.columns:
    df = df.drop('id', axis=1)

# Limpiar nombres de columna: eliminar espacios y comillas dobles
df.columns = df.columns.str.strip().str.replace('\\"', '')

# Limpiar y codificar la variable objetivo (M: 1, B: 0)
df['diagnosis'] = df['diagnosis'].astype(str).str.strip().str.upper()
df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0, '1': 1, '0': 0, 1: 1, 0:
    ↪0, '1.0': 1, '0.0': 0})

X = df.drop('diagnosis', axis=1)
y = df['diagnosis']

# Split de datos
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# Escalado (necesario para PCA; en arboles no es obligatorio, pero lo usamos
    ↪para consistencia)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

print('Datos cargados y escalados con exito.')
```

Datos cargados y escalados con exito.

9.1.3 Análisis de Componentes Principales (PCA)

```
[106]: # Aplicacion de PCA con 5 componentes
pca = PCA(n_components=5, random_state=42)
X_train_pca = pca.fit_transform(X_train_scaled)
X_test_pca = pca.transform(X_test_scaled)
```

9.1.4 1.1 Loadings (Grafica de Barras)

Analizamos que variables originales tienen mayor peso en las componentes principales.


```
[107]: loadings = pd.DataFrame(
    pca.components_.T,
    columns=[f'PC{i+1}' for i in range(5)],
    index=X.columns
)

fig, axes = plt.subplots(3, 2, figsize=(18, 18))
axes = axes.flatten()

for i in range(5):
    pc_name = f'PC{i+1}'
    top_pc_loadings = loadings[pc_name].abs().sort_values(ascending=False).
    ↪head(10).index
    sns.barplot(
        x=loadings.loc[top_pc_loadings, pc_name],
        y=top_pc_loadings,
        palette='viridis',
        ax=axes[i]
    )
    axes[i].set_title(f'Loadings de {pc_name} (Top 10 Variables)')

if len(axes) > 5:
    fig.delaxes(axes[5])

plt.tight_layout()
plt.show()
```



Representación Biplot (PC1 vs PC2) Proyectamos observaciones y variables en el espacio de PC1 vs PC2.

```
[108]: top_pc1 = loadings['PC1'].abs().sort_values(ascending=False).head(6).index
top_pc2 = loadings['PC2'].abs().sort_values(ascending=False).head(6).index
top_vars = list(set(top_pc1).union(set(top_pc2)))
coeff_subset = pca.components_.T[X.columns.get_indexer(top_vars)]

biplot(X_train_pca, coeff_subset, labels=top_vars)
```




Gráfico de Sedimentación (Scree Plot) Graficamos la varianza explicada por cada una de las 5 componentes y su varianza acumulada.


```
[109]: explained_variance = pca.explained_variance_ratio_
        cumulative_variance = np.cumsum(explained_variance)

        plt.figure(figsize=(8, 5))
        bars = plt.bar(range(1, 6), explained_variance, alpha=0.7, align='center',
            ↳label='Varianza individual', color='skyblue')
        plt.step(range(1, 6), cumulative_variance, where='mid', label='Varianza
            ↳acumulada', color='red', marker='o')

        for bar in bars:
            yval = bar.get_height()
            plt.text(bar.get_x() + bar.get_width() / 2, yval + 0.01, f'{yval:.2%}',
                ↳ha='center', va='bottom', fontsize=9)
```



```
plt.ylabel('Ratio de Varianza Explicada')
plt.xlabel('Componentes Principales')
plt.xticks(range(1, 6))
plt.title('Scree Plot (Varianza Explicada por 5 Componentes)')
plt.legend(loc='center right')
plt.ylim(0, 1.1)
plt.show()
```



2. Modelado y Evaluacion Ajustamos hiperparametros priorizando **Recall** (evitar falsos negativos). Despues revisamos el **F1-Score** como balance entre precision y recall.

9.1.5 KNN y Análisis de Componentes Principales (PCA)

Este notebook organiza y compara el rendimiento del modelo K-Nearest Neighbors (KNN) con y sin PCA (5 componentes).

Estructura del Documento: 1. **PCA (5 Componentes)** - Loadings (Gráfica de barras) - Biplot (Observaciones y variables) - Scree Plot 2. **Evaluación de Rendimiento** - Comparación base: Variables escaladas vs. sin escalar. - Evolución de métricas (Accuracy, Precision, Recall, F1-Score) iterando sobre K (Sin PCA vs Con PCA). 3. **Matrices de Confusión** - Resultados detallados de falsos positivos y negativos.

```
[110]: warnings.filterwarnings('ignore')

sns.set_theme(style="whitegrid")
```

```
[111]: # Carga y Limpieza de datos
df = pd.read_csv('Cancer_Data.csv')
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↪inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)
if 'Unnamed: 32' in df.columns:
    df = df.drop('Unnamed: 32', axis=1)
if 'id' in df.columns:
    df = df.drop('id', axis=1)

# Limpiar nombres de columna: eliminar espacios y comillas dobles
df.columns = df.columns.str.strip().str.replace('"', '')

# Limpiar valores de la columna 'diagnosis' y codificarlos (M: 1, B: 0)
df['diagnosis'] = df['diagnosis'].astype(str).str.strip().str.upper()
df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0, '1': 1, '0': 0, 1: 1, 0:
    ↪0, '1.0': 1, '0.0': 0})

X = df.drop('diagnosis', axis=1)
y = df['diagnosis']

# Split de datos
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
    ↪random_state=42, stratify=y)

# Escalado general de los datos
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
print("Datos cargados y escalados con éxito.")
```

Datos cargados y escalados con éxito.

9.1.6 Análisis de Componentes Principales (PCA)

```
[112]: # Aplicación de PCA con 5 componentes
pca = PCA(n_components=5, random_state=42)
X_train_pca = pca.fit_transform(X_train_scaled)
X_test_pca = pca.transform(X_test_scaled)
```

Análisis de Loadings (Cargas de Componentes) Analizamos qué variables originales tienen mayor peso o aporte en la formación de la primera (PC1) y segunda (PC2) componente principal.


```
[113]: loadings = pd.DataFrame(pca.components_.T, columns=[f'PC{i+1}' for i in
    ↪range(5)], index=X.columns)

fig, axes = plt.subplots(3, 2, figsize=(18, 18)) # Create 3 rows, 2 columns for
    ↪5 plots + 1 empty
axes = axes.flatten() # Flatten the array of axes for easy iteration

for i in range(5):
    pc_name = f'PC{i+1}'
    top_pc_loadings = loadings[pc_name].abs().sort_values(ascending=False).
    ↪head(10).index
    sns.barplot(x=loadings.loc[top_pc_loadings, pc_name], y=top_pc_loadings,
    ↪palette='viridis', ax=axes[i])
    axes[i].set_title(f'Loadings de {pc_name} (Top 10 Variables)')

# Hide the unused 6th subplot if there are only 5 components
if len(axes) > 5:
    fig.delaxes(axes[5])

plt.tight_layout()
plt.show()
```



Representación Biplot (PC1 vs PC2) Proyectamos observaciones y variables en el espacio de PC1 vs PC2.

```
[114]: top_vars = list(set(top_pc1).union(set(top_pc2)))
coeff_subset = pca.components_.T[X.columns.get_indexer(top_vars)]
biplot(X_train_pca, coeff_subset, labels=top_vars)
```





Gráfico de Sedimentación (Scree Plot) Graficamos la varianza explicada por cada una de las 5 componentes y su varianza acumulada.

```
[115]: explained_variance = pca.explained_variance_ratio_
        cumulative_variance = np.cumsum(explained_variance)

        plt.figure(figsize=(8, 5))
        bars = plt.bar(range(1, 6), explained_variance, alpha=0.7, align='center',
            ↳label='Varianza individual', color='skyblue')
        plt.step(range(1, 6), cumulative_variance, where='mid', label='Varianza
            ↳acumulada', color='red', marker='o')

        for bar in bars:
            yval = bar.get_height()
            plt.text(bar.get_x() + bar.get_width()/2, yval + 0.01, f'{yval:.2%}',
            ↳ha='center', va='bottom', fontsize=9)
```

```
plt.ylabel('Ratio de Varianza Explicada')
plt.xlabel('Componentes Principales')
plt.xticks(range(1, 6))
plt.title('Scree Plot (Varianza Explicada por 5 Componentes)')
plt.legend(loc='center right')
plt.ylim(0, 1.1)
plt.show()
```



9.1.7 Evaluación de Rendimiento

9.1.8 7. Escalado y PCA: seleccion estandarizada de componentes

PCA requiere escalado. Ajustamos un PCA completo para observar la varianza explicada acumulada, pero para este proyecto usamos **exactamente 5 componentes** en Random Forest con PCA.


La razon es metodologica: Arbol de Decision, KNN y Regresion ya usan PCA con 5 componentes. Mantener el mismo numero permite comparar los modelos bajo una reduccion de dimensionalidad equivalente, sin que Random Forest tenga ventaja por usar mas informacion comprimida.

```
[116]: plt.figure(figsize=(8, 5))
plt.plot(range(1, len(varianza_acum) + 1), varianza_acum, marker="o")
```

```

plt.axhline(umbral_referencia, color="red", linestyle="--", label=f"Referencia_{int(umbral_referencia*100)}%")
plt.axvline(k, color="green", linestyle="--", label=f"Componentes usadas = {k}")
plt.title("Varianza explicada acumulada")
plt.xlabel("Numero de componentes")
plt.ylabel("Varianza acumulada")
plt.legend()
plt.grid(True)
plt.show()

```




```

[117]: explained = varianza
cumulative = varianza_acum

plt.figure(figsize=(8, 5))
plt.bar(range(1, len(explained) + 1), explained, alpha=0.7, label="Varianza_{individual", color="#72B7B2")
plt.step(range(1, len(cumulative) + 1), cumulative, where="mid", label="Varianza acumulada", color="#E45756", marker="o")
plt.title("Scree Plot - PCA")
plt.xlabel("Componentes principales")
plt.ylabel("Varianza explicada")
plt.ylim(0, 1.1)

```

```
plt.legend()
plt.grid(True)
plt.show()
```



```
[118]: loadings = pd.DataFrame(
    pca_full.components_.T,
    columns=[f"PC{i+1}" for i in range(pca_full.components_.shape[0])],
    index=X.columns
)

top_pc1 = loadings["PC1"].abs().sort_values(ascending=False).head(10).index
top_pc2 = loadings["PC2"].abs().sort_values(ascending=False).head(10).index

fig, axes = plt.subplots(1, 2, figsize=(12, 5))

sns.barplot(x=loadings.loc[top_pc1, "PC1"], y=top_pc1, ax=axes[0],
            palette="viridis")
axes[0].set_title("Loadings PC1 (Top 10)")
axes[0].set_xlabel("Peso")
axes[0].set_ylabel("Variable")
```




```

sns.barplot(x=loadings.loc[top_pc2, "PC2"], y=top_pc2, ax=axes[1],
            palette="viridis")
axes[1].set_title("Loadings PC2 (Top 10)")
axes[1].set_xlabel("Peso")
axes[1].set_ylabel("Variable")

plt.tight_layout()
plt.show()

```



9.1.9 Modelos de Random Forest

Transformamos los datos a **5 componentes principales** y entrenamos un Random Forest con los mismos parametros base. Esta decision estandariza la comparacion con Arbol de Decision, KNN y Regresion, que tambien trabajan con PCA de 5 componentes.

```

[119]: pca = PCA(n_components=k, random_state=42)
X_train_pca = pca.fit_transform(X_train_scaled)
X_test_pca = pca.transform(X_test_scaled)

rf_pca = RandomForestClassifier(
    n_estimators=200,
    random_state=42,
    n_jobs=-1
)


rf_pca.fit(X_train_pca, y_train)
y_pred_pca = rf_pca.predict(X_test_pca)

print(f"Random Forest con PCA entrenado usando {k} componentes.")
print(f"Varianza retenida por esas {k} componentes: {pca.
    explained_variance_ratio_.sum():.4f}")

```

Random Forest con PCA entrenado usando 30 componentes.
Varianza retenida por esas 30 componentes: 1.0000

```
[120]: plt.figure(figsize=(7, 5))
scatter = plt.scatter(
    X_train_pca[:, 0],
    X_train_pca[:, 1],
    c=y_train,
    cmap="coolwarm",
    alpha=0.7
)
plt.title("PCA: PC1 vs PC2 (datos de entrenamiento)")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.legend(*scatter.legend_elements(), title="Diagnostico")
plt.grid(True)
plt.show()
```



9.1.10 9. Evaluacion del modelo con PCA

Repetimos las metricas y la matriz de confusion para comparar con el modelo sin PCA.

```
[121]: metricas_pca = evaluar_clasificacion(y_test, y_pred_pca)
```

```
pd.DataFrame([metricas_pca], index=["Random Forest con PCA (5 comp)"])
```

```
[121]:
```

	modelo	accuracy	precision	recall	f1
Random Forest con PCA (5 comp)	Modelo	0.938596	0.906977	0.928571	0.917647

```
[122]: print(classification_report(y_test, y_pred_pca, target_names=["Benigno",  
↪ "Maligno"]))
```

```
cm_pca = confusion_matrix(y_test, y_pred_pca)
```

```
plt.figure(figsize=(4.5, 4))
```

```
sns.heatmap(cm_pca, annot=True, fmt="d", cmap="Greens", cbar=False,  
            xticklabels=["Benigno", "Maligno"],  
            yticklabels=["Benigno", "Maligno"])
```


```
plt.title("Matriz de confusion - Con PCA")
```

```
plt.xlabel("Prediccion")
```

```
plt.ylabel("Real")
```

```
plt.show()
```

	precision	recall	f1-score	support
Benigno	0.96	0.94	0.95	72
Maligno	0.91	0.93	0.92	42
accuracy			0.94	114
macro avg	0.93	0.94	0.93	114
weighted avg	0.94	0.94	0.94	114



```
[123]: varianza_df = pd.DataFrame({
    "Componente": [f"PC{i+1}" for i in range(len(varianza))],
    "Varianza Individual": varianza,
    "Varianza Acumulada": varianza_acum,
    "Varianza Individual (%)": (varianza * 100).round(2),
    "Varianza Acumulada (%)": (varianza_acum * 100).round(2)
})

print("VARIANZA DE CADA COMPONENTE PRINCIPAL:\n")
print(varianza_df.to_string(index=False))
print(f"\nComponentes usadas en esta comparacion: {k}")
print(f"Varianza acumulada en {k} componentes: {varianza_acum[k-1]*100:.2f}%")
```

VARIANZA DE CADA COMPONENTE PRINCIPAL:

Componente	Varianza Individual	Varianza Acumulada	Varianza Individual (%)
PC1	0.436925	0.436925	43.69
PC2	0.192264	0.629189	19.23
PC3	0.097447	0.726636	9.74

79.33	PC4	0.066703	0.793339	6.67
84.94	PC5	0.056063	0.849402	5.61
88.99	PC6	0.040518	0.889920	4.05
91.17	PC7	0.021751	0.911671	2.18
92.75	PC8	0.015829	0.927500	1.58
94.02	PC9	0.012729	0.940229	1.27
95.21	PC10	0.011881	0.952111	1.19
96.24	PC11	0.010271	0.962382	1.03
97.18	PC12	0.009430	0.971812	0.94
97.96	PC13	0.007774	0.979585	0.78
98.42	PC14	0.004598	0.984183	0.46
98.73	PC15	0.003140	0.987324	0.31
98.98	PC16	0.002485	0.989808	0.25
99.18	PC17	0.002003	0.991812	0.20
99.35	PC18	0.001676	0.993488	0.17
99.49	PC19	0.001436	0.994923	0.14
99.60	PC20	0.001102	0.996025	0.11
99.69	PC21	0.000920	0.996945	0.09
99.77	PC22	0.000789	0.997734	0.08
99.84	PC23	0.000644	0.998378	0.06
99.89	PC24	0.000568	0.998946	0.06
99.94	PC25	0.000493	0.999439	0.05
99.97	PC26	0.000282	0.999721	0.03
99.99	PC27	0.000202	0.999923	0.02

PC28	0.000046	0.999969	0.00
100.00			
PC29	0.000027	0.999996	0.00
100.00			
PC30	0.000004	1.000000	0.00
100.00			

Componentes usadas en esta comparacion: 30
 Varianza acumulada en 30 componentes: 100.00%

```
[124]: print("RESUMEN DE VARIANZA PCA (primeros 15 componentes):\n")
print(varianza_df.head(15).to_string(index=False))
print(f"\n... (total de {len(varianza)} componentes)")
print(f"\nComponentes usadas para estandarizar la comparacion: {k}")
print(f"Varianza acumulada en {k} componentes: {varianza_acum[k-1]*100:.2f}%")
```

RESUMEN DE VARIANZA PCA (primeros 15 componentes):

Componente	Varianza Individual	Varianza Acumulada	Varianza Individual (%)
PC1	0.436925	0.436925	43.69
PC2	0.192264	0.629189	19.23
PC3	0.097447	0.726636	9.74
PC4	0.066703	0.793339	6.67
PC5	0.056063	0.849402	5.61
PC6	0.040518	0.889920	4.05
PC7	0.021751	0.911671	2.18
PC8	0.015829	0.927500	1.58
PC9	0.012729	0.940229	1.27
PC10	0.011881	0.952111	1.19
PC11	0.010271	0.962382	1.03
PC12	0.009430	0.971812	0.94
PC13	0.007774	0.979585	0.78
PC14	0.004598	0.984183	0.46

PC15	0.003140	0.987324	0.31
98.73			

... (total de 30 componentes)

Componentes usadas para estandarizar la comparacion: 30

Varianza acumulada en 30 componentes: 100.00%

9.1.11 Regresión con PCA

9.1.12 Regresión y Análisis de Componentes Principales (PCA)

Este notebook organiza y compara el rendimiento de los modelos de Regresión (Logística y Lineal) con y sin PCA (5 componentes).

Estructura del Documento: 1. **PCA (5 Componentes)** - Loadings (Gráfica de barras) - Biplot (Observaciones y variables) - Scree Plot 2. **Regresión Logística** - Sin PCA · Con PCA · Comparación de métricas · Matrices de Confusión 3. **Regresión Lineal** - Sin PCA · Con PCA · Comparación de métricas · Gráficas Real vs Predicho

```
[125]: warnings.filterwarnings('ignore')
```

```
sns.set_theme(style="whitegrid")
```

```
[126]: # Carga y Limpieza de datos
df = pd.read_csv('Cancer_Data.csv')
df.columns = df.columns.str.replace('"', '').str.strip()
if 'id' in df.columns: df.drop('id', axis=1, errors='ignore', inplace=True)
if 'Unnamed: 32' in df.columns: df.drop('Unnamed: 32', axis=1, errors='ignore',
    ↪inplace=True)
df = df.map(lambda x: x.strip() if isinstance(x, str) else x)
if 'Unnamed: 32' in df.columns:
    df = df.drop('Unnamed: 32', axis=1)
if 'id' in df.columns:
    df = df.drop('id', axis=1)

# Limpiar nombres de columna: eliminar espacios y comillas dobles
df.columns = df.columns.str.strip().str.replace('"', '')

# Limpiar valores de la columna 'diagnosis' y codificarlos (M: 1, B: 0)
df['diagnosis'] = df['diagnosis'].astype(str).str.strip().str.upper()
df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0, '1': 1, '0': 0, 1: 1, 0:
    ↪0, '1.0': 1, '0.0': 0})

X = df.drop('diagnosis', axis=1)
y = df['diagnosis']

# Split de datos
X_train, X_test, y_train, y_test = train_test_split(
```

```

    X, y, test_size=0.2, random_state=42, stratify=y
)

# Escalado general de los datos
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
print("Datos cargados y escalados con éxito.")

```

Datos cargados y escalados con éxito.

9.1.13 Análisis de Componentes Principales (PCA)

```

[127]: # Aplicación de PCA con 5 componentes
pca = PCA(n_components=5, random_state=42)
X_train_pca = pca.fit_transform(X_train_scaled)
X_test_pca = pca.transform(X_test_scaled)

```


Análisis de Loadings (Cargas de Componentes) Analizamos qué variables originales tienen mayor peso o aporte en la formación de la primera (PC1) y segunda (PC2) componente principal.

```

[128]: feature_names = X.columns.tolist()
loadings = pd.DataFrame(
    pca.components_.T,
    index=feature_names,
    columns=[f'PC{i+1}' for i in range(5)]
)

fig, axes = plt.subplots(1, 2, figsize=(18, 7))
for i, pc in enumerate(['PC1', 'PC2']):
    sorted_loadings = loadings[pc].sort_values()
    colors = ['red' if v < 0 else 'steelblue' for v in sorted_loadings]
    axes[i].barh(sorted_loadings.index, sorted_loadings.values, color=colors)
    axes[i].axvline(0, color='black', linewidth=0.8)
    axes[i].set_title(f'Loadings - {pc}', fontsize=14)
    axes[i].set_xlabel('Peso (Loading)', fontsize=12)
plt.tight_layout()
plt.show()

```





Representación Biplot (PC1 vs PC2) Proyectamos observaciones y variables en el espacio de PC1 vs PC2.

```
[129]: fig, ax = plt.subplots(figsize=(12, 10))
scatter = ax.scatter(
    X_train_pca[:, 0], X_train_pca[:, 1],
    c=y_train, cmap='coolwarm', alpha=0.6, s=40, label='Observaciones'
)
plt.colorbar(scatter, ax=ax, label='Diagnóstico (0=B, 1=M)')
scale = 3
for i, feature in enumerate(feature_names):
    ax.annotate('', xy=(pca.components_[0, i]*scale, pca.components_[1, i]*scale),
        xytext=(0, 0), arrowprops=dict(arrowstyle='->', color='black', lw=1.2))
    ax.text(pca.components_[0, i]*scale*1.1, pca.components_[1, i]*scale*1.1,
        feature, fontsize=7, ha='center')
ax.set_xlabel(f'PC1 ({pca.explained_variance_ratio_[0]:.1%} var.)', fontsize=12)
ax.set_ylabel(f'PC2 ({pca.explained_variance_ratio_[1]:.1%} var.)', fontsize=12)
ax.set_title('Biplot PCA (PC1 vs PC2)', fontsize=14)
ax.axhline(0, color='grey', lw=0.5, ls='--')
ax.axvline(0, color='grey', lw=0.5, ls='--')
plt.tight_layout()
plt.show()
```



```
plt.xticks(range(1, 6))
plt.title('Scree Plot (Varianza Explicada por 5 Componentes)')
plt.legend(loc='center right')
plt.ylim(0, 1.1)
plt.show()
```



2. Regresión Logística Aplicamos Regresión Logística para predecir **diagnosis** (Maligno / Benigno).

Utilizamos un **Pipeline** que primero escala los datos (**StandardScaler**) y luego aplica el modelo. Esto previene el **Data Leakage** ya que el escalador se ajusta solo con los datos de entrenamiento.

9.2 8.2 Clustering (KMeans, Jerárquico, DBSCAN)

9.2.1 Modelos de Aprendizaje No Supervisado (Clustering)

El clustering busca grupos sin mirar la etiqueta **diagnosis**. Esto es muy útil como pregunta exploratoria: si el diagnóstico no existiera, ¿las mediciones del tumor formarían grupos parecidos a benigno y maligno?

Usaremos tres enfoques:

- **KMeans:** crea grupos compactos alrededor de centros.

- **Clustering jerarquico:** construye una especie de arbol de similitudes entre pacientes.
- **DBSCAN:** busca zonas densas y puede marcar casos raros como ruido.

Antes de agrupar, escalamos las variables porque muchas estan en unidades distintas. Tambien usamos PCA de dos componentes para visualizar los pacientes en un plano.

```
[131]: scaler_cluster = StandardScaler()
X_scaled_cluster = scaler_cluster.fit_transform(X_cancer)


pca_2d = PCA(n_components=2, random_state=42)
X_pca_2d = pca_2d.fit_transform(X_scaled_cluster)

pca_plot_df = pd.DataFrame({
    "PC1": X_pca_2d[:, 0],
    "PC2": X_pca_2d[:, 1],
    "Diagnostico": y_labels
})

plt.figure(figsize=(8, 6))
sns.scatterplot(data=pca_plot_df, x="PC1", y="PC2", hue="Diagnostico", alpha=0.
↪85)

plt.title("Vista PCA 2D coloreada por diagnostico real")
plt.xlabel(f"PC1 ({pca_2d.explained_variance_ratio_[0]:.1%} de varianza)")
plt.ylabel(f"PC2 ({pca_2d.explained_variance_ratio_[1]:.1%} de varianza)")
plt.show()

print("Lectura para exposicion:")
print("PCA comprime las variables originales en dos ejes. Si benignos y
↪malignos quedan separados visualmente, hay senales fuertes en las mediciones
↪del tumor.")
```



Lectura para exposicion:

PCA comprime las variables originales en dos ejes. Si benignos y malignos quedan separados visualmente, hay senales fuertes en las mediciones del tumor.

```
[132]: k_values = range(2, 9)
inertias = []
silhouettes = []

for k in k_values:
    km = KMeans(n_clusters=k, random_state=42, n_init=20)
    labels_k = km.fit_predict(X_scaled_cluster)
    inertias.append(km.inertia_)
    silhouettes.append(silhouette_score(X_scaled_cluster, labels_k))


fig, axes = plt.subplots(1, 2, figsize=(13, 4))
axes[0].plot(list(k_values), inertias, marker="o")
axes[0].set_title("Metodo del codo para KMeans")
axes[0].set_xlabel("Numero de clusters k")
axes[0].set_ylabel("Inercia")
```

```

axes[1].plot(list(k_values), silhouettes, marker="o", color="darkgreen")
axes[1].set_title("Silhouette por numero de clusters")
axes[1].set_xlabel("Numero de clusters k")
axes[1].set_ylabel("Silhouette")
plt.show()

k_sugerido = list(k_values)[int(np.argmax(silhouettes))]
print(f"El mayor Silhouette en esta busqueda aparece con k={k_sugerido}.")
print("Como el problema medico tiene dos diagnosticos principales, tambien_
↪evaluaremos k=2 para contrastarlo con benigno/maligno.")

```



El mayor Silhouette en esta busqueda aparece con k=2.
 Como el problema medico tiene dos diagnosticos principales, tambien evaluaremos k=2 para contrastarlo con benigno/maligno.

```

[133]: def evaluar_clusters(nombre, labels, X_eval, y_ref):
    labels = np.asarray(labels)
    clusters_validos = [c for c in np.unique(labels) if c != -1]
    n_clusters = len(clusters_validos)
    ruido = int(np.sum(labels == -1))

    if n_clusters >= 2:
        mask = labels != -1
        sil = silhouette_score(X_eval[mask], labels[mask]) if mask.sum() > 0
    ↪n_clusters else np.nan
    else:
        sil = np.nan

    ari = adjusted_rand_score(y_ref, labels)
    return {
        "Metodo": nombre,
        "Clusters": n_clusters,
        "Casos_ruido": ruido,

```

```

        "Silhouette": sil,
        "ARI_vs_diagnostico": ari
    }

kmeans_2 = KMeans(n_clusters=2, random_state=42, n_init=20)
labels_kmeans = kmeans_2.fit_predict(X_scaled_cluster)

jerarquico_2 = AgglomerativeClustering(n_clusters=2, linkage="ward")
labels_jerarquico = jerarquico_2.fit_predict(X_scaled_cluster)

eps_grid = np.arange(1.5, 6.1, 0.25)
dbscan_candidates = []
for eps in eps_grid:
    db = DBSCAN(eps=float(eps), min_samples=5)
    labels_db = db.fit_predict(X_scaled_cluster)
    result = evaluar_clusters(f"DBSCAN eps={eps:.2f}", labels_db,
    ↪X_scaled_cluster, y_cancer)
    result["eps"] = eps
    result["labels"] = labels_db
    if result["Clusters"] >= 2:
        dbscan_candidates.append(result)

if dbscan_candidates:
    best_dbscan = max(dbscan_candidates, key=lambda d: -999 if pd.
    ↪isna(d["Silhouette"]) else d["Silhouette"])
    labels_dbscan = best_dbscan["labels"]
    dbscan_name = f"DBSCAN eps={best_dbscan['eps']:.2f}"
else:
    labels_dbscan = DBSCAN(eps=3.0, min_samples=5).fit_predict(X_scaled_cluster)
    dbscan_name = "DBSCAN eps=3.00"

cluster_results = pd.DataFrame([
    evaluar_clusters("KMeans k=2", labels_kmeans, X_scaled_cluster, y_cancer),
    evaluar_clusters("Jerarquico Ward k=2", labels_jerarquico,
    ↪X_scaled_cluster, y_cancer),
    evaluar_clusters(dbscan_name, labels_dbscan, X_scaled_cluster, y_cancer),
])

display(cluster_results.round(4))

print("Como leer la tabla:")
print("Silhouette cerca de 1 indica grupos bien separados. ARI compara los
    ↪clusters con el diagnostico real: 1 seria coincidencia perfecta, 0 seria
    ↪parecido al azar.")
print("En clustering, el diagnostico no se usa para entrenar; se usa al final
    ↪como espejo para interpretar.")

```

	Metodo	Clusters	Casos_ruido	Silhouette	ARI_vs_diagnostico
0	KMeans k=2	2	0	0.3450	0.6707
1	Jerarquico Ward k=2	2	0	0.3394	0.5750
2	DBSCAN eps=2.25	4	293	0.1619	0.2267

Como leer la tabla:


Silhouette cerca de 1 indica grupos bien separados. ARI compara los clusters con el diagnostico real: 1 seria coincidencia perfecta, 0 seria parecido al azar. En clustering, el diagnostico no se usa para entrenar; se usa al final como espejo para interpretar.

```
[134]: fig, axes = plt.subplots(1, 3, figsize=(16, 4.8))
cluster_maps = [
    ("KMeans k=2", labels_kmeans),
    ("Jerarquico Ward k=2", labels_jerarquico),
    (dbscan_name, labels_dbscan),
]

for ax, (title, labels) in zip(axes, cluster_maps):
    plot_df = pd.DataFrame({"PC1": X_pca_2d[:, 0], "PC2": X_pca_2d[:, 1],
    ↪ "Cluster": labels.astype(str)})
    sns.scatterplot(data=plot_df, x="PC1", y="PC2", hue="Cluster", ax=ax,
    ↪ alpha=0.85, legend=False)
    ax.set_title(title)
    ax.set_xlabel("PC1")
    ax.set_ylabel("PC2")

plt.suptitle("Comparacion visual de clusters sobre el plano PCA", y=1.03)
plt.tight_layout()
plt.show()
```

Comparacion visual de clusters sobre el plano PCA



```
[135]: sample_size = min(80, X_scaled_cluster.shape[0])
rng = np.random.default_rng(42)
sample_idx = rng.choice(X_scaled_cluster.shape[0], size=sample_size,
    ↪ replace=False)
```




```

Z = linkage(X_scaled_cluster[sample_idx], method="ward")
plt.figure(figsize=(14, 5))
dendrogram(Z, no_labels=True, color_threshold=None)
plt.title("Dendrograma jerarquico sobre una muestra de pacientes")
plt.xlabel("Pacientes de la muestra")
plt.ylabel("Distancia")
plt.show()

print("Lectura para exposicion:")
print("El dendrograma muestra como los pacientes se van uniendo por similitud.┐
└Cortar el arbol en cierta altura equivale a decidir cuantos grupos queremos┐
└formar." )

```



Lectura para exposicion:

El dendrograma muestra como los pacientes se van uniendo por similitud. Cortar el arbol en cierta altura equivale a decidir cuantos grupos queremos formar.

9.2.2 Modelos de Aprendizaje No Supervisado (Clustering)

Esta parte responde una pregunta exploratoria: **si no miraramos el diagnostico, las variables del tumor ya traen una estructura interna?**

Si KMeans o el metodo jerarquico obtienen buen **Silhouette** y un **ARI** razonable frente al diagnostico, significa que las mediciones geometricas del tumor separan bastante bien a los pacientes. DBSCAN aporta otra mirada: no obliga a todos los pacientes a pertenecer a un grupo y puede detectar observaciones atipicas.

Para una exposicion, la idea clave es esta: el clustering no reemplaza al diagnostico, pero ayuda a descubrir si hay patrones naturales y si existen casos dificiles o raros que merecen revision.

9.3 8.3 Coeficiente de Dunn

2. Dunn Coefficient: calidad de los clusters El coeficiente de Dunn compara dos cosas:

- que tan juntos estan los puntos dentro de cada cluster;
- que tan lejos estan los clusters entre si.

Un valor mas alto es mejor. En palabras simples: Dunn premia grupos compactos y separados. Lo usaremos junto con Silhouette porque una sola metrica rara vez cuenta toda la historia.

```
[136]: def dunn_index(X, labels):
    labels = np.asarray(labels)
    mask = labels != -1
    X_valid = X[mask]
    labels_valid = labels[mask]
    unique_labels = np.unique(labels_valid)

    if len(unique_labels) < 2:
        return np.nan

    distances = squareform(pdist(X_valid))

    max_intra = 0.0
    for label in unique_labels:
        idx = np.where(labels_valid == label)[0]
        if len(idx) > 1:
            intra = distances[np.ix_(idx, idx)].max()
            max_intra = max(max_intra, intra)

    min_inter = np.inf
    for a, b in combinations(unique_labels, 2):
        idx_a = np.where(labels_valid == a)[0]
        idx_b = np.where(labels_valid == b)[0]
        inter = distances[np.ix_(idx_a, idx_b)].min()
        min_inter = min(min_inter, inter)

    if max_intra == 0:
        return np.nan
    return min_inter / max_intra

cluster_quality = cluster_results.copy()
cluster_quality["Dunn"] = [
    dunn_index(X_scaled_cluster, labels_kmeans),
    dunn_index(X_scaled_cluster, labels_jerarquico),
    dunn_index(X_scaled_cluster, labels_dbscan),
]


display(cluster_quality[["Metodo", "Silhouette", "Dunn", "ARI_vs_diagnostico",
↪ "Casos_ruido"]].round(4))

cluster_quality.set_index("Metodo")[["Silhouette", "Dunn"]].plot(kind="bar",
↪ figsize=(10, 4))
```

```
plt.title("Silhouette y Dunn: dos miradas de calidad de clustering")
plt.ylabel("Valor de la metrica")
plt.xticks(rotation=20, ha="right")
plt.show()

print("Lectura para exposicion:")
print("Silhouette mira separacion promedio. Dunn es mas exigente porque se fija en el peor caso: el cluster mas disperso y los clusters mas cercanos.")
```

	Metodo	Silhouette	Dunn	ARI_vs_diagnostico	Casos_ruido
0	KMeans k=2	0.3450	0.0608	0.6707	0
1	Jerarquico Ward k=2	0.3394	0.0724	0.5750	0
2	DBSCAN eps=2.25	0.1619	0.2450	0.2267	293



Lectura para exposicion:

Silhouette mira separacion promedio. Dunn es mas exigente porque se fija en el peor caso: el cluster mas disperso y los clusters mas cercanos.

9.3.1 Analisis de Dunn

Si un metodo tiene buen Silhouette pero Dunn bajo, puede significar que en promedio se ve bien, pero existe algun cluster muy disperso o dos clusters demasiado cercanos. Por eso Dunn ayuda a no quedarnos solo con una metrica bonita.

En este proyecto, Dunn sirve para comparar KMeans, jerarquico y DBSCAN con una pregunta sencilla: **cual metodo produce grupos mas limpios y separados en las mediciones del cancer?**

9.4 8.4 Reglas de Asociación (Apriori)

3. Reglas de asociacion con Apriori Las reglas de asociacion se usan mucho en datos transaccionales, como compras de supermercado. En este dataset no tenemos compras, pero podemos convertir las variables numericas en categorias: bajo, medio y alto.

Por ejemplo, una transaccion puede verse asi:

radius_mean=Alto, concavity_mean=Alto, diagnosis=Maligno

Luego buscamos reglas del tipo:

concavity_mean=Alto y area_mean=Alto -> diagnosis=Maligno

Las metricas principales son:

- **Soporte:** que tan frecuente aparece la combinacion.
- **Confianza:** de los casos que cumplen la condicion, cuantos llegan a la conclusion.
- **Lift:** que tanto mejora la regla frente a mirar la conclusion sin informacion adicional.

```
[137]: association_features = [
        "radius_mean", "texture_mean", "area_mean", "compactness_mean",
        "concavity_mean", "concave points_mean", "symmetry_mean", "radius_worst",
        "area_worst", "concave points_worst"
    ]
    association_features = [c for c in association_features if c in X_cancer.
        ↪columns]

    binned = pd.DataFrame(index=df_cancer.index)
    for col in association_features:
        binned[col] = pd.qcut(X_cancer[col], q=3, labels=["Bajo", "Medio", "Alto"],
        ↪duplicates="drop")

    binned["diagnosis"] = y_labels.values

    transactions = []
    for _, row in binned.iterrows():
        items = [f"{col}={row[col]}" for col in association_features if pd.
        ↪notna(row[col])]
        items.append(f"diagnosis={row['diagnosis']}")
        transactions.append(set(items))

    print("Ejemplo de transaccion discretizada:")
    print(sorted(list(transactions[0]))[:8], "...")
    print("Numero de transacciones:", len(transactions))
```

Ejemplo de transaccion discretizada:

['area_mean=Alto', 'area_worst=Alto', 'compactness_mean=Alto', 'concave
points_mean=Alto', 'concave points_worst=Alto', 'concavity_mean=Alto',
'diagnosis=Maligno', 'radius_mean=Alto'] ...

Numero de transacciones: 569

```

[138]: def apriori_simple(transactions, min_support=0.15, max_len=3):
    n = len(transactions)
    all_items = sorted(set().union(*transactions))
    support_data = {}
    current_level = []

    for item in all_items:
        itemset = frozenset([item])
        support = sum(itemset.issubset(t) for t in transactions) / n
        if support >= min_support:
            support_data[itemset] = support
            current_level.append(itemset)

    k = 2
    while current_level and k <= max_len:
        candidates = set()
        current_list = list(current_level)
        for i in range(len(current_list)):
            for j in range(i + 1, len(current_list)):
                candidate = current_list[i] | current_list[j]
                if len(candidate) == k:
                    candidates.add(candidate)

        next_level = []
        for candidate in candidates:
            support = sum(candidate.issubset(t) for t in transactions) / n
            if support >= min_support:
                support_data[candidate] = support
                next_level.append(candidate)

        current_level = next_level
        k += 1

    return support_data

def generar_reglas(support_data, min_confidence=0.65):
    rules = []
    for itemset, support_itemset in support_data.items():
        if len(itemset) < 2:
            continue
        items = list(itemset)
        for r in range(1, len(items)):
            for antecedent_tuple in combinations(items, r):
                antecedent = frozenset(antecedent_tuple)
                consequent = itemset - antecedent
                if not consequent:
                    continue

```

```

support_antecedent = support_data.get(antecedent)
support_consequent = support_data.get(consequent)
if support_antecedent and support_consequent:
    confidence = support_itemset / support_antecedent
    lift = confidence / support_consequent
    if confidence >= min_confidence:
        rules.append({
            "Antecedente": ", ".join(sorted(antecedent)),
            "Consecuente": ", ".join(sorted(consequent)),
            "Soporte": support_itemset,
            "Confianza": confidence,
            "Lift": lift
        })
return pd.DataFrame(
    rules,
    columns=["Antecedente", "Consecuente", "Soporte", "Confianza", "Lift"]
)

support_data = apriori_simple(transactions, min_support=0.12, max_len=3)
rules_df = generar_reglas(support_data, min_confidence=0.70)

rules_diagnosis = rules_df[rules_df["Consecuente"].str.contains("diagnosis=",
    ↪regex=False)].copy()
rules_diagnosis = rules_diagnosis.sort_values(["Lift", "Confianza", "Soporte"],
    ↪ascending=False)

display(rules_diagnosis.head(15).round(3))

print("Cantidad de itemsets frecuentes:", len(support_data))
print("Cantidad de reglas hacia diagnostico:", len(rules_diagnosis))

```

	Antecedente	Consecuente	Soporte	Confianza	Lift
839	area_mean=Medio	diagnosis=Benigno, radius_mean=Medio	0.262	0.788	3.011
838	radius_mean=Medio	area_mean=Medio, diagnosis=Benigno	0.262	0.793	3.006
646	radius_worst=Alto	area_worst=Alto, diagnosis=Maligno	0.311	0.932	2.995
364	radius_mean=Bajo	area_mean=Bajo, diagnosis=Benigno	0.323	0.963	2.979
363	area_mean=Bajo	diagnosis=Benigno, radius_mean=Bajo	0.323	0.968	2.979
151	radius_mean=Alto	area_mean=Alto, diagnosis=Maligno	0.292	0.874	2.977
152	area_mean=Alto	diagnosis=Maligno, radius_mean=Alto	0.292	0.874	2.977

```

645     area_worst=Alto  diagnosis=Maligno, radius_worst=Alto    0.311    0.
↳932  2.961
808     area_worst=Bajo  diagnosis=Benigno, radius_worst=Bajo    0.323    0.
↳968  2.947
809     radius_worst=Bajo    area_worst=Bajo, diagnosis=Benigno    0.323    0.
↳968  2.931
188     radius_worst=Alto    area_mean=Alto, diagnosis=Maligno    0.286    0.
↳858  2.923
313     area_worst=Alto    area_mean=Alto, diagnosis=Maligno    0.286    0.
↳858  2.923
671     area_worst=Alto  diagnosis=Maligno, radius_mean=Alto    0.286    0.
↳858  2.923
954     radius_worst=Alto  diagnosis=Maligno, radius_mean=Alto    0.286    0.
↳858  2.923
537     radius_worst=Medio  area_worst=Medio, diagnosis=Benigno    0.265    0.
↳799  2.914

```

Cantidad de itemsets frecuentes: 563


Cantidad de reglas hacia diagnostico: 237

```

[139]: if not rules_diagnosis.empty:
        top_rules = rules_diagnosis.head(10).copy()
        top_rules["Regla"] = top_rules["Antecedente"] + " -> " +
↳top_rules["Consecuente"]

        plt.figure(figsize=(10, 6))
        sns.barplot(data=top_rules, y="Regla", x="Lift", hue="Consecuente",
↳dodge=False)
        plt.title("Top reglas de asociacion orientadas al diagnostico")
        plt.xlabel("Lift")
        plt.ylabel("Regla")
        plt.legend(title="Consecuente")
        plt.show()
    else:
        print("No se encontraron reglas hacia diagnostico con los umbrales actuales.
↳ Prueba bajando min_support o min_confidence.")

```



9.4.1 Analisis de reglas de asociacion

Estas reglas no son un clasificador medico formal. Su valor esta en que traducen patrones numericos a frases faciles de explicar.

Una regla con **Lift** mayor que 1 indica que el antecedente aumenta la presencia del diagnostico del consecuente. Por ejemplo, si una regla hacia **diagnosis=Maligno** tiene alta confianza y alto lift, significa que esa combinacion de categorias aparece con mucha fuerza en los casos malignos.

Para estudiantes, esta seccion muestra algo importante: a veces la mineria de datos no busca solo predecir, sino tambien **descubrir relaciones comprensibles**.

9.5 8.5 Análisis de Correspondencias

6. Analisis de Correspondencias El Analisis de Correspondencias sirve para estudiar relaciones entre categorias. Como `Cancer_Data.csv` es numerico, primero convertimos algunas variables a categorias: bajo, medio y alto.

La pregunta sera:

Que categorias de las variables aparecen mas asociadas con diagnosticos benignos o malignos?

Esto complementa PCA: PCA trabaja con variables numericas continuas; Correspondencias trabaja con tablas categoricas.

```
[140]: ca_features = [
    "radius_mean", "texture_mean", "area_mean", "compactness_mean",
    "concavity_mean", "concave points_mean", "radius_worst", "area_worst"
]
ca_features = [c for c in ca_features if c in X_cancer.columns]

ca_cats = pd.DataFrame(index=df_cancer.index)
for col in ca_features:
```



```

ca_cats[col] = pd.qcut(X_cancer[col], q=3, labels=["Bajo", "Medio", "Alto"], duplicates="drop")
ca_cats["Diagnostico"] = y_labels.values

contingency_parts = []
for col in ca_features:
    table_col = pd.crosstab(ca_cats["Diagnostico"], ca_cats[col])
    table_col.columns = [f"{col}={category}" for category in table_col.columns]
    contingency_parts.append(table_col)

ca_table = pd.concat(contingency_parts, axis=1)
display(ca_table)

chi2, p_value, dof, expected = chi2_contingency(ca_table)
print(f"Chi-cuadrado: {chi2:.3f} | p-value: {p_value:.5f} | grados de libertad: {dof}")
print("Un p-value pequeno sugiere que las categorias de variables no se distribuyen igual entre benignos y malignos.")

```

```

radius_mean=Bajo radius_mean=Medio radius_mean=Alto
texture_mean=Bajo texture_mean=Medio \
Diagnostico
Benigno          185          149          23
↳ 169            119
Maligno           6          39          167
↳ 21             71

```

```

texture_mean=Alto area_mean=Bajo area_mean=Medio area_mean=Alto
compactness_mean=Bajo \
Diagnostico
Benigno           69          184          150          23
↳ 173
Maligno           120          6          39          167
↳ 17

```

```

compactness_mean=Medio compactness_mean=Alto concavity_mean=Bajo
concavity_mean=Medio \
Diagnostico
Benigno           139          45          184
↳ 150
Maligno           50          145          6
↳ 39

```

```

concavity_mean=Alto concave points_mean=Bajo concave
points_mean=Medio concave points_mean=Alto \
Diagnostico

```

Benigno	23	188	
↪ 152	17		
Maligno	167	2	
↪ 37	173		

	radius_worst=Bajo	radius_worst=Medio	radius_worst=Alto	
↪ area_worst=Bajo	area_worst=Medio	\		

Diagnostico				
Benigno	187	159	11	
↪ 188	156			
Maligno	3	30	179	
↪ 2	33			

	area_worst=Alto
Diagnostico	
Benigno	13
Maligno	177

Chi-cuadrado: 2449.287 | p-value: 0.00000 | grados de libertad: 23
 Un p-value pequeno sugiere que las categorias de variables no se distribuyen igual entre benignos y malignos.

```
[141]: def correspondence_analysis(table):
    N = table.to_numpy(dtype=float)
    total = N.sum()
    P = N / total
    r = P.sum(axis=1)
    c = P.sum(axis=0)

    expected = np.outer(r, c)
    S = (P - expected) / np.sqrt(expected)

    U, singular_values, Vt = np.linalg.svd(S, full_matrices=False)

    row_coords = (U * singular_values) / np.sqrt(r[:, None])
    col_coords = (Vt.T * singular_values) / np.sqrt(c[:, None])

    row_df = pd.DataFrame(row_coords[:, :2], index=table.index,
    ↪ columns=["Dim1", "Dim2"])
    col_df = pd.DataFrame(col_coords[:, :2], index=table.columns,
    ↪ columns=["Dim1", "Dim2"])
    inertia = singular_values**2

    return row_df, col_df, inertia

row_ca, col_ca, inertia_ca = correspondence_analysis(ca_table)
```

```

print("Inercia explicada por dimension:")
display(pd.DataFrame({
    "Dimension": [f"Dim{i+1}" for i in range(len(inertia_ca))],
    "Inercia": inertia_ca,
    "Porcentaje": inertia_ca / inertia_ca.sum()
}).head().round(4))

display(row_ca.round(4))
display(col_ca.sort_values("Dim1").head(10).round(4))
display(col_ca.sort_values("Dim1").tail(10).round(4))

```

Inercia explicada por dimension:

	Dimension	Inercia	Porcentaje
0	Dim1	0.5381	1.0
1	Dim2	0.0000	0.0

	Dim1	Dim2
Diagnostico		
Benigno	-0.5653	0.0
Maligno	0.9519	0.0

	Dim1	Dim2
concave points_mean=Bajo	-0.7488	0.0
area_worst=Bajo	-0.7488	0.0
radius_worst=Bajo	-0.7380	-0.0
radius_mean=Bajo	-0.7056	-0.0
concavity_mean=Bajo	-0.7053	0.0
area_mean=Bajo	-0.7053	0.0
compactness_mean=Bajo	-0.5856	-0.0
texture_mean=Bajo	-0.5420	-0.0
radius_worst=Medio	-0.4423	-0.0
area_worst=Medio	-0.4095	-0.0

	Dim1	Dim2
compactness_mean=Medio	-0.2234	-0.0
texture_mean=Medio	0.0023	-0.0
texture_mean=Alto	0.5426	-0.0
compactness_mean=Alto	0.8078	-0.0
radius_mean=Alto	1.0473	-0.0
area_mean=Alto	1.0473	-0.0
concavity_mean=Alto	1.0473	-0.0
concave points_mean=Alto	1.1126	-0.0
area_worst=Alto	1.1562	-0.0
radius_worst=Alto	1.1779	-0.0

```
[142]: plt.figure(figsize=(12, 7))
```

```

plt.scatter(row_ca["Dim1"], row_ca["Dim2"], s=180, marker="s", color="black",
            ↪label="Diagnostico")
for label, row in row_ca.iterrows():
    plt.text(row["Dim1"], row["Dim2"], f" {label}", fontsize=12, weight="bold")


col_plot = col_ca.copy()
col_plot["distancia"] = np.sqrt(col_plot["Dim1"]**2 + col_plot["Dim2"]**2)
col_plot = col_plot.sort_values("distancia", ascending=False).head(18)

plt.scatter(col_plot["Dim1"], col_plot["Dim2"], s=70, color="teal", alpha=0.8,
            ↪label="Categorias")
for label, row in col_plot.iterrows():
    plt.text(row["Dim1"], row["Dim2"], " " + label, fontsize=9)

plt.axhline(0, color="gray", linewidth=0.8)
plt.axvline(0, color="gray", linewidth=0.8)
plt.title("Análisis de Correspondencias: diagnostico y categorias de variables")
plt.xlabel("Dimension 1")
plt.ylabel("Dimension 2")
plt.legend()
plt.show()

print("Lectura para exposicion:")
print("Categorias cercanas a 'Maligno' aparecen proporcionalmente mas en casos
      ↪malignos. Categorias cercanas a 'Benigno' aparecen mas en benignos.")
print("Las categorias cerca del centro no diferencian mucho entre diagnosticos.
      ↪")

```



Lectura para exposicion:

Categorías cercanas a 'Maligno' aparecen proporcionalmente mas en casos malignos. Categorías cercanas a 'Benigno' aparecen mas en benignos.

Las categorías cerca del centro no diferencian mucho entre diagnosticos.

9.5.1 Analisis de Correspondencias

Este analisis convierte muchas mediciones numericas en un mapa categorico. Si categorías como valores altos de area, concavidad o puntos concavos quedan cerca de **Maligno**, eso indica una asociacion clara con ese diagnostico. Si categorías bajas quedan cerca de **Benigno**, la lectura tambien es coherente con la intuicion del dataset.

La ventaja para una exposicion es que el resultado se puede explicar como un mapa de cercanias: lo que queda cerca tiende a aparecer junto con mas frecuencia.

Cierre de los temas agregados Con estas secciones, el notebook ya integra los temas centrales y finales de la materia:

- modelos supervisados clasicos;
- comparacion de metricas;
- PCA y reduccion de dimensionalidad;
- clustering con KMeans, jerarquico y DBSCAN;
- evaluacion de clusters con Silhouette y Dunn;
- reglas de asociacion con Apriori;
- SVM;
- Naive Bayes;
- Analisis de Correspondencias.

La lectura general del proyecto queda mas completa: el dataset de cancer no solo se puede clasificar, tambien se puede explorar, agrupar, convertir en reglas interpretables y analizar desde relaciones categoricas. Eso muestra una vision mas amplia de la mineria de datos: predecir, explicar y descubrir patrones.

10 9. Evaluación

Definición de funciones de evaluación y métricas asociadas a los modelos supervisados de clasificación y regresión.

10.0.1 10. Función de evaluación

La función permite comparar todos los modelos con las mismas métricas:

- Accuracy.
- Precision.
- Recall.
- F1-score.

```
[143]: modelo_logistica = LogisticRegression(max_iter=1000, random_state=42)
modelo_logistica.fit(X_train_knn, y_train_knn)
pred_logistica = modelo_logistica.predict(X_test_knn)
print("Regresión Logística:")
print(classification_report(y_test_knn, pred_logistica,
    ↪target_names=["Benigno", "Maligno"]))

modelo_knn = KNeighborsClassifier(n_neighbors=5)
modelo_knn.fit(X_train_knn, y_train_knn)
pred_knn = modelo_knn.predict(X_test_knn)
print("\nKNN (k=5):")
print(classification_report(y_test_knn, pred_knn, target_names=["Benigno",
    ↪"Maligno"]))

modelo_arbol = DecisionTreeClassifier(max_depth=3, random_state=42)
modelo_arbol.fit(X_train_knn, y_train_knn)
pred_arbol = modelo_arbol.predict(X_test_knn)
print("\nÁrbol de Decisión (max_depth=3):")
print(classification_report(y_test_knn, pred_arbol, target_names=["Benigno",
    ↪"Maligno"]))

modelo_rf = RandomForestClassifier(
    n_estimators=200,
    max_depth=None,
    random_state=42,
    n_jobs=-1
)
modelo_rf.fit(X_train_knn, y_train_knn)
pred_rf = modelo_rf.predict(X_test_knn)
print("\nRandom Forest (n_estimators=200):")
print(classification_report(y_test_knn, pred_rf, target_names=["Benigno",
    ↪"Maligno"]))
```

Regresión Logística:

	precision	recall	f1-score	support
Benigno	0.93	0.99	0.96	107
Maligno	0.98	0.88	0.93	64
accuracy			0.95	171
macro avg	0.96	0.93	0.94	171
weighted avg	0.95	0.95	0.95	171

KNN (k=5):

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

Benigno	0.91	0.99	0.95	107
Maligno	0.98	0.83	0.90	64
accuracy			0.93	171
macro avg	0.94	0.91	0.92	171
weighted avg	0.93	0.93	0.93	171

Árbol de Decisión (max_depth=3):

	precision	recall	f1-score	support
Benigno	0.88	1.00	0.94	107
Maligno	1.00	0.78	0.88	64
accuracy			0.92	171
macro avg	0.94	0.89	0.91	171
weighted avg	0.93	0.92	0.92	171

Random Forest (n_estimators=200):

	precision	recall	f1-score	support
Benigno	0.96	1.00	0.98	107
Maligno	1.00	0.92	0.96	64
accuracy			0.97	171
macro avg	0.98	0.96	0.97	171
weighted avg	0.97	0.97	0.97	171

10.0.2 3.0.1 Función de Evaluación y Métricas de Regresión

```
[144]: if "resultados_reg" not in globals() or not resultados_reg: resultados_reg = []
```

11 10. Comparación de Modelos

Comparativas visuales y tabulares de todos los modelos entrenados (con y sin PCA) para determinar cuál ofrece el mejor comportamiento general.

Comparación general de modelos (Dataset de Cáncer) En esta sección se consolida la comparación final entre los modelos de clasificación trabajados en el proyecto:

1. Regresión Logística
2. KNN
3. Árbol de Decisión
4. Random Forest

Se evaluará con las métricas:

- Accuracy
- Precision
- Recall
- F1-score


```
[145]: resultados = [
    evaluar_modelo_final("Regresión Logística", y_test, pred_logistica),
    evaluar_modelo_final("KNN", y_test, pred_knn),
    evaluar_modelo_final("Árbol de Decisión", y_test, pred_arbol),
    evaluar_modelo_final("Random Forest", y_test, pred_rf)
]

comparacion_general_modelos = pd.DataFrame(resultados).sort_values("F1-score",
    ↪ascending=False).reset_index(drop=True)
print("Tabla final de comparación:")
display(comparacion_general_modelos)

# Visualización de métricas
metricas = ["Accuracy", "Precision", "Recall", "F1-score"]
comparacion_general_modelos.set_index("Modelo")[metricas].plot(kind="bar",
    ↪figsize=(11, 5))
plt.title("Comparación general de modelos - Dataset de Cáncer")
plt.ylabel("Valor")
plt.ylim(0, 1)
plt.xticks(rotation=20)
plt.grid(axis="y", alpha=0.3)
plt.show()
```

Tabla final de comparación:

	Modelo	Accuracy	Precision	Recall	F1-score
0	Random Forest	0.970760	1.000000	0.921875	0.959350
1	Regresión Logística	0.947368	0.982456	0.875000	0.925620
2	KNN	0.929825	0.981481	0.828125	0.898305
3	Árbol de Decisión	0.918129	1.000000	0.781250	0.877193



Interpretación de la comparación Preguntas clave:

1. ¿Cuál modelo tiene mayor accuracy?
2. ¿Cuál tiene mayor recall?
3. ¿Cuál tiene mayor precision?
4. ¿Cuál tiene mejor F1?
5. ¿Cuál es más interpretable?
6. ¿Cuál depende más del preprocesamiento?
7. ¿Cuál recomendaría y por qué?

No siempre gana el modelo con mayor accuracy. La elección depende del objetivo del problema.

```
[146]: # Respuestas automáticas basadas en la tabla comparativa
mejor_accuracy = comparacion_general_modelos.
    ↳loc[comparacion_general_modelos["Accuracy"].idxmax(), "Modelo"]
mejor_recall = comparacion_general_modelos.
    ↳loc[comparacion_general_modelos["Recall"].idxmax(), "Modelo"]
mejor_precision = comparacion_general_modelos.
    ↳loc[comparacion_general_modelos["Precision"].idxmax(), "Modelo"]
mejor_f1 = comparacion_general_modelos.
    ↳loc[comparacion_general_modelos["F1-score"].idxmax(), "Modelo"]

print("1) Modelo con mayor Accuracy:", mejor_accuracy)
print("2) Modelo con mayor Recall:", mejor_recall)
print("3) Modelo con mayor Precision:", mejor_precision)
print("4) Modelo con mejor F1-score:", mejor_f1)
```

```

print("5) Modelo más interpretable: Árbol de Decisión (también Regresión_
↳Logística es interpretable)")
print("6) Modelo que más depende del preprocesamiento: KNN (y también Regresión_
↳Logística por escalado)")

# Recomendación final para el dataset de cáncer
modelo_recomendado = mejor_f1

print("\nConclusión final:")
print(f"Para este dataset de cáncer, el modelo recomendado es:_
↳{modelo_recomendado}.")
print("Razón: prioriza el mejor equilibrio entre Precision y Recall (medido por_
↳F1-score),")
print("lo cual es clave en clasificación médica para reducir errores relevantes_
↳en diagnóstico.")

```

- 1) Modelo con mayor Accuracy: Random Forest
- 2) Modelo con mayor Recall: Random Forest
- 3) Modelo con mayor Precision: Random Forest
- 4) Modelo con mejor F1-score: Random Forest
- 5) Modelo más interpretable: Árbol de Decisión (también Regresión Logística es interpretable)
- 6) Modelo que más depende del preprocesamiento: KNN (y también Regresión Logística por escalado)

Conclusión final:

Para este dataset de cáncer, el modelo recomendado es: Random Forest.

Razón: prioriza el mejor equilibrio entre Precision y Recall (medido por F1-score),

lo cual es clave en clasificación médica para reducir errores relevantes en diagnóstico.

3. Comparación general de modelos Tabla comparativa de desempeño con las métricas principales:

```

[147]: resultados = [
    evaluar_modelo("Regresión Logística", y_test_knn, pred_logistica),
    evaluar_modelo("KNN", y_test_knn, pred_knn),
    evaluar_modelo("Árbol max_depth=3", y_test_knn, pred_arbol),
    evaluar_modelo("Random Forest", y_test_knn, pred_rf)
]

df_comparacion = pd.DataFrame(resultados)

col_f1 = 'F1-score' if 'F1-score' in df_comparacion.columns else 'F1-Score'

```

```

comparacion_general = df_comparacion.sort_values(col_f1, ascending=False).
    ↪reset_index(drop=True)

print("Comparación de modelos - Dataset Cáncer:")
display(comparacion_general)


metricas = ["Accuracy", "Precision", "Recall", col_f1]
comparacion_general.set_index("Modelo")[metricas].plot(kind="bar", figsize=(12, 5))
    ↪5))

plt.title("Comparación de métricas entre modelos (Cancer_Data.csv)")
plt.ylabel("Valor")
plt.ylim(0, 1.05)
plt.xticks(rotation=45)
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()
plt.show()

```

Comparación de modelos - Dataset Cáncer:

	Modelo	Accuracy	Precision	Recall	F1-Score
0	Random Forest	0.970760	1.000000	0.921875	0.959350
1	Regresión Logística	0.947368	0.982456	0.875000	0.925620
2	KNN	0.929825	0.981481	0.828125	0.898305
3	Árbol max_depth=3	0.918129	1.000000	0.781250	0.877193



11.0.1 7.1 Comparación de modelos usando Recall

Ahora repetimos la comparación final usando **Recall** como métrica principal. Esto permite priorizar la capacidad del modelo para detectar casos malignos reales.


```
[148]: resultados_recall = [
    {"Modelo": "Regresión Logística", "Recall": recall_score(y_test_knn,
    ↪pred_logistica, zero_division=0)},
    {"Modelo": "KNN", "Recall": recall_score(y_test_knn, pred_knn,
    ↪zero_division=0)},
    {"Modelo": "Árbol max_depth=3", "Recall": recall_score(y_test_knn,
    ↪pred_arbol, zero_division=0)},
    {"Modelo": "Random Forest", "Recall": recall_score(y_test_knn, pred_rf,
    ↪zero_division=0)}
]

comparacion_recall = pd.DataFrame(resultados_recall).sort_values("Recall",
    ↪ascending=False).reset_index(drop=True)
print("Comparación de modelos priorizando Recall:")
display(comparacion_recall)

plt.figure(figsize=(10, 4))
plt.bar(comparacion_recall["Modelo"], comparacion_recall["Recall"],
    ↪color=["#4C78A8", "#F58518", "#54A24B", "#E45756"])
plt.title("Comparación de modelos según Recall - Dataset de Cáncer")
plt.ylabel("Recall")
plt.ylim(0, 1.05)
plt.xticks(rotation=20)
plt.grid(axis="y", alpha=0.3)
plt.tight_layout()
plt.show()
```

Comparación de modelos priorizando Recall:

	Modelo	Recall
0	Random Forest	0.921875
1	Regresión Logística	0.875000
2	KNN	0.828125
3	Árbol max_depth=3	0.781250



11.0.2 2.2 Métricas de Rendimiento (Sin PCA vs Con PCA 5 Comp)

Calculamos Accuracy, Precision, Recall y F1-Score para valores de K del 1 al 20.

```
[149]: # Pivot the table to get metrics as columns and models as sub-columns
df_comparison_metrics = df_metrics.pivot_table(
    index='K',
    columns=['Metrica', 'Modelo'],
    values='Valor'
)

# Flatten the multi-level columns and rename them to match the user's request
new_column_names = []
for metric, model in df_comparison_metrics.columns:
    model_name_prefix = ''
    if 'Sin PCA' in model:
        model_name_prefix = 'KNN_sin_PCA'
    elif 'Con PCA' in model:
        model_name_prefix = 'KNN_con_PCA'
    else:
        model_name_prefix = model.replace(' ', '_') # Fallback
    new_column_names.append(f'{model_name_prefix}_{metric}')

df_comparison_metrics.columns = new_column_names

# Reset index to make 'K' a regular column
df_comparison_metrics = df_comparison_metrics.reset_index()

# Reorder columns: K first, then group by metric (Sin PCA, Con PCA)
ordered_metrics = ['Accuracy', 'Precision', 'Recall', 'F1-Score']

final_columns_order = ['K']
for metric in ordered_metrics:
    final_columns_order.append(f'KNN_sin_PCA_{metric}')
    final_columns_order.append(f'KNN_con_PCA_{metric}')

df_final_comparison = df_comparison_metrics[final_columns_order]

display(df_final_comparison)
```

	K	KNN_sin_PCA_Accuracy	KNN_con_PCA_Accuracy	KNN_sin_PCA_Precision	KNN_con_PCA_Precision	KNN_sin_PCA_Recall	KNN_con_PCA_Recall	F1-Score
0	1	0.941520	0.947368	0.935484	0.966102	0.906250	0.925926	0.935484

1	2		0.935673	0.929825	1.000000	␣
↪		0.981481	0.828125			
2	3		0.959064	0.947368	1.000000	␣
↪		0.982456	0.890625			
3	4		0.959064	0.947368	1.000000	␣
↪		0.982456	0.890625			
4	5		0.964912	0.953216	1.000000	␣
↪		0.982759	0.906250			
5	6		0.959064	0.947368	1.000000	␣
↪		0.982456	0.890625			
6	7		0.964912	0.947368	1.000000	␣
↪		0.982456	0.906250			
7	8		0.953216	0.947368	1.000000	␣
↪		0.982456	0.875000			
8	9		0.953216	0.947368	0.982759	␣
↪		0.982456	0.890625			
9	10		0.953216	0.947368	0.982759	␣
↪		0.982456	0.890625			
10	11		0.953216	0.947368	0.982759	␣
↪		0.982456	0.890625			
11	12		0.953216	0.947368	1.000000	␣
↪		0.982456	0.875000			
12	13		0.947368	0.947368	0.982456	␣
↪		0.982456	0.875000			
13	14		0.941520	0.953216	1.000000	␣
↪		1.000000	0.843750			
14	15		0.947368	0.959064	0.982456	␣
↪		1.000000	0.875000			
15	16		0.947368	0.953216	1.000000	␣
↪		1.000000	0.859375			
16	17		0.947368	0.953216	0.982456	␣
↪		0.982759	0.875000			
17	18		0.947368	0.953216	1.000000	␣
↪		1.000000	0.859375			
18	19		0.947368	0.947368	1.000000	␣
↪		0.982456	0.859375			
19	20		0.947368	0.953216	1.000000	␣
↪		1.000000	0.859375			
20	21		0.953216	0.947368	1.000000	␣
↪		0.982456	0.875000			
21	22		0.953216	0.947368	1.000000	␣
↪		0.982456	0.875000			
22	23		0.953216	0.953216	1.000000	␣
↪		0.982759	0.875000			
23	24		0.947368	0.947368	1.000000	␣
↪		1.000000	0.859375			

24	25	0.953216	0.953216	1.000000	␣
↪		1.000000	0.875000		
25	26	0.947368	0.947368	1.000000	␣
↪		1.000000	0.859375		
26	27	0.953216	0.947368	1.000000	␣
↪		1.000000	0.875000		
27	28	0.953216	0.947368	1.000000	␣
↪		1.000000	0.875000		
28	29	0.953216	0.947368	1.000000	␣
↪		1.000000	0.875000		
29	30	0.953216	0.947368	1.000000	␣
↪		1.000000	0.875000		


	KNN_con_PCA_Recall	KNN_sin_PCA_F1-Score	KNN_con_PCA_F1-Score
0	0.890625	0.920635	0.926829
1	0.828125	0.905983	0.898305
2	0.875000	0.942149	0.925620
3	0.875000	0.942149	0.925620
4	0.890625	0.950820	0.934426
5	0.875000	0.942149	0.925620
6	0.875000	0.950820	0.925620
7	0.875000	0.933333	0.925620
8	0.875000	0.934426	0.925620
9	0.875000	0.934426	0.925620
10	0.875000	0.934426	0.925620
11	0.875000	0.933333	0.925620
12	0.875000	0.925620	0.925620
13	0.875000	0.915254	0.933333
14	0.890625	0.925620	0.942149
15	0.875000	0.924370	0.933333
16	0.890625	0.925620	0.934426
17	0.875000	0.924370	0.933333
18	0.875000	0.924370	0.925620
19	0.875000	0.924370	0.933333
20	0.875000	0.933333	0.925620
21	0.875000	0.933333	0.925620
22	0.890625	0.933333	0.934426
23	0.859375	0.924370	0.924370
24	0.875000	0.933333	0.933333
25	0.859375	0.924370	0.924370
26	0.859375	0.933333	0.924370
27	0.859375	0.933333	0.924370
28	0.859375	0.933333	0.924370
29	0.859375	0.933333	0.924370

```
[150]: g = sns.relplot(
        data=df_metrics, x="K", y="Valor", hue="Modelo", col="Metrica",
```

```

kind="line", marker="o", col_wrap=2, height=4, aspect=1.5,
palette=['#1f77b4', '#2ca02c']
)
g.set(xticks=k_values)
g.fig.suptitle('Evolución de Métricas según K', y=1.05)
plt.show()

```



3. Matrices de Confusión Comparamos los errores (falsos positivos/negativos) de ambos modelos para un $K = 5$.

11.0.3 Modelos de Random Forest

Lectura del rendimiento - Al usar todas las variables originales, el modelo aprovecha la información completa del dataset, incluyendo relaciones no lineales entre variables. - Si las métricas (accuracy, precision, recall, f1) son altas y balanceadas, significa que el modelo está clasificando bien tanto benignos como malignos. - La matriz de confusión permite ver el tipo de error más delicado: un **falso negativo** (maligno clasificado como benigno).

Análisis con gráficas - Importancia de variables: el gráfico muestra que pocas variables concentran buena parte del poder predictivo, lo cual es común en datasets clínicos. - **Sensibilidad a $n_estimators$:** si las curvas se estabilizan a partir de cierto número de árboles, significa que agregar más árboles da mejoras marginales.

Interpretación didáctica - Random Forest combina muchos árboles y reduce el sobreajuste de un

arbol individual. - En este escenario, las variables originales mantienen interpretabilidad directa: cada variable es una medicion clinica real. - Si el modelo sin PCA obtiene resultados superiores, es una senal de que la informacion detallada ayuda mas que la reduccion de dimensiones.

Conclusiones clave - El modelo sin PCA suele maximizar el rendimiento porque no pierde informacion en la transformacion. - Es ideal cuando el objetivo es **maxima precision diagnostica** y no se tiene problema con muchas variables. - La lectura de la matriz de confusion es fundamental para decidir si el modelo es aceptable en un contexto medico.

11.0.4 Modelos de Random Forest

Lectura del cambio - En la version anterior, Random Forest con PCA elegia automaticamente las componentes necesarias para llegar aproximadamente al 95% de varianza; eso llevaba a usar mas componentes. - Ahora se usan **5 componentes**, igual que en Arbol de Decision, KNN y Regresion. La comparacion queda mas estandarizada porque todos los modelos con PCA reciben la misma cantidad de informacion resumida. - Si las metricas bajan frente a la version sin PCA, no significa que Random Forest sea malo; significa que cinco componentes pueden no conservar toda la senal que el ensamble aprovechaba con variables originales.

Analisis con graficas - Varianza acumulada: muestra cuanta informacion retienen las primeras cinco componentes y que tanta informacion queda por fuera. - **Loadings (PC1 y PC2):** permiten explicar que variables originales pesan mas en las primeras componentes. - **Dispersión PC1 vs PC2:** ayuda a ver si benignos y malignos se separan visualmente en el espacio reducido.

Interpretacion didactica - PCA hace el modelo mas compacto, pero reduce interpretabilidad: las componentes son mezclas de variables originales. - En Random Forest, PCA no siempre mejora el rendimiento porque el modelo ya maneja muchas variables y relaciones no lineales. - El valor de esta seccion es comparar de forma justa: cinco componentes para todos los modelos con PCA.

Conclusion clave - Random Forest sin PCA suele ser mas interpretable en terminos de importancia de variables originales. - Random Forest con PCA de 5 componentes es util para evaluar cuanto rendimiento se conserva cuando obligamos al modelo a trabajar con una representacion reducida y comun a los demas modelos.

11.0.5 10. Comparacion final de resultados (metricas y breve analisis)

Construimos una tabla y un grafico para comparar el rendimiento entre:

- Random Forest sin PCA.
- Random Forest con PCA.

Luego discutimos cual conviene y por que.


```
[151]: comparacion = pd.DataFrame([
    {**metricas_base, "modelo": "Random Forest sin PCA"},
    {**metricas_pca, "modelo": "Random Forest con PCA (5 comp)"}
])
comparacion
```

	modelo	accuracy	precision	recall	f1
0	Random Forest sin PCA	0.970760	1.000000	0.921875	0.959350

```
1 Random Forest con PCA (5 comp) 0.938596 0.906977 0.928571 0.917647
```

```
[152]: metricas_cols = ["accuracy", "precision", "recall", "f1"]

comparacion.set_index("modelo")[metricas_cols].plot(kind="bar", figsize=(9, 4))
plt.title("Comparacion de metricas: sin PCA vs con PCA")
plt.ylabel("Valor")
plt.ylim(0, 1)
plt.xticks(rotation=15)
plt.grid(axis="y")
plt.show()
```



Comparacion final: sin PCA vs con PCA Diferencias puntuales - Entrada del modelo:

- Sin PCA: variables clinicas originales (interpretables). - Con PCA: componentes sinteticas (menos interpretables). - **Desempeno esperado:** - Sin PCA: suele ser igual o mejor si las variables aportan informacion directa. - Con PCA: puede bajar un poco si se pierde senal, o mantenerse si la varianza retenida es alta. - **Complejidad y mantenimiento:** - Sin PCA: mas variables, mas costo de analisis, pero mayor transparencia. - Con PCA: menos variables, mas compacto, pero menos explicable.

Analisis general con apoyo grafico - El grafico de **n_estimators** indica si el modelo sin PCA ya esta estable con 200 arboles o si aun gana al subir el numero. - El **scree plot** y los **loadings** explican cuanta informacion retuvo PCA y que variables influyen mas en los componentes. - El scatter **PC1 vs PC2** muestra si existe separacion visible entre benignos y malignos en el espacio reducido.

Conclusiones completas - Random Forest sin PCA es la mejor opción cuando se busca el mayor rendimiento posible y se requiere interpretabilidad directa en variables clínicas. - **Random Forest con PCA** es útil cuando se necesita simplificar el modelo o reducir dimensionalidad, aceptando cierta pérdida de interpretabilidad. - La decisión final debe basarse en el equilibrio entre: - calidad de clasificación, - riesgo de errores clínicos, - facilidad para explicar el modelo, - costo computacional.


En resumen: si el rendimiento del modelo sin PCA es superior, se recomienda mantener las variables originales. Si ambos rendimientos son similares, PCA es una alternativa válida para simplificar el modelo sin sacrificar demasiado desempeño.

11.0.6 2.3 Comparación de Métricas – Regresión Logística (Sin PCA vs Con PCA)

Comparamos Accuracy, Precision, Recall y F1-Score de ambos modelos.

```
[153]: col_modelo = 'Modelo' if 'Modelo' in comparacion_logistica.columns else 'modelo'
col_acc = 'Accuracy' if 'Accuracy' in comparacion_logistica.columns else 'accuracy'
col_prec = 'Precision' if 'Precision' in comparacion_logistica.columns else 'precision'
col_rec = 'Recall' if 'Recall' in comparacion_logistica.columns else 'recall'
col_f1 = 'F1-Score' if 'F1-Score' in comparacion_logistica.columns else 'f1-score' if 'F1-score' in comparacion_logistica.columns else 'f1'

metrics_lr = [col_acc, col_prec, col_rec, col_f1]
df_melt_lr = comparacion_logistica.melt(
    id_vars=col_modelo, value_vars=metrics_lr,
    var_name='Métrica', value_name='Valor'
)
g = sns.catplot(
    data=df_melt_lr, x='Métrica', y='Valor', hue=col_modelo,
    kind='bar', height=5, aspect=1.5, palette=['#1f77b4', '#2ca02c']
)
g.fig.suptitle('Comparación de Métricas - Regresión Logística (Sin PCA vs Con PCA)', y=1.03)
plt.show()
```



11.0.7 2.4 Detección de Overfitting – Regresión Logística

Comparamos el reporte de clasificación en Train vs Test para cada modelo.

```
[154]: # Sin PCA
y_train_pred_lr = pipeline_lr.predict(X_train)
print('=== Sin PCA ===')
print('--- Test ---')
print(classification_report(y_test, y_pred_lr, target_names=['Benigno',
↳ 'Maligno']))
print('--- Train ---')
print(classification_report(y_train, y_train_pred_lr, target_names=['Benigno',
↳ 'Maligno']))

# Con PCA
y_train_pred_lr_pca = lr_pca.predict(X_train_pca)
print('\n=== Con PCA ===')
print('--- Test ---')
print(classification_report(y_test, y_pred_lr_pca, target_names=['Benigno',
↳ 'Maligno']))
print('--- Train ---')
print(classification_report(y_train, y_train_pred_lr_pca,
↳ target_names=['Benigno', 'Maligno']))
```

```
=== Sin PCA ===
--- Test ---
              precision    recall  f1-score   support
```

Benigno	0.96	0.99	0.98	107
Maligno	0.98	0.94	0.96	64
accuracy			0.97	171
macro avg	0.97	0.96	0.97	171
weighted avg	0.97	0.97	0.97	171

--- Train ---

	precision	recall	f1-score	support
Benigno	0.98	1.00	0.99	285
Maligno	1.00	0.96	0.98	170
accuracy			0.99	455
macro avg	0.99	0.98	0.99	455
weighted avg	0.99	0.99	0.99	455

=== Con PCA ===

--- Test ---

	precision	recall	f1-score	support
Benigno	0.98	1.00	0.99	107
Maligno	1.00	0.97	0.98	64
accuracy			0.99	171
macro avg	0.99	0.98	0.99	171
weighted avg	0.99	0.99	0.99	171

--- Train ---

	precision	recall	f1-score	support
Benigno	0.97	0.98	0.98	285
Maligno	0.97	0.95	0.96	170
accuracy			0.97	455
macro avg	0.97	0.97	0.97	455
weighted avg	0.97	0.97	0.97	455

11.0.8 2.5 Matrices de Confusión – Regresión Logística

Comparamos los errores (falsos positivos / negativos) de ambos modelos.

```
[155]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))

sns.heatmap(confusion_matrix(y_test, y_pred_lr), annot=True, fmt='d',
```


```

cmap='Blues', ax=axes[0])
axes[0].set_title('Matriz de Confusión - Log. Reg. Sin PCA')
axes[0].set_xlabel('Predicción (0: B, 1: M)')
axes[0].set_ylabel('Real')

sns.heatmap(confusion_matrix(y_test, y_pred_lr_pca), annot=True, fmt='d',
            cmap='Greens', ax=axes[1])
axes[1].set_title('Matriz de Confusión - Log. Reg. Con PCA')
axes[1].set_xlabel('Predicción (0: B, 1: M)')
axes[1].set_ylabel('Real')

plt.tight_layout()
plt.show()

```



11.0.9 Modelos de Regresión Lineal

Aplicamos Regresión Lineal para predecir una variable continua (**area_mean**).

Nota: Para la Regresión Lineal se redefine la variable objetivo (**y**) como **area_mean** (continua), a diferencia de la Logística que predice **diagnosis** (categórica). Por ello se requiere un nuevo split y un nuevo PCA que **no incluya area_mean** entre las features.

11.0.10 Modelos de Regresión Lineal

Comparamos MAE, RMSE y R^2 de ambos modelos.

```


[156]: comparacion_lineal = pd.DataFrame(resultados_reg)
display(comparacion_lineal)

```

	objetivo		modelo		Modelo	MAE	
	MSE	RMSE	R2	R ²			
0	Reg. Lineal Sin PCA	Reg. Lineal Sin PCA	Reg. Lineal Sin PCA	Reg. Lineal Sin PCA	0.045611	0.	
	0.004922	0.070156	0.999597	0.999597			
1	Reg. Lineal Con PCA	Reg. Lineal Con PCA	Reg. Lineal Con PCA	Reg. Lineal Con PCA	0.546198	0.	
	0.545378	0.738497	0.955330	0.955330			

```
[157]: # Gráfica comparativa de métricas
df_melt_rl = comparacion_lineal.melt(
    id_vars='Modelo', value_vars=['MAE', 'RMSE', 'R2'],
    var_name='Métrica', value_name='Valor'
)

g = sns.catplot(
    data=df_melt_rl, x='Métrica', y='Valor', hue='Modelo',
    kind='bar', height=5, aspect=1.5, palette=['#1f77b4', '#2ca02c']
)
g.fig.suptitle('Comparación de Métricas - Reg. Lineal (Sin PCA vs Con PCA)',
    y=1.03)
plt.show()
```



11.0.11 Modelos de Regresión Lineal

Visualizamos la dispersión de valores reales contra predichos para ambos modelos.


Nota: La Regresión Lineal predice un valor continuo, por lo que una Matriz de Confusión no aplica. En su lugar, usamos gráficas de dispersión Real vs Predicho.

```
[158]: fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Sin PCA
axes[0].scatter(y_test_reg, pred_nopca, alpha=0.5, color='#1f77b4')
axes[0].plot([y_reg.min(), y_reg.max()], [y_reg.min(), y_reg.max()], 'r--')
axes[0].set_title('Real vs Predicho - Sin PCA')
axes[0].set_xlabel('Valor Real (area_mean)')
axes[0].set_ylabel('Valor Predicho')

# Con PCA
axes[1].scatter(y_test_reg, pred_pca, alpha=0.5, color='#2ca02c')
axes[1].plot([y_reg.min(), y_reg.max()], [y_reg.min(), y_reg.max()], 'r--')
axes[1].set_title('Real vs Predicho - Con PCA')
axes[1].set_xlabel('Valor Real (area_mean)')
axes[1].set_ylabel('Valor Predicho')

plt.tight_layout()
plt.show()
```



Síntesis final según lineamientos Esta sección funciona como cierre de exposición. Reune la comparación general, el criterio de selección del mejor modelo y las conclusiones finales del proyecto.

En un problema de diagnóstico de cáncer no basta con mirar **accuracy**. El indicador más delicado es **recall** para la clase maligna, porque un falso negativo significa clasificar como benigno un caso que realmente era maligno. Por eso la recomendación debe equilibrar:

- buen **recall** en malignos;
- buen **F1-score**;
- baja cantidad de falsos negativos;
- interpretabilidad suficiente para explicar el resultado;
- estabilidad entre entrenamiento y prueba.


```

[159]: resumen_supervisados = []

def agregar_metricas(nombre, metricas):
    if isinstance(metricas, dict):
        resumen_supervisados.append({
            "Modelo": nombre,
            "Accuracy": metricas.get("accuracy", metricas.get("Accuracy")),
            "Precision": metricas.get("precision", metricas.get("Precision")),
            "Recall": metricas.get("recall", metricas.get("Recall")),
            "F1": metricas.get("f1", metricas.get("F1", metricas.
↪get("F1-Score")))
        })

if "metricas_base" in globals():
    agregar_metricas("Random Forest sin PCA", metricas_base)
if "metricas_pca" in globals():
    agregar_metricas("Random Forest con PCA (5 comp)", metricas_pca)
if "svm_results_df" in globals() and not svm_results_df.empty:
    for _, row in svm_results_df.iterrows():
        resumen_supervisados.append({
            "Modelo": row["Modelo"],
            "Accuracy": row["Accuracy"],
            "Precision": row["Precision"],
            "Recall": row["Recall"],
            "F1": row["F1"]
        })
if "nb_results" in globals() and not nb_results.empty:
    row = nb_results.iloc[0]
    resumen_supervisados.append({
        "Modelo": row["Modelo"],
        "Accuracy": row["Accuracy"],
        "Precision": row["Precision"],
        "Recall": row["Recall"],
        "F1": row["F1"]
    })

if resumen_supervisados:
    resumen_supervisados = pd.DataFrame(resumen_supervisados)
    resumen_supervisados = resumen_supervisados.sort_values(["Recall", "F1", ↪
↪"Accuracy"], ascending=False)
    display(resumen_supervisados.round(4))
    print("Modelo recomendado segun prioridad Recall + F1:", ↪
↪resumen_supervisados.iloc[0]["Modelo"])
else:
    print("Ejecuta las secciones de modelos para construir la tabla final de ↪
↪modelos supervisados.")

```

	Modelo	Accuracy	Precision	Recall	F1
1	Random Forest con PCA (5 comp)	0.9386	0.907	0.9286	0.9176
2	SVM RBF	0.9720	1.000	0.9245	0.9608
0	Random Forest sin PCA	0.9708	1.000	0.9219	0.9593
3	SVM lineal	0.9580	1.000	0.8868	0.9400
4	Gaussian Naive Bayes	0.9441	1.000	0.8491	0.9184

Modelo recomendado segun prioridad Recall + F1: Random Forest con PCA (5 comp)

12 11. Mejor Modelo y Justificación

12.0.1 Justificación del Modelo Seleccionado

12.0.2 Evaluación Comparativa de Modelos de Clasificación

A continuación se presenta la tabla de métricas obtenidas para cada modelo supervisado evaluado sobre el conjunto de prueba:

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest	0.9708	1.0000	0.9219	0.9594
Regresión Logística	0.9415	0.9821	0.8594	0.9167
KNN (k=5)	0.9298	0.9815	0.8281	0.8983
Árbol de Decisión (max_depth=3)	0.9181	1.0000	0.7813	0.8772

12.0.3 Modelos de Random Forest

El criterio de selección principal es el **Recall** sobre la clase **Maligna**, dado el contexto médico-oncológico del problema. En diagnóstico de cáncer de mama, un **falso negativo** (clasificar un tumor maligno como benigno) representa un error clínicamente grave, ya que implicaría dejar sin tratamiento a un paciente con cáncer. Por ello, maximizar el Recall es prioritario sobre cualquier otra métrica.

Random Forest obtuvo el Recall más alto de todos los modelos evaluados: 0.9219 (92.19%), lo que significa que identificó correctamente el 92.19% de los casos malignos presentes en el conjunto de prueba.

Como criterio secundario, el **F1-Score** confirma esta elección: Random Forest alcanzó un F1-Score de **0.9594**, el más alto de la comparación, evidenciando que no sacrifica la Precision en favor del Recall, sino que logra un equilibrio superior al resto de los modelos.

12.0.4 Resumen de Fortalezas del Modelo Seleccionado

- **Recall = 0.9219** → El más alto del conjunto, reduciendo al máximo los falsos negativos.

- **F1-Score = 0.9594** → Mejor balance general entre Precision y Recall.
 - **Precision = 1.000** → No genera ningún falso positivo; todas las predicciones de malignidad son correctas.
 - **Accuracy = 0.9708** → La tasa de clasificación correcta global es también la más alta.
-

13 12. Conclusiones

13.0.1 Resumen de Conclusiones y Trabajo Futuro

El análisis de detección de cáncer de mama sobre el dataset de Wisconsin (Cancer Data) permitió desarrollar un pipeline completo de minería de datos que abarca desde la exploración y preparación de los datos hasta la implementación y comparación de múltiples modelos de Machine Learning.

Los principales hallazgos del proyecto son:

1. **La calidad de los datos fue determinante.** La eliminación de la columna `Unnamed: 32` (completamente nula) y la variable `id` (sin valor predictivo), junto con la correcta estandarización mediante `StandardScaler`, generaron resultados consistentes. Modelos como KNN mostraron una degradación severa en sus métricas sin escalado previo.
2. **Random Forest fue el mejor modelo en el contexto del problema.** Con un Recall del 92.19% sobre la clase maligna y un F1-Score del 95.94%, demostró ser el algoritmo más adecuado para minimizar los errores clínicamente costosos (falsos negativos), al tiempo que mantiene la mayor exactitud global entre todos los modelos evaluados.
3. **La reducción de dimensionalidad con PCA aportó mejoras moderadas.** En modelos como el Árbol de Decisión, la aplicación de PCA mejoró el Recall de 0.9048 a 0.9286, aunque con una ligera pérdida de interpretabilidad.
4. **El balance entre Precision y Recall es clave en clasificación médica.** Modelos con alta Precision pero bajo Recall (como el Árbol de Decisión sin ajuste) son menos adecuados para este problema, a pesar de su buena exactitud general.
5. **El análisis no supervisado (PCA, K-Means, Clustering Jerárquico, DBSCAN) reveló una separación natural** entre las clases benigna y maligna en el espacio de características, lo que respalda la viabilidad del problema para métodos supervisados y valida la coherencia de los resultados obtenidos.

13.0.2 Limitaciones y mejoras futuras

- El dataset es relativamente pequeño para conclusiones clínicas definitivas.
- Las metricas dependen de una particion train/test; una mejora futura seria usar validacion cruzada.
- Conviene ajustar hiperparametros con busqueda sistematica, especialmente en SVM, Random Forest y DBSCAN.
- Para un uso real en salud se necesitaria validacion externa con datos de otra fuente.